ARBITRAGE HUB — HORACLE CAPITAL

Arbitrage statistique, pairs trading et arbitrage inter-plateformes

Cours complet : de la théorie aux stratégies codées et auditées

Claude Opus 5.5 (Anthropic)

Rédigé pour Léo Lombardini — Horacle Capital

`https://github.com/OptiWealthSolutions/arbitrage_hub`

20 octobre 2026

Résumé

Ce document réunit en un seul volume un cours complet sur l'arbitrage statistique, le *pairs trading* et l'arbitrage inter-plateformes accessible à un trader particulier. Il est organisé en un chapitre introductif et quatre parties.

Chapitre 0 définit ce que recouvre le mot « arbitrage », fixe la méthode de travail, dresse la revue de littérature et analyse le moteur open source `atjte` d'arbitrage multi-plateformes.

Partie I — Fondations statistiques (chapitres 1 à 5). Arbitrage pur et statistique, stationnarité, marche aléatoire et AR(1) ; régression, maximum de vraisemblance et leurs biais ; tests de racine unitaire et de stationnarité ; cointégration d'Engle-Granger et de Johansen ; processus d'Ornstein-Uhlenbeck, temps de premier passage et seuils de trading optimaux.

Partie II — Les méthodes de pairs trading (chapitres 6 à 11). Méthode des distances de Gatev, Goetzmann et Rouwenhorst ; sélection de paires par cointégration et contrôle des faux positifs ; ratio de couverture dynamique par filtre de Kalman ; copules ; arbitrage statistique multi-actifs par analyse en composantes principales (Avellaneda et Lee) ; apprentissage automatique et validation sans fuite d'information.

Partie III — Arbitrage inter-plateformes (chapitres 12 à 15). Microstructure et modèle de coûts ; arbitrage spatial et triangulaire et course à la latence ; arbitrage de base, *cash-and-carry* et *funding* des contrats perpétuels, avec l'étude du cas `atjte` ; exécution, risque de jambe, sélection adverse et architecture logicielle.

Partie IV — Validation, risque et mise en production (chapitres 16 à 18). *Backtest* sans biais, tests multiples, ratio de Sharpe déflaté et probabilité de surapprentissage ; dimensionnement, détection de rupture, limites de l'arbitrage ; passage du papier au code avec Claude Code, du cahier des charges au *paper trading*.

Chaque affirmation quantitative importante est vérifiée par un script Python du dépôt `arbitrage_hub`, sur données simulées (où la vérité est connue) ou sur des données réelles (GLD, GLDM, KO, PEP, 500 séances téléchargées via Interactive Brokers). Les résultats chiffrés reportés dans le texte sont ceux que produisent ces scripts. Le cours est honnête sur un point central : la littérature montre que les profits du *pairs trading* classique ont fortement diminué depuis les années 2000 et que l'arbitrage « pur » entre plateformes est une course de vitesse perdue d'avance pour un particulier. L'objectif est de construire un avantage réel, mesuré et robuste, pas de promettre un profit.

Mots-clés : arbitrage statistique, pairs trading, cointégration, Ornstein-Uhlenbeck, filtre de Kalman, copules, analyse en composantes principales, microstructure, arbitrage de base, *funding*, surapprentissage, ratio de Sharpe déflaté.

Table des matières

Résumé **i**

0 Cartographie de l'arbitrage, méthode et revue de littérature **1**

0.1 Introduction : pourquoi ajouter l'arbitrage à un portefeuille de stratégies 1
0.2 Méthode de travail 2
0.3 Cartographie : que veut dire « arbitrage » ? 3
0.4 Prérequis mathématiques et statistiques 3
0.5 Programme détaillé 3
0.6 Revue de littérature annotée 7
0.7 Dépôts logiciels étudiés 10
0.8 Faisabilité pour un trader particulier 11
0.9 Architecture du dépôt `arbitrage_hub` 11
0.10 Calendrier indicatif 12
0.11 Limites et avertissements 12

I Fondations statistiques **13**

1 Arbitrage, stationnarité et retour à la moyenne **14**

1.1 Objectifs et organisation du chapitre 14
1.2 Qu'est-ce que l'arbitrage ? 14
1.3 Rappels de probabilités orientés trading 15
1.4 Processus stochastiques et stationnarité 17
1.5 La marche aléatoire 17
1.6 Le processus autorégressif d'ordre un, AR(1) 19
1.7 De deux prix non stationnaires à un écart stationnaire 21
1.8 Du spread au signal : une première règle de trading 23
1.9 Ce que la théorie apporte, et ses limites 25
1.10 Fiche à recopier au tableau blanc 25
1.11 Exercices 25
1.12 Pour aller plus loin 26
1.13 Scripts du chapitre 26

2 Régression et estimation **28**

2.1 Objectifs et organisation du chapitre 28
2.2 Le modèle linéaire et les moindres carrés 28
2.3 Propriétés statistiques de l'estimateur 29

2.4 Quelle variable expliquer ? L'asymétrie de la régression 30
2.5 Le maximum de vraisemblance 31
2.6 Le biais de petit échantillon et sa correction 33
2.7 Ce que la théorie apporte, et ses limites 33
2.8 Fiche à recopier au tableau blanc 34
2.9 Exercices 34
2.10 Pour aller plus loin 34
2.11 Scripts du chapitre 34

3 Tester la stationnarité et le retour à la moyenne 35
3.1 Objectifs et organisation du chapitre 35
3.2 Le test de Dickey-Fuller 35
3.3 La puissance : combien de données faut-il ? 37
3.4 Le test KPSS : inverser l'hypothèse nulle 37
3.5 Le ratio de variance 38
3.6 L'exposant de Hurst 39
3.7 Études de cas réelles 39
3.8 Tests multiples : un avertissement 40
3.9 Ce que la théorie apporte, et ses limites 40
3.10 Fiche à recopier au tableau blanc 41
3.11 Exercices 41
3.12 Pour aller plus loin 41
3.13 Scripts du chapitre 41

4 Cointégration 42
4.1 Objectifs et organisation du chapitre 42
4.2 Ordre d'intégration et définition 42
4.3 La méthode d'Engle-Granger 42
4.4 Le modèle à correction d'erreur 43
4.5 Plusieurs actifs : la procédure de Johansen 44
4.6 La cointégration partielle 45
4.7 Études de cas réelles 45
4.8 Ce que la théorie apporte, et ses limites 46
4.9 Fiche à recopier au tableau blanc 46
4.10 Exercices 46
4.11 Pour aller plus loin 46
4.12 Scripts du chapitre 47

5 Le processus d'Ornstein-Uhlenbeck 48
5.1 Objectifs et organisation du chapitre 48

5.2 Mouvement brownien et équations différentielles stochastiques . . . 48
5.3 Le processus d'Ornstein-Uhlenbeck . . . 48
5.4 Combien de temps pour revenir ? Les temps de premier passage . . . 50
5.5 Seuils de trading optimaux . . . 51
5.6 Étude de cas : l'écart GLD/GLDM . . . 52
5.7 Ce que la théorie apporte, et ses limites . . . 52
5.8 Fiche à recopier au tableau blanc . . . 52
5.9 Exercices . . . 53
5.10 Pour aller plus loin . . . 53
5.11 Scripts du chapitre . . . 53

II Les méthodes de pairs trading 54

6 La méthode des distances 55
6.1 Objectifs et organisation du chapitre . . . 55
6.2 Le protocole de Gatev, Goetzmann et Rouwenhorst . . . 55
6.3 Ce que dit la littérature . . . 56
6.4 Réplication sur un univers simulé . . . 56
6.5 Pourquoi la SSD est un critère imparfait . . . 57
6.6 Études de cas réelles . . . 57
6.7 Ce que la théorie apporte, et ses limites . . . 57
6.8 Fiche à recopier au tableau blanc . . . 58
6.9 Exercices . . . 58
6.10 Pour aller plus loin . . . 58
6.11 Scripts du chapitre . . . 58

7 Cointégration appliquée : sélectionner les paires sans se mentir 59
7.1 Objectifs et organisation du chapitre . . . 59
7.2 Le problème des tests multiples . . . 59
7.3 Un pipeline de sélection . . . 60
7.4 Expérience : 4 950 paires, 10 vraies . . . 60
7.5 Ratio de couverture : statique ou glissant ? . . . 61
7.6 Dimensionner les positions . . . 61
7.7 Ce que la théorie apporte, et ses limites . . . 62
7.8 Fiche à recopier au tableau blanc . . . 62
7.9 Exercices . . . 62
7.10 Pour aller plus loin . . . 62
7.11 Scripts du chapitre . . . 62

8 Modèles espace-état et filtre de Kalman 63

8.1 Objectifs et organisation du chapitre . . . 63
8.2 Le modèle espace-état . . . 63
8.3 Les équations du filtre . . . 63
8.4 Ratio de couverture variable . . . 64
8.5 Estimer la cointégration partielle . . . 65
8.6 Études de cas réelles . . . 66
8.7 Ce que la théorie apporte, et ses limites . . . 66
8.8 Fiche à recopier au tableau blanc . . . 67
8.9 Exercices . . . 67
8.10 Pour aller plus loin . . . 67
8.11 Scripts du chapitre . . . 67

9 Copules **68**
9.1 Objectifs et organisation du chapitre . . . 68
9.2 Définition et théorème de Sklar . . . 68
9.3 Estimation et choix de la copule . . . 69
9.4 Signaux de trading fondés sur les copules . . . 70
9.5 Étude de cas réelle : KO et PEP . . . 70
9.6 Ce que la théorie apporte, et ses limites . . . 71
9.7 Fiche à recopier au tableau blanc . . . 71
9.8 Exercices . . . 71
9.9 Pour aller plus loin . . . 71
9.10 Scripts du chapitre . . . 71

10 Arbitrage statistique multi-actifs **72**
10.1 Objectifs et organisation du chapitre . . . 72
10.2 L'analyse en composantes principales . . . 72
10.3 Le modèle d'Avellaneda et Lee . . . 73
10.4 Expérience . . . 74
10.5 Portefeuilles de retour à la moyenne parcimonieux . . . 74
10.6 Ce que la théorie apporte, et ses limites . . . 75
10.7 Fiche à recopier au tableau blanc . . . 75
10.8 Exercices . . . 75
10.9 Pour aller plus loin . . . 75
10.10 Scripts du chapitre . . . 76

11 Apprentissage automatique **77**
11.1 Objectifs et organisation du chapitre . . . 77
11.2 Trois usages . . . 77
11.3 Variables, étiquettes et fuite d'information . . . 77

11.4 Complexe contre simple 78
11.5 Sélection de paires par *clustering* 78
11.6 Ce que la théorie apporte, et ses limites 79
11.7 Fiche à recopier au tableau blanc 79
11.8 Exercices 79
11.9 Pour aller plus loin 79
11.10 Scripts du chapitre 79

III Arbitrage inter-plateformes **80**

12 À rédiger **81**

13 À rédiger **82**

14 À rédiger **83**

15 À rédiger **84**

IV Validation, risque et mise en production **85**

16 À rédiger **86**

17 À rédiger **87**

18 À rédiger **88**

A Formulaire **89**

CHAPITRE 0

Cartographie de l'arbitrage, méthode et revue de littérature

0.1 Introduction : pourquoi ajouter l'arbitrage à un portefeuille de stratégies

Un portefeuille de stratégies comprenant déjà une stratégie macro/quantitative et des *Expert Advisors* (EA) déployés sur des comptes de *prop firms* est, par construction, exposé à la direction des marchés. Même un EA qui alterne achats et ventes gagne de l'argent parce qu'il anticipe correctement un mouvement de prix. L'arbitrage statistique repose sur une logique différente : on ne parie pas sur le niveau d'un prix, mais sur la *relation* entre plusieurs prix. On achète ce qui est relativement bon marché et on vend ce qui est relativement cher, de sorte que le mouvement général du marché s'annule en grande partie dans la position.

Image mentale

Imaginez deux bateaux amarrés côte à côte dans un port agité. Prédire la hauteur d'un bateau dans une heure est presque impossible : elle dépend de la marée et des vagues. En revanche, l'écart de hauteur entre les deux bateaux reste petit, car ils sont soulevés par la même eau. L'arbitrage statistique consiste à parier sur cet *écart*, pas sur la marée. Quand l'écart devient anormalement grand (une vague a frappé un bateau avant l'autre), on parie qu'il va se refermer.

Cette logique apporte une diversification réelle : un portefeuille « neutre au marché » a, en principe, une faible corrélation avec des stratégies directionnelles. Mais elle comporte des risques propres, très différents : la relation entre les prix peut se rompre définitivement, les coûts de transaction peuvent dévorer un avantage de quelques points de base, et l'exécution simultanée de deux ordres sur deux plateformes peut échouer à moitié. Ce cours étudie ces trois questions avec autant de soin que la théorie.

0.1.1 Objectifs d'apprentissage

À la fin du cours, vous devez être capable de :

O1. distinguer formellement arbitrage pur, quasi-arbitrage de convergence et arbitrage statistique, et dire pour chaque opportunité dans quelle catégorie elle tombe ;

O2. démontrer les propriétés des processus utilisés (marche aléatoire, AR(1), processus d'Ornstein-Uhlenbeck, systèmes cointégrés) et savoir les estimer sur données réelles ;

O3. appliquer et interpréter les tests statistiques (ADF, KPSS, Engle-Granger, Johansen, ratio de variance, exposant de Hurst) en connaissant leurs hypothèses et leurs faiblesses ;

O4. implémenter les cinq grandes familles de *pairs trading* (distance, cointégration, séries temporelles, copules, apprentissage automatique) ainsi que l'arbitrage multi-facteurs ;

O5. modéliser une opportunité inter-plateformes (arbitrage spatial, triangulaire, de base, de *funding*) en intégrant frais, latence, financement et risque de contrepartie ;

O6. valider une stratégie sans se mentir : séparation formation/test, coûts réalistes, tests multiples, ratio de Sharpe déflaté, probabilité de surapprentissage ;

O7. rédiger un cahier des charges que Claude Code peut transformer en code testé, puis déployer progressivement (papier, petite taille, taille cible).

0.1.2 Ce que ce cours ne promet pas

Le but final est de générer du profit, et c'est légitime. Mais la littérature impose trois constats que nous garderons en tête à chaque chapitre. Premièrement, la rentabilité du *pairs trading* simple sur actions américaines a nettement baissé au fil du temps [12, 13]. Deuxièmement, l'arbitrage pur entre plateformes est une course de vitesse que les acteurs institutionnels gagnent à la milliseconde [7]. Troisièmement, la plupart des stratégies qui semblent rentables en *backtest* le sont par hasard, parce qu'on a essayé beaucoup de variantes [3, 21]. Le cours est construit pour transformer ces trois obstacles en critères de sélection.

0.2 Méthode de travail

0.2.1 Un chapitre à la fois

Le cours est réuni dans ce seul document, mais il se travaille chapitre par chapitre : on ne passe au suivant que lorsque les exercices du précédent sont faits et que les scripts Python associés tournent sur votre machine. Chaque chapitre suit la même structure :

1. **Intuition** : une image mentale (encadré bleu) avant toute formule ;
2. **Formalisation** : définitions, propositions et démonstrations, chaque étape algébrique justifiée ;
3. **Vérification** : un script Python teste l'hypothèse au lieu de l'affirmer (encadré vert) ;
4. **Limites** : ce que la théorie ne dit pas, et comment cela peut coûter de l'argent (encadré rouge) ;
5. **Fiche tableau blanc** : les formules à recopier et annoter (encadré jaune) ;
6. **Quoi lire** : références précises (article, section ou chapitre) pour approfondir (encadré gris) ;
7. **Exercices**, dont au moins un à coder.

0.2.2 Le tableau blanc

Le tableau blanc sert à *reconstruire* les démonstrations, pas à les recopier. La méthode conseillée : (1) lire la section une fois sans écrire ; (2) fermer le PDF et réécrire au tableau la définition et l'énoncé ; (3) refaire la démonstration en ne rouvrant le PDF qu'en cas de blocage ; (4) photographier le tableau et déposer la photo dans `whiteboard/chXX/` du dépôt, pour garder une trace datée de votre progression.

0.2.3 Le cycle « hypothèse → script → conclusion »

Aucune affirmation importante du cours ne doit être crue sur parole. Chaque fois qu'une propriété est énoncée (par exemple « la variance d'une marche aléatoire croît linéairement avec le temps »), un script dans `code/chXX/` la vérifie par simulation ou sur données réelles, et le résultat chiffré figure dans le chapitre. Vous pouvez relancer chaque script et obtenir les mêmes nombres (graines aléatoires fixées).

0.2.4 Données réelles et données simulées

Deux sortes d'expériences coexistent dans le cours. Les **simulations** placent la stratégie dans un monde dont on connaît la vérité (le vrai β, la vraie demi-vie) : c'est le seul moyen de vérifier qu'une méthode retrouve ce qu'elle prétend mesurer. Les **études de cas réelles** utilisent les clôtures quotidiennes de quatre titres téléchargées via l'API d'Interactive Brokers le 20 octobre 2026 (500 séances, du 21 octobre 2024 au 19 octobre 2026) : deux ETF adossés à l'or physique, GLD et GLDM, qui forment un quasi-arbitrage, et deux actions du même secteur, Coca-Cola (KO) et PepsiCo (PEP), qui forment la paire statistique la plus

citée des manuels. Les fichiers sont dans `data/case_studies/`. Deux ans de données, c'est court : les études de cas illustrent les méthodes, elles ne prétendent pas établir la rentabilité d'une stratégie.

0.2.5 Comment lire les encadrés

- **Image mentale** (bleu) : l'intuition, à comprendre avant la formule.
- **Au tableau blanc** (jaune) : les formules à reconstruire et annoter.
- **Piège / limite** (rouge) : ce qui peut coûter de l'argent.
- **Vérification en Python** (vert) : une hypothèse testée, avec le script et les chiffres obtenus.
- **Pour aller plus loin** (gris) : quoi lire, avec la section ou le chapitre précis.

0.3 Cartographie : que veut dire « arbitrage » ?

Le mot « arbitrage » est utilisé de façon très lâche sur les réseaux sociaux. Nous distinguerons trois familles, définies formellement au chapitre 1.

Arbitrage pur. Une stratégie qui ne coûte rien aujourd'hui, ne peut jamais perdre, et gagne avec une probabilité strictement positive. Exemple : un même actif coté à deux prix différents au même instant, achetable et vendable simultanément. En pratique, l'arbitrage pur n'existe que pendant des fractions de seconde, ou en présence de frictions (frais, transferts, contrôles des capitaux) qui en font justement autre chose qu'un arbitrage pur.

Quasi-arbitrage de convergence. Deux instruments liés par une relation *contractuelle* ou *économique forte* (un contrat à terme et son sous-jacent, un jeton adossé à l'or et un CFD sur l'or, un ETF et son panier) dont l'écart doit converger à une date connue ou rester borné. Le risque existe (l'écart peut s'élargir avant de converger, le financement peut coûter cher), mais la relation a une *ancre* théorique.

Arbitrage statistique. Une relation purement *estimée* à partir de données historiques (deux actions du même secteur, un panier de devises) et supposée persister. Aucune loi n'oblige la relation à durer : c'est un pari à espérance positive, justifié par des tests statistiques, et c'est la famille la plus exposée au risque de rupture.

0.4 Prérequis mathématiques et statistiques

Le tableau 2 liste les notions nécessaires, l'endroit où elles servent et le chapitre où elles sont (re)vues. Celles marquées $\star$ sont indispensables dès le chapitre 1 ; les autres sont introduites au moment où elles servent.

0.5 Programme détaillé

La figure 1 donne l'ordre des dépendances. Les flèches indiquent « doit être compris avant ».

Pour chaque chapitre, nous indiquons les notions mathématiques, les lectures de référence et le code associé. Le code vit dans `code/chXX/` pendant l'apprentissage, puis les fonctions réutilisables migrent dans le paquet `src/arbhub/`.

Tableau 1: Taxonomie des stratégies étudiées dans le cours.

Stratégie	Famille	Source de l'écart et ancre	Chapitres
Arbitrage spatial (même actif, deux plateformes)	Pur / quasi	Fragmentation, frais, transferts lents [37]	12, 13
Arbitrage triangulaire (FX, crypto)	Pur	Incohérence de trois taux croisés	13
Base *cash-and-carry* (futures vs comptant)	Quasi	Coût de portage, convergence à l'échéance [25]	14
Funding des perpétuels	Quasi	Taux de financement périodique	14
Perpétuel/jeton vs CFD (cas `atjte`)	Quasi	Même sous-jacent, deux plateformes [1]	14, 15
Pairs trading par distance	Statistique	Co-mouvement historique [16]	6
Pairs trading par cointégration	Statistique	Équilibre de long terme [15]	4, 7
Modèles espace-état, Kalman	Statistique	Ratio de couverture variable [14]	8
Copules	Statistique	Dépendance non linéaire [34]	9
Multi-facteurs (ACP, résidus)	Statistique	Résidus d'un modèle de facteurs [2]	10
Apprentissage automatique	Statistique	Prévision des résidus [30]	11

0.5.1 Partie I — Fondations statistiques

Chapitre 1 — Arbitrage, stationnarité et retour à la moyenne. Définitions formelles de l'arbitrage pur et de l'arbitrage statistique [22] ; rappels de probabilités (espérance, variance, covariance, variance d'une combinaison linéaire) ; ratio de couverture à variance minimale ; processus stochastiques, bruit blanc, stationnarité ; marche aléatoire ; processus AR(1), moyenne et variance stationnaires, autocorrélation, demi-vie ; intuition de la cointégration [38] ; corrélation contre cointégration ; *z-score* et première règle de trading. **Code :** cinq scripts qui testent les propriétés énoncées. **Lire :** Hamilton [19] ch. 3 ; Chan [8] ch. 2.

Chapitre 2 — Régression et estimation. Moindres carrés ordinaires (dérivation matricielle), hypothèses de Gauss-Markov, propriétés des résidus ; régression fallacieuse [17] ; maximum de vraisemblance, application à l'AR(1) ; biais des petits échantillons sur le coefficient autorégressif ; régression orthogonale (moindres carrés totaux) et asymétrie du choix Y sur X contre X sur Y. **Code :** estimateurs écrits à la main, comparés à `statsmodels` [44].

Chapitre 3 — Tester la stationnarité et le retour à la moyenne. Test de Dickey-Fuller et version augmentée [11] : pourquoi la statistique ne suit pas une loi de Student ; test KPSS [31] et logique d'hypothèse nulle inversée ; ratio de variance [35] ; exposant de Hurst ; puissance des tests sur échantillons courts ; tests multiples sur un univers de paires. **Code :** simulation de la distribution de Dickey-Fuller ; courbe de puissance en fonction de la taille d'échantillon.

Chapitre 4 — Cointégration. Ordre d'intégration, définition de la cointégration ; méthode en deux étapes d'Engle-Granger et valeurs critiques spécifiques [15] ; modèle à correction d'erreur ; théorème de représentation de Granger ; VAR, VECM et procédure de Johansen (tests de la trace et de la valeur propre

Tableau 2: Prérequis et lieu d'utilisation.

Notion	À quoi elle sert dans le cours	Chapitre
⋆ Espérance, variance, covariance, corrélation	Variance d'un *spread*, ratio de couverture optimal	1
⋆ Loi normale, quantiles	Seuils d'entrée en *z-score*, intervalles de confiance	1
⋆ Suites géométriques, logarithmes	Fonction d'autocorrélation, demi-vie	1
Régression linéaire, moindres carrés	Ratio de couverture, test d'Engle-Granger	2
Maximum de vraisemblance	Estimation AR(1) et Ornstein-Uhlenbeck	2, 5
Tests d'hypothèse, *p*-valeur, puissance	ADF, KPSS, tests multiples	3, 16
Algèbre linéaire (matrices, valeurs propres)	Johansen, ACP, portefeuilles multi-actifs	4, 10
Calcul stochastique de base (mouvement brownien, lemme d'Itô)	Processus d'Ornstein-Uhlenbeck	5
Temps d'arrêt, temps de premier passage	Seuils optimaux [5, 32]	5
Modèles espace-état, filtrage bayésien	Filtre de Kalman	8
Copules, théorème de Sklar	Dépendance non gaussienne	9
Apprentissage supervisé, validation croisée purgée	Sélection de paires, prévision	11, 16
Microstructure (carnet d'ordres, *maker/taker*)	Coûts réels, exécution inter-plateformes	12, 15
Évaluation des futures (portage)	Arbitrage de base et de *funding*	14

maximale) [26] ; cointégration partielle [9]. **Code :** générateur de systèmes cointégrés ; implémentation pas à pas d'Engle-Granger ; comparaison avec Johansen.

Chapitre 5 — Le processus d'Ornstein-Uhlenbeck. Mouvement brownien, équation différentielle stochastique, lemme d'Itô ; solution explicite [47] ; lien exact avec l'AR(1) ; estimation par maximum de vraisemblance ; temps de premier passage ; seuils d'entrée et de sortie optimaux [5], avec coûts et stop-loss [32, 33]. **Code :** simulation exacte, estimation, optimisation numérique des seuils.

0.5.2 Partie II — Les méthodes de *pairs trading*

Cette partie suit la taxonomie de la revue de Krauss [29], qui classe la littérature en approches par distance, cointégration, séries temporelles, contrôle stochastique et « autres » (copules, apprentissage).

Chapitre 6 — La méthode des distances. Réplication de Gatev et al. [16] : normalisation des prix, somme des écarts quadratiques, période de formation de douze mois, période de trading de six mois, seuil de deux écarts-types ; calcul des rendements sur capital engagé ; résultats de Do and Faff [12, 13] sur la baisse de rentabilité et l'effet des coûts. **Code :** réplication sur un univers d'actions ou d'ETF accessible via Interactive Brokers.

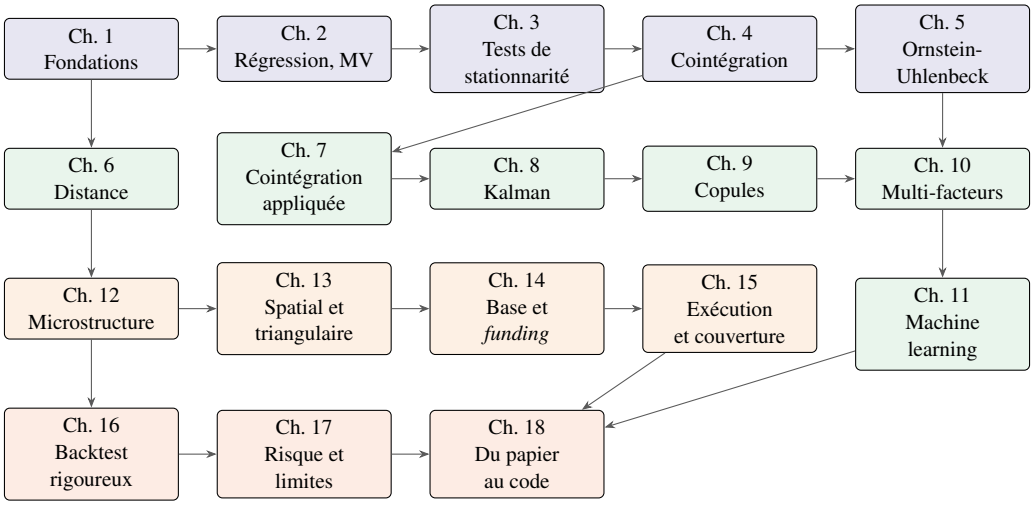


Figure 1: Carte du cours. Bleu : fondations ; vert : méthodes de *pairs trading* ; orange : arbitrage inter-plateformes ; rouge : validation, risque et mise en production.

Chapitre 7 — Cointégration appliquée. Sélection des paires (secteur, cointégration, demi-vie, nombre de croisements de la moyenne) [23, 48] ; ratio de couverture statique contre glissant ; comparaison distance/cointégration/copule [42] ; risque de rupture et suivi en ligne. **Code :** pipeline de sélection avec correction pour tests multiples.

Chapitre 8 — Modèles espace-état et filtre de Kalman. Le *spread* comme état caché observé avec bruit [14] ; dérivation du filtre de Kalman (prédiction, mise à jour, gain) ; ratio de couverture variable dans le temps ; réglage des variances de bruit. **Code :** filtre écrit à la main, comparé à une régression glissante.

Chapitre 9 — Copules. Théorème de Sklar, copules gaussienne, de Student, de Clayton, de Gumbel, de Frank ; dépendance de queue ; probabilités conditionnelles comme signal [34, 49]. **Code :** ajustement de copules et comparaison des signaux.

Chapitre 10 — Arbitrage statistique multi-actifs. Analyse en composantes principales des rendements ; résidus d'un modèle de facteurs (ACP ou ETF sectoriels) modélisés comme Ornstein-Uhlenbeck et *s-score* [2] ; portefeuilles de retour à la moyenne parcimonieux [6, 10]. **Code :** réplication simplifiée d'Avellaneda-Lee sur un univers liquide.

Chapitre 11 — Apprentissage automatique. Prévision des rendements relatifs par forêts aléatoires, *gradient boosting* et réseaux [30] ; extraction de signaux sur résidus par réseaux profonds [18] ; sélection de paires par réduction de dimension et *clustering* [43] ; étiquetage, validation croisée purgée [36]. **Code :** sélection de paires par *clustering*, puis comparaison avec la sélection par cointégration.

0.5.3 Partie III — Arbitrage inter-plateformes

Chapitre 12 — Microstructure et coûts. Carnet d'ordres, fourchette achat-vente, ordres *maker* et *taker*, remises, glissement, impact de marché, latence [20] ; modèle de coût complet par aller-retour ; pourquoi un avantage de 5 points de base disparaît avec deux fourchettes et deux commissions. **Code :** modèle de coûts paramétrable et réutilisable par toutes les stratégies.

Chapitre 13 — Arbitrage spatial et triangulaire. Loi du prix unique entre plateformes ; résultats empiriques sur les cryptomonnaies [37] : écarts importants et persistants entre pays, beaucoup plus faibles à l'intérieur d'un même pays ; contraintes de transfert, de capital et de risque de contrepartie ; arbitrage triangulaire et pourquoi il est quasi inaccessible sans colocalisation [7]. **Code :** détecteur d'écarts sur données publiques, avec calcul du profit net de frais.

Chapitre 14 — Arbitrage de base et de *funding*. Relation de portage $F = Se^{(r-q)T}$ [25] ; contrats à terme datés contre comptant ; contrats perpétuels et mécanisme de *funding* ; stratégie *cash-and-carry* ; cas d'étude `atjte` : *spread* entre un jeton ou perpétuel sur l'or et un CFD sur MetaTrader 5, bande de Bollinger sur le *spread*, base « juste » d'un futur daté [1]. **Code :** calculateur de base et de rendement annualisé net du financement.

Chapitre 15 — Exécution et couverture. Risque de jambe (*leg risk*) : une jambe exécutée, l'autre non ; stratégie *maker* d'un côté, couverture *taker* de l'autre ; réconciliation des positions ; coupe-circuit (*dead man's switch*) ; architecture par passerelles (*gateways*) qui isolent les clés. **Code :** simulateur d'exécution avec latence et rejets aléatoires.

0.5.4 Partie IV — Validation, risque et mise en production

Chapitre 16 — *Backtest* rigoureux. Biais d'anticipation, de survie, de sélection ; périodes formation/test, *walk-forward* ; coûts réalistes ; problème des tests multiples [21] ; ratio de Sharpe déflaté [3] ; probabilité de surapprentissage [4]. **Code :** moteur de *backtest* vectorisé avec tests unitaires anti-anticipation.

Chapitre 17 — Risque et limites de l'arbitrage. Dimensionnement (critère de Kelly fractionné, ciblage de volatilité), stop-loss sur *spread*, détection de rupture ; limites de l'arbitrage et rappels de marge [45] ; foule et liquidation forcée : la crise des *quants* d'août 2007 [28] ; risque de plateforme, de contrepartie et réglementaire ; règles des *prop firms*. **Code :** tableau de bord de risque.

Chapitre 18 — Du papier au code avec Claude Code. Rédiger un cahier des charges testable ; architecture du paquet `arbhub` ; tests unitaires, tests de propriétés, intégration continue ; *paper trading*, puis taille réduite, puis taille cible ; journal de trading et revue mensuelle. **Code :** première stratégie complète en *paper trading*.

0.6 Revue de littérature annotée

Cette section résume ce que chaque référence apporte et ce qu'il faut en retenir. Les références sont regroupées par question.

0.6.1 Le *pairs trading* fonctionne-t-il ? La base empirique

Gatev et al. [16] est l'article fondateur. Les auteurs apparient chaque action américaine à celle dont la trajectoire de prix normalisée est la plus proche sur douze mois, puis ouvrent une position quand l'écart dépasse deux écarts-types historiques et la ferment quand les prix se recroisent. Sur 1962–2002, les portefeuilles des meilleures paires produisent des rendements excédentaires annualisés de l'ordre de 11 % selon les auteurs, avec une faible exposition aux facteurs de risque usuels. **À retenir :** la règle est simple et non paramétrique ; elle sert de référence pour toute méthode plus sophistiquée.

Do and Faff [12] prolongent l'étude jusqu'en 2009 et montrent une baisse marquée de la rentabilité à partir des années 1990, avec une résistance relative pendant les périodes de turbulence. Do and Faff [13] ajoutent des coûts de transaction réalistes : une grande partie du profit disparaît, sauf pour des paires mieux sélectionnées. **À retenir :** sans modèle de coûts sérieux, un *backtest* de *pairs trading* n'a aucune valeur.

Krauss [29] propose la revue la plus complète, avec la taxonomie adoptée dans ce cours, et liste les questions ouvertes (sélection des paires, robustesse, coûts). Rad et al. [42] comparent sur longue période les méthodes par distance, cointégration et copules, toutes avec le même protocole : selon les auteurs, les trois approches produisent des rendements positifs dont l'ampleur décroît dans le temps, et leurs profils de risque diffèrent. **À retenir :** aucune méthode n'est dominante en toute circonstance ; le protocole de test compte autant que la méthode.

0.6.2 Cointégration : la théorie de l'équilibre de long terme

Engle and Granger [15] définissent la cointégration et proposent le test en deux étapes ; Johansen [26] généralise à plusieurs actifs par maximum de vraisemblance. Murray [38] donne l'image pédagogique d'une promeneuse ivre et de son chien, reprise au chapitre 1. Vidyamurthy [48] est le premier livre de praticien entièrement consacré au *pairs trading* par cointégration. Clegg and Krauss [9] introduisent la cointégration partielle : le *spread* y est la somme d'une composante qui revient à la moyenne et d'une composante de marche aléatoire, ce qui décrit mieux les paires réelles dont la relation dérive lentement.

0.6.3 Modéliser le *spread* : Ornstein-Uhlenbeck et seuils optimaux

Bertram [5] obtient des expressions analytiques des seuils d'entrée et de sortie qui maximisent le rendement espéré par unité de temps (ou le ratio de Sharpe) quand le *spread* suit un processus d'Ornstein-Uhlenbeck, en tenant compte des coûts. Leung and Li [32] formulent le problème comme un double arrêt optimal avec coûts de transaction et stop-loss. **À retenir :** le seuil « deux écarts-types » n'a rien d'optimal ; les seuils dépendent de la vitesse de retour, de la volatilité et des coûts.

0.6.4 Ratio de couverture variable : modèles espace-état

Elliott et al. [14] modélisent le *spread* comme un processus de retour à la moyenne observé avec du bruit, estimé par filtre de Kalman. Ce cadre permet de suivre un ratio de couverture qui évolue, au lieu de le figer sur une période de formation.

0.6.5 Au-delà de la corrélation linéaire : copules

Liew and Wu [34] et Xie et al. [49] utilisent les copules pour mesurer la probabilité conditionnelle qu'une action soit « trop chère » sachant le prix de l'autre. Les copules captent la dépendance de queue, qui compte justement lors des grands écarts.

0.6.6 Arbitrage statistique multi-actifs

Avellaneda and Lee [2] décomposent les rendements d'un large univers d'actions en facteurs (ACP ou ETF sectoriels) et en résidus, modélisent les résidus cumulés comme des processus d'Ornstein-Uhlenbeck et tradent leur *s-score*. Selon le résumé des auteurs, la version ACP affiche un ratio de Sharpe annuel moyen de 1,44 sur 1997–2007, avec une performance plus forte avant 2003. d'Aspremont [10] cherche des portefeuilles parcimonieux qui reviennent fortement à la moyenne, dans la lignée de l'analyse canonique de Box and Tiao [6].

0.6.7 Apprentissage automatique

Krauss et al. [30] entraînent des réseaux profonds, du *gradient boosting* et des forêts aléatoires à prédire quelles actions du S&P 500 surperformeront le lendemain ; l'ensemble des modèles produit, selon les auteurs, des rendements quotidiens d'environ 0,45 % avant coûts sur 1992–2015, en net déclin dans la période récente. Guijarro-Ordonez et al. [18] extraient les signaux de résidus de portefeuilles d'arbitrage par réseaux convolutifs et *transformers* et rapportent des ratios de Sharpe hors échantillon élevés. Sarmento and Horta [43] utilisent la réduction de dimension et le *clustering* pour proposer des paires candidates. **À retenir :** ces résultats sont obtenus sur des univers très liquides avec des hypothèses de coûts précises ; leur transposition à un compte particulier exige de refaire tout le calcul des coûts.

0.6.8 Les limites de l'arbitrage

Shleifer and Vishny [45] montrent que l'arbitrage est réalisé par un petit nombre d'acteurs spécialisés qui gèrent un capital emprunté ou délégué : quand l'écart s'élargit, ces acteurs subissent des pertes, des appels de marge ou des retraits de capital, et doivent liquider au pire moment. Pour un particulier, l'équivalent est l'appel de marge du courtier. Khandani and Lo [28] analysent la crise d'août 2007, où de nombreux fonds d'arbitrage statistique ont subi en quelques jours des pertes importantes parce qu'ils détenaient des positions semblables et ont dû les déboucler en même temps. **À retenir :** le risque d'une stratégie de retour à la moyenne se concentre dans les rares épisodes où l'écart s'élargit beaucoup plus que d'habitude.

0.6.9 Arbitrage entre plateformes et vitesse

Makarov and Schoar [37] documentent des écarts de prix du bitcoin importants et récurrents entre plateformes, surtout entre pays (avec des contrôles de capitaux), beaucoup plus faibles entre plateformes d'un même pays. Budish et al. [7] montrent que les opportunités d'arbitrage mécanique entre le future S&P 500 et l'ETF SPY persistent mais que leur durée est passée à quelques millisecondes : la compétition porte sur la vitesse. **À retenir :** un particulier ne doit pas chercher à battre les institutionnels sur la latence ; il doit chercher des écarts qui durent assez longtemps pour être exploités à son échelle de temps.

0.6.10 Validation et surapprentissage

Harvey et al. [21] montrent qu'après des centaines de « facteurs » testés, un seuil de t-statistique de 2 est beaucoup trop faible. Bailey and López de Prado [3] corrigent le ratio de Sharpe du nombre d'essais et de la non-normalité des rendements ; Bailey et al. [4] estiment la probabilité qu'une stratégie choisie en échantillon soit sous la médiane hors échantillon. López de Prado [36] détaille les méthodes de validation croisée adaptées aux séries financières.

0.6.11 Livres de référence

Hamilton [19] et Tsay [46] pour les séries temporelles ; Vidyamurthy [48], Pole [41] et Chan [8] pour la pratique de l'arbitrage statistique ; Leung and Li [33] pour le contrôle optimal ; Hull [25] pour les futures ; Harris [20] pour la microstructure.

0.7 Dépôts logiciels étudiés

0.7.1 `atjte` : un moteur d'arbitrage multi-plateformes en conditions réelles

Le dépôt `atj-khactu/atjte` [1] est la référence pratique de ce cours pour l'arbitrage inter-plateformes. Son principe, tel que décrit dans sa documentation et son code, est le suivant.

- **Deux jambes.** Une jambe de cotation sur une plateforme d'échange (Kraken, Kraken Futures, Coinbase, Binance, Hyperliquid, Lighter, ou des futures cotés chez Interactive Brokers) et une jambe de couverture sous forme de CFD sur MetaTrader 5.
- **Le *spread*.** Il est défini par $s_t = P_t^{\text{plateforme}} - k\,P_t^{\text{MT5}}$, où k (`HEDGE_RATIO`) convertit les unités (par exemple une part d'un ETF sur l'or contre une once de XAUUSD). Un module vérifie que k est cohérent avec le rapport des prix, pour éviter une erreur d'unité qui couvrirait dix fois trop ou trop peu.
- **L'exécution.** Les ordres sont des ordres limites *maker* (*post-only*) sur la plateforme d'échange, au prix $k \times \text{MT5}_{\text{bid}} + \text{niveau}$ à l'achat ; chaque exécution est immédiatement couverte par un ordre au marché opposé sur MT5. Au plus un ordre d'achat et un ordre de vente reposent à la fois.
- **Les stratégies fournies.** Niveaux fixes, grille, bandes de Bollinger sur le *spread* (moyenne glissante $\pm$ un multiple de l'écart-type), et une grille sur futures datés centrée sur une base « juste » égale au coût de portage multiplié par le nombre de jours jusqu'à l'échéance.
- **L'infrastructure.** Chaque plateforme est atteinte par une passerelle (*gateway*) qui détient seule les clés ; les robots ne voient jamais de clé. Le moteur réconcilie régulièrement la position réelle des deux côtés, s'arrête si les flux temps réel sont muets, et enregistre un historique du *spread* à la seconde.

Piège / limite

Ce que ce dépôt enseigne : (1) l'arbitrage « multi-plateformes » accessible à un particulier est en réalité un **quasi-arbitrage de convergence** sur un *spread* qui fluctue autour d'une valeur de référence, pas un gain sans risque ; (2) l'essentiel du code concerne l'exécution, la couverture et la réconciliation, pas le signal ; (3) le document du dépôt lui-même rappelle qu'une couverture peut échouer ou être exécutée en retard, qu'une plateforme peut tomber et que le *spread* peut évoluer défavorablement plus longtemps que la marge ne le permet. Enfin, les *prop firms* interdisent en règle générale l'arbitrage de latence et la couverture croisée entre comptes [40]. Ces stratégies doivent donc tourner sur du capital propre et chez des courtiers qui les acceptent explicitement, jamais sur vos comptes de *prop firms*.

0.7.2 ArbitrageLab (Hudson & Thames)

Bibliothèque Python [24], sous licence BSD-3, qui implémente une grande partie de la littérature (cointégration, Ornstein-Uhlenbeck, seuils de Bertram, copules, Kalman, approches par apprentissage) en suivant la taxonomie de Krauss [29]. Le dépôt n'est plus activement mis à jour (dernière modification en 2024 selon un agrégateur) : on l'utilisera comme **référence de lecture et de comparaison**, en réécrivant nous-mêmes les fonctions dont on dépend.

0.7.3 `statsmodels`

La bibliothèque économétrique standard en Python [44] : tests ADF, KPSS, Engle-Granger (`coint`), Johansen (`coint_johansen`), modèles ARIMA et espace-état. On l'utilisera pour vérifier nos propres implémentations.

0.7.4 Autres dépôts

Le thème GitHub `statistical-arbitrage` regroupe des projets d'étudiants et de praticiens (comparaison de méthodes, filtres de Kalman, copules). Leur qualité est très variable : aucun ne sera utilisé sans relecture et tests.

0.8 Faisabilité pour un trader particulier

Le tableau 3 croise chaque famille avec les contraintes d'un particulier. Les jugements sont qualitatifs et seront vérifiés chiffres à l'appui dans les chapitres concernés.

Tableau 3: Matrice de faisabilité indicative pour un particulier.

Stratégie	Infrastructure nécessaire	Risque principal	Faisabilité
Pairs trading actions/ETF (journalier)	Courtier avec vente à découvert (IBKR), données quotidiennes	Rupture de la relation, coûts d'emprunt	Élevée
Arbitrage statistique multi-facteurs	Univers large, données propres, calcul	Coûts, foule [28]	Moyenne
Cash-and-carry / *funding* crypto	Comptes sur plateformes, gestion de marge	Contrepartie, liquidation d'une jambe	Élevée
Perpétuel/jeton vs CFD (`atjte`)	Passerelles, VPS, deux comptes	Couverture ratée, courtier, *funding*	Moyenne
Futures calendaires (même sous-jacent)	Courtier futures	Écart de base, marge	Moyenne
Arbitrage spatial crypto	Fonds sur plusieurs plateformes	Transferts, frais, contrepartie	Faible à moyenne
Arbitrage triangulaire	Colocalisation, très faible latence	Course de vitesse [7]	Faible
Arbitrage de latence	Flux plus rapide que le courtier	Interdit par la plupart des *prop firms* et courtiers	À exclure

0.9 Architecture du dépôt `arbitrage_hub`

```
arbitrage_hub/
  README.md              présentation, mode d'emploi, avancement du cours
  CLAUDE.md              règles de travail pour Claude Code (tests, conventions)
  docs/
    cours/               CE COURS : arbitrage_hub_cours_complet.tex/.pdf,
                         chapitres/chXX.tex, figures/chXX/, references.bib
  code/
    common/style.py      style des figures, chargement des données réelles
    ch01/ ... ch18/      scripts pédagogiques : chaque chiffre du cours en sort
  src/arbhub/            paquet réutilisable (migré depuis code/ quand stable)
    data/                chargement, nettoyage, alignement des séries
    stats/               tests (ADF, KPSS, Hurst, Engle-Granger, Johansen)
    models/              AR(1), Ornstein-Uhlenbeck, Kalman, copules
    signals/             z-score, s-score, seuils optimaux
    backtest/            moteur vectorisé, modèle de coûts, métriques
    execution/           simulateur d'exécution, connecteurs (plus tard)
    risk/                dimensionnement, limites, détection de rupture
  tests/                 tests unitaires (pytest), dont tests anti-anticipation
  notebooks/             explorations jetables (jamais de logique critique)
  papers/                liste des articles + liens (PDF à ajouter par vous)
  whiteboard/chXX/       photos datées du tableau blanc
```

```
data/case_studies/   clôtures réelles GLD, GLDM, KO, PEP (IBKR, 2024-2026)
data/raw, data/processed   vos données (non versionnées)
```

Règles de travail avec Claude Code. Le fichier `CLAUDE.md` fixe les règles que l'assistant doit respecter : toute fonction de `src/arbhub` a un test ; aucune fonction de signal ne peut lire une donnée datée après l'instant de décision (un test l'impose) ; chaque *backtest* déclare son modèle de coûts ; chaque résultat publié précise le nombre de variantes essayées. Le cycle de travail recommandé est : (1) cahier des charges en Markdown dans `docs/specs/` ; (2) tests écrits d'abord ; (3) implémentation ; (4) *backtest* hors échantillon ; (5) *paper trading* ; (6) petite taille réelle ; (7) revue.

0.10 Calendrier indicatif

À raison de deux à trois séances par semaine, un rythme réaliste est d'environ un chapitre par semaine pour la partie I, et d'une à deux semaines par chapitre ensuite, soit quatre à cinq mois au total. La première stratégie en *paper trading* peut démarrer dès la fin du chapitre 7, en parallèle du reste du cours, ce qui permet d'accumuler des données d'exécution réelles pendant l'apprentissage.

0.11 Limites et avertissements

Ce cours est un support pédagogique, pas un conseil en investissement. Les performances rapportées par les articles sont des résultats historiques obtenus dans des conditions précises (univers, période, coûts) qui ne se reproduisent pas automatiquement. Certaines stratégies d'arbitrage inter-plateformes sont interdites par les conditions générales de courtiers ou de *prop firms* ; il vous revient de vérifier ces conditions avant tout déploiement. Les références ont été vérifiées au moment de la rédaction ; les informations sur les dépôts logiciels (licence, activité) peuvent évoluer.

PARTIE I

Fondations statistiques

CHAPITRE 1

Arbitrage, stationnarité et retour à la moyenne

1.1 Objectifs et organisation du chapitre

Objectifs du chapitre. À la fin de ce chapitre, vous saurez : (1) dire si une opportunité est un arbitrage pur, un quasi-arbitrage ou un arbitrage statistique ; (2) calculer la variance d'un écart entre deux actifs et le ratio de couverture qui la minimise ; (3) définir la stationnarité et expliquer pourquoi elle est la condition de tout trading de retour à la moyenne ; (4) démontrer les propriétés de la marche aléatoire et de l'AR(1) ; (5) calculer et interpréter une demi-vie ; (6) expliquer la différence entre corrélation et cointégration ; (7) construire un *z-score* sans utiliser d'information future.

Prérequis. Espérance et variance d'une variable aléatoire, loi normale, logarithmes, suites géométriques. Tout le reste est redémontré.

Fichiers associés. Les cinq scripts du dossier `code/ch01/` du dépôt. Chacun teste une hypothèse (notée H1 à H5) et écrit ses résultats dans `code/ch01/results/` et ses figures dans `docs/cours/figures/ch01/`. Les graines aléatoires sont fixées : en relançant un script, vous obtenez exactement les nombres de ce document.

1.2 Qu'est-ce que l'arbitrage ?

1.2.1 L'arbitrage pur

On considère un marché avec N actifs. Aujourd'hui (date 0) leurs prix forment un vecteur $p \in \mathbb{R}^N$. Demain (date 1) leurs valeurs sont aléatoires et forment un vecteur $V \in \mathbb{R}^N$. Un portefeuille est un vecteur $\theta \in \mathbb{R}^N$: $\theta_i > 0$ signifie qu'on détient θ_i unités de l'actif i, $\theta_i < 0$ qu'on en a vendu à découvert $|\theta_i|$ unités. Le coût du portefeuille aujourd'hui est $p^\top \theta = \sum_i p_i \theta_i$ et sa valeur demain est $V^\top \theta$.

Définition 1.1 (Arbitrage pur)**.** Un portefeuille θ est un *arbitrage* si

(i) il ne coûte rien ou rapporte de l'argent aujourd'hui : $p^\top \theta \leq 0$;

(ii) il ne peut jamais perdre demain : $\mathbb{P}(V^\top \theta \geq 0) = 1$;

(iii) il gagne strictement dans au moins un scénario : $\mathbb{P}(V^\top \theta > 0) > 0$ ou $p^\top \theta < 0$.

Image mentale

Un arbitrage, c'est un billet de banque posé par terre que personne d'autre n'a encore ramassé : on se baisse (coût nul), on ne peut rien perdre, et on gagne quelque chose. La théorie financière part du principe qu'un tel billet ne reste pas longtemps par terre.

Loi du prix unique. Conséquence directe : deux actifs qui ont exactement la même valeur demain dans tous les scénarios doivent avoir le même prix aujourd'hui. Sinon, on achète le moins cher, on vend le plus cher, et le portefeuille vérifie la définition 1.1 : il rapporte la différence de prix aujourd'hui ($p^\top \theta < 0$) et vaut exactement zéro demain.

Exemple 1.1 (Le même actif sur deux plateformes)**.** Un actif est proposé à l'achat (*ask*) à 100,00 sur la plateforme A et repris à la vente (*bid*) à 100,08 sur la plateforme B. Les frais sont de 0,05 % du montant échangé sur chaque plateforme. On achète une unité sur A et on la vend sur B :

$$\begin{aligned} \text{gain brut} &= 100{,}08 - 100{,}00 = 0{,}08, \\ \text{frais} &= 0{,}0005 \times 100{,}00 + 0{,}0005 \times 100{,}08 = 0{,}05 + 0{,}05004 = 0{,}10004, \\ \text{gain net} &= 0{,}08 - 0{,}10004 = -0{,}02004. \end{aligned}$$

L'écart affiché de 8 centimes n'est pas un arbitrage : il est inférieur aux frais. Pour qu'il le devienne, il faudrait un écart supérieur à environ 0,10, soit 10 points de base. Et même dans ce cas, il faut que les deux ordres soient exécutés *au même instant*, sans quoi le prix peut bouger entre les deux (risque de jambe, chapitre 15).

Remarque 1.1. Les frais se mesurent souvent en *points de base* (pb, ou *bps*) : 1 pb $= 0{,}01\,\% = 10^{-4}$. Dans l'exemple, $0{,}05\,\% = 5$ pb par jambe, donc 10 pb pour l'aller simple sur deux plateformes.

1.2.2 Le quasi-arbitrage de convergence

Considérons un contrat à terme sur l'or qui expire dans trois mois et l'or au comptant. À l'échéance, le contrat est livré contre de l'or : les deux prix sont *forcés* de coïncider. Avant l'échéance, l'écart (la « base ») reflète le coût de portage (intérêts, stockage) et fluctue autour de lui. Si la base est anormalement élevée, on vend le contrat, on achète l'or, et on attend la convergence. Le gain final est connu à l'avance, mais la position peut subir des pertes latentes avant l'échéance, exiger de la marge, et coûter en financement. C'est un *quasi-arbitrage* : il existe une ancre contractuelle, mais pas d'absence totale de risque. Le moteur `atjte` étudié au chapitre 0 exploite une variante de cette idée entre un instrument cotant l'or sur une plateforme crypto et un CFD sur l'or chez un courtier MetaTrader 5 [1].

1.2.3 L'arbitrage statistique

L'arbitrage statistique renonce à la condition (ii) de la définition 1.1 : on accepte de pouvoir perdre à court terme, pourvu que la stratégie gagne *en moyenne* et que le risque de perte disparaisse *à long terme*. Hogan et al. [22] en donnent une définition précise. Soit une stratégie autofinancée (on ne rajoute ni ne retire d'argent) de coût initial nul, et $v(t)$ sa valeur cumulée actualisée à la date t.

Définition 1.2 (Arbitrage statistique, d'après Hogan et al. [22])**.** La stratégie est un *arbitrage statistique* si

(i) $v(0) = 0$: elle ne coûte rien au départ ;

(ii) $\lim_{t\to\infty} \mathbb{E}[v(t)] > 0$: son gain espéré à long terme est positif ;

(iii) $\lim_{t\to\infty} \mathbb{P}(v(t) < 0) = 0$: la probabilité d'être en perte tend vers zéro ;

(iv) si $\mathbb{P}(v(t) < 0) > 0$ pour tout t, alors $\lim_{t\to\infty} \mathrm{Var}(v(t))/t = 0$: la variance du gain croît moins vite que le temps.

Image mentale

Pensez au casino face à ses clients à la roulette. Sur un tour, le casino peut perdre. Sur une soirée, il peut perdre. Mais il a un petit avantage à chaque tour (condition ii), et sur des millions de tours la probabilité qu'il soit globalement en perte devient minuscule (condition iii). La condition (iv) exclut une stratégie qui gagnerait en moyenne mais dont le risque exploserait avec le temps. L'arbitragiste statistique veut être le casino. Le danger, que l'on verra en fin de chapitre, est que la roulette change de règles sans prévenir.

Piège / limite

La définition 1.2 parle de limites quand $t \to \infty$. Un trader n'a jamais un temps infini : il a un capital fini, des appels de marge et une tolérance limitée aux pertes. Une stratégie peut satisfaire la définition et ruiner son utilisateur avant que la « loi des grands nombres » ne joue. C'est le cœur des « limites de l'arbitrage » de Shleifer and Vishny [45], étudiées au chapitre 17.

1.3 Rappels de probabilités orientés trading

1.3.1 Espérance, variance, covariance

Pour deux variables aléatoires X et Y et deux constantes a, b :

$$\mathbb{E}[aX + bY] = a\,\mathbb{E}[X] + b\,\mathbb{E}[Y] \qquad \text{(linéarité)} \tag{1.1}$$

$$\mathrm{Var}(X) = \mathbb{E}\big[(X - \mathbb{E}X)^2\big] = \mathbb{E}[X^2] - (\mathbb{E}X)^2 \tag{1.2}$$

$$\mathrm{Cov}(X,Y) = \mathbb{E}\big[(X - \mathbb{E}X)(Y - \mathbb{E}Y)\big] \tag{1.3}$$

$$\mathrm{Corr}(X,Y) = \rho_{XY} = \frac{\mathrm{Cov}(X,Y)}{\sigma_X\,\sigma_Y} \in [-1,1], \qquad \sigma_X = \sqrt{\mathrm{Var}\,X}. \tag{1.4}$$

Si X et Y sont indépendantes, $\mathrm{Cov}(X,Y) = 0$ (la réciproque est fausse en général).

1.3.2 Variance d'un écart entre deux actifs

C'est le calcul le plus important du chapitre. On construit un écart (*spread*) $S = Y - \beta X$: on détient une unité de Y et on est vendeur de β unités de X.

Proposition 1.1. $\operatorname{Var}(Y - \beta X) = \sigma_Y^2 + \beta^2 \sigma_X^2 - 2\beta \operatorname{Cov}(X,Y)$.

Démonstration. Notons $\mu_X = \mathbb{E}X$, $\mu_Y = \mathbb{E}Y$. Par linéarité (1.1), $\mathbb{E}[Y - \beta X] = \mu_Y - \beta\mu_X$. Donc

$$\begin{aligned}
\operatorname{Var}(Y - \beta X) &= \mathbb{E}\Big[\big((Y - \beta X) - (\mu_Y - \beta\mu_X)\big)^2\Big] && \text{définition (1.2)} \\
&= \mathbb{E}\Big[\big((Y - \mu_Y) - \beta(X - \mu_X)\big)^2\Big] && \text{on regroupe les termes} \\
&= \mathbb{E}\big[(Y - \mu_Y)^2\big] - 2\beta\,\mathbb{E}\big[(Y - \mu_Y)(X - \mu_X)\big] + \beta^2\,\mathbb{E}\big[(X - \mu_X)^2\big] && (a-b)^2 = a^2 - 2ab + b^2 \\
&= \sigma_Y^2 - 2\beta \operatorname{Cov}(X,Y) + \beta^2 \sigma_X^2. && \text{définitions (1.2), (1.3)}
\end{aligned}$$

□

1.3.3 Le ratio de couverture à variance minimale

Quel β rend l'écart le moins volatil possible ? La proposition 1.1 donne une fonction de β :

$$f(\beta) = \sigma_Y^2 + \beta^2 \sigma_X^2 - 2\beta \operatorname{Cov}(X,Y).$$

C'est un polynôme du second degré en β, de coefficient dominant $\sigma_X^2 > 0$: une parabole tournée vers le haut, qui a donc un unique minimum.

Proposition 1.2 (Ratio de couverture optimal)**.** *La variance de $Y - \beta X$ est minimale pour*

$$\beta^\star = \frac{\operatorname{Cov}(X,Y)}{\sigma_X^2} = \rho_{XY}\,\frac{\sigma_Y}{\sigma_X}, \qquad \textit{et alors} \qquad \operatorname{Var}(Y - \beta^\star X) = \sigma_Y^2\,(1 - \rho_{XY}^2).$$

Démonstration. On dérive f par rapport à β : $f'(\beta) = 2\beta\sigma_X^2 - 2\operatorname{Cov}(X,Y)$. Le minimum annule la dérivée : $2\beta^\star\sigma_X^2 = 2\operatorname{Cov}(X,Y)$, d'où $\beta^\star = \operatorname{Cov}(X,Y)/\sigma_X^2$. La dérivée seconde $f''(\beta) = 2\sigma_X^2 > 0$ confirme qu'il s'agit d'un minimum. La seconde écriture vient de (1.4) : $\operatorname{Cov}(X,Y) = \rho_{XY}\sigma_X\sigma_Y$, donc $\beta^\star = \rho_{XY}\sigma_X\sigma_Y/\sigma_X^2 = \rho_{XY}\sigma_Y/\sigma_X$.

Pour la variance minimale, on remplace β par $\beta^\star$ dans f :

$$\begin{aligned}
f(\beta^\star) &= \sigma_Y^2 + \frac{\operatorname{Cov}(X,Y)^2}{\sigma_X^4}\sigma_X^2 - 2\frac{\operatorname{Cov}(X,Y)}{\sigma_X^2}\operatorname{Cov}(X,Y) = \sigma_Y^2 + \frac{\operatorname{Cov}(X,Y)^2}{\sigma_X^2} - 2\frac{\operatorname{Cov}(X,Y)^2}{\sigma_X^2} \\
&= \sigma_Y^2 - \frac{\operatorname{Cov}(X,Y)^2}{\sigma_X^2} = \sigma_Y^2 - \frac{\rho_{XY}^2\sigma_X^2\sigma_Y^2}{\sigma_X^2} = \sigma_Y^2(1 - \rho_{XY}^2).
\end{aligned}$$

□

Remarque 1.2 (Lien avec la régression). La formule $\beta^\star = \operatorname{Cov}(X,Y)/\operatorname{Var}(X)$ est exactement celle de la pente de la régression linéaire de Y sur X par moindres carrés (chapitre 2). C'est pourquoi, en *pairs trading*, on estime presque toujours le ratio de couverture par une régression : on cherche l'écart le moins bruité.

Image mentale

Couvrir, c'est retirer de Y la partie qui « ressemble » à X. Ce qui reste, l'écart, a un écart-type $\sigma_Y\sqrt{1-\rho^2}$. Même avec une corrélation de 0,9, il reste $\sqrt{1-0{,}81} = \sqrt{0{,}19} \approx 0{,}436$, soit 44 % de la volatilité de Y. Avec $\rho = 0{,}99$, il en reste encore 14 %. Une corrélation « élevée » ne suffit pas à rendre un écart calme.

Piège / limite

Ce calcul porte sur des variables aléatoires « figées ». Appliqué à des *prix* qui évoluent dans le temps, il peut donner un résultat absurde : la section 1.7.3 montre que la régression d'un prix sur un autre prix peut afficher une relation forte entre deux actifs totalement indépendants. Appliqué à des *rendements*, il donne un ratio de couverture de court terme, qui ne garantit pas que l'écart des prix reste borné. Distinguer ces deux situations est l'objet de la section 1.7.

1.3.4 Loi normale et *z-score*

Si $Z \sim \mathcal{N}(0,1)$, alors $\mathbb{P}(|Z|>1) \approx 31{,}7\,\%$, $\mathbb{P}(|Z|>2) \approx 4{,}55\,\%$ et $\mathbb{P}(|Z|>3) \approx 0{,}27\,\%$. Le *z-score* d'une observation s par rapport à une moyenne m et un écart-type d est $z = (s-m)/d$: il mesure l'écart « en nombre d'écarts-types ». Une règle « entrer quand $|z|>2$ » s'appuie implicitement sur l'idée que de tels écarts sont rares *et temporaires*. Le mot important est « temporaires » : c'est ce que la stationnarité va garantir, ou non.

1.4 Processus stochastiques et stationnarité

1.4.1 Définitions

Définition 1.3. Un *processus stochastique* en temps discret est une suite de variables aléatoires $(X_t)_{t\in\mathbb{Z}}$ ou $(X_t)_{t\geq 0}$. Une *trajectoire* est une réalisation particulière $(x_0, x_1, x_2, \dots)$.

Image mentale

Le processus est l'ensemble de tous les films possibles ; la série de prix que vous voyez sur votre écran est *un seul* de ces films. Toute la difficulté statistique vient de là : on veut apprendre les règles qui produisent les films en n'en regardant qu'un.

Définition 1.4 (Bruit blanc)**.** (ε_t) est un *bruit blanc* de variance σ^2 si $\mathbb{E}[\varepsilon_t]=0$, $\mathrm{Var}(\varepsilon_t)=\sigma^2$ et $\mathrm{Cov}(\varepsilon_t,\varepsilon_s)=0$ pour $t\neq s$. On écrira souvent $\varepsilon_t \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,\sigma^2)$ (indépendantes et de même loi normale), ce qui est un cas particulier plus fort.

Définition 1.5 (Stationnarité)**.** Le processus (X_t) est *stationnaire au sens faible* (ou « du second ordre ») si

(i) $\mathbb{E}[X_t]=\mu$ ne dépend pas de t ;

(ii) $\mathrm{Var}(X_t)=\gamma(0)<\infty$ ne dépend pas de t ;

(iii) $\mathrm{Cov}(X_t, X_{t-h})=\gamma(h)$ ne dépend que de l'écart h, pas de t.

La fonction $\gamma(h)$ est l'*autocovariance* et $\rho(h)=\gamma(h)/\gamma(0)$ l'*autocorrélation* (ACF). Le processus est *strictement stationnaire* si la loi jointe de $(X_{t_1},\dots,X_{t_k})$ est la même que celle de $(X_{t_1+h},\dots,X_{t_k+h})$ pour tous $t_1,\dots,t_k,h$.

Image mentale

Un processus stationnaire est un paysage dont le relief ne change pas quand on se déplace : la hauteur moyenne, l'amplitude des collines et la longueur typique d'une pente sont les mêmes partout. Si vous mesurez la moyenne et l'écart-type sur une partie du paysage, la mesure vaut pour le reste. C'est exactement ce que fait un trader qui calcule un *z-score* à partir de l'historique : il suppose que la moyenne et l'écart-type passés valent pour l'avenir.

1.4.2 Pourquoi la stationnarité est la condition du retour à la moyenne

Une stratégie de retour à la moyenne vend quand X_t est « au-dessus de sa moyenne » et achète quand il est en dessous. Cela n'a de sens que si cette moyenne existe et reste fixe (condition i), et si les écarts ont une taille typique stable (condition ii). La condition (iii) dit en plus que la façon dont le passé influence le présent ne change pas : la « vitesse » du retour, que l'on mesurera par la demi-vie, est stable. Nous allons voir que les prix ne vérifient pas ces conditions, mais que certaines combinaisons de prix peuvent les vérifier.

1.5 La marche aléatoire

1.5.1 Définition et propriétés

Définition 1.6. $(P_t)_{t\geq 0}$ est une *marche aléatoire* si $P_t = P_{t-1}+\varepsilon_t$ pour $t\geq 1$, avec P_0 fixé et (ε_t) un bruit blanc i.i.d. de variance σ^2. En remplaçant de proche en proche :

$$P_t = P_{t-1}+\varepsilon_t = P_{t-2}+\varepsilon_{t-1}+\varepsilon_t = \cdots = P_0 + \sum_{i=1}^{t}\varepsilon_i.$$

Proposition 1.3. *Pour une marche aléatoire :* $\mathbb{E}[P_t]=P_0$, $\mathrm{Var}(P_t)=t\sigma^2$ *et* $\mathrm{Cov}(P_t,P_s)=\sigma^2\min(t,s)$.

Démonstration. *Espérance.* Par linéarité, $\mathbb{E}[P_t] = P_0 + \sum_{i=1}^{t} \mathbb{E}[\varepsilon_i] = P_0 + 0 = P_0$.

Variance. P_0 est une constante, donc $\mathrm{Var}(P_t) = \mathrm{Var}\left(\sum_{i=1}^{t} \varepsilon_i\right)$. La variance d'une somme est la somme des variances plus deux fois la somme des covariances entre termes distincts :

$$\mathrm{Var}\left(\sum_{i=1}^{t} \varepsilon_i\right) = \sum_{i=1}^{t} \mathrm{Var}(\varepsilon_i) + 2\sum_{i<j} \mathrm{Cov}(\varepsilon_i, \varepsilon_j) = t\sigma^2 + 0,$$

car les chocs sont non corrélés.

Covariance. Supposons $s \le t$. On écrit $P_t = P_s + \sum_{i=s+1}^{t} \varepsilon_i$. Les chocs après s sont non corrélés avec P_s, qui ne dépend que des chocs jusqu'à s. Donc $\mathrm{Cov}(P_t, P_s) = \mathrm{Var}(P_s) + 0 = s\sigma^2 = \sigma^2 \min(t, s)$. □

Image mentale

Un promeneur ivre fait un pas aléatoire à chaque seconde. En moyenne il reste au point de départ (l'espérance ne bouge pas), mais il s'en éloigne de plus en plus : après t pas, sa distance typique au départ est $\sigma\sqrt{t}$. Rien ne le rappelle vers son point de départ. Il n'y a aucune « moyenne » vers laquelle revenir.

Conséquence : une marche aléatoire n'est pas stationnaire. Sa variance $t\sigma^2$ dépend de t (condition ii violée). Pire, l'autocorrélation entre P_t et P_{t+h} vaut

$$\mathrm{Corr}(P_t, P_{t+h}) = \frac{\sigma^2 t}{\sqrt{\sigma^2 t}\sqrt{\sigma^2 (t+h)}} = \sqrt{\frac{t}{t+h}},$$

qui dépend de t et tend vers 1 quand t est grand : la série est extrêmement « persistante », chaque valeur ressemble à la précédente, sans jamais être rappelée vers un niveau fixe.

1.5.2 Vérification (H1)

Vérification en Python — script `h1_random_walk_variance.py`

Hypothèse : $\mathrm{Var}(P_t) = t\sigma^2$. **Protocole :** 20 000 trajectoires de 1 000 pas avec $\sigma = 1$; variance mesurée entre trajectoires à chaque date ; régression de $\log \mathrm{Var}(P_t)$ sur $\log t$ (pente attendue 1, ordonnée attendue $\log \sigma^2 = 0$). **Résultats :** variances empiriques de 10,09 ; 99,10 ; 493,09 ; 1016,89 pour $t = 10, 100, 500, 1000$ (écarts relatifs à la théorie inférieurs à 1,7 %) ; pente log-log 1,0045, ordonnée $-0{,}028$. **Conclusion :** la croissance linéaire de la variance est confirmée.

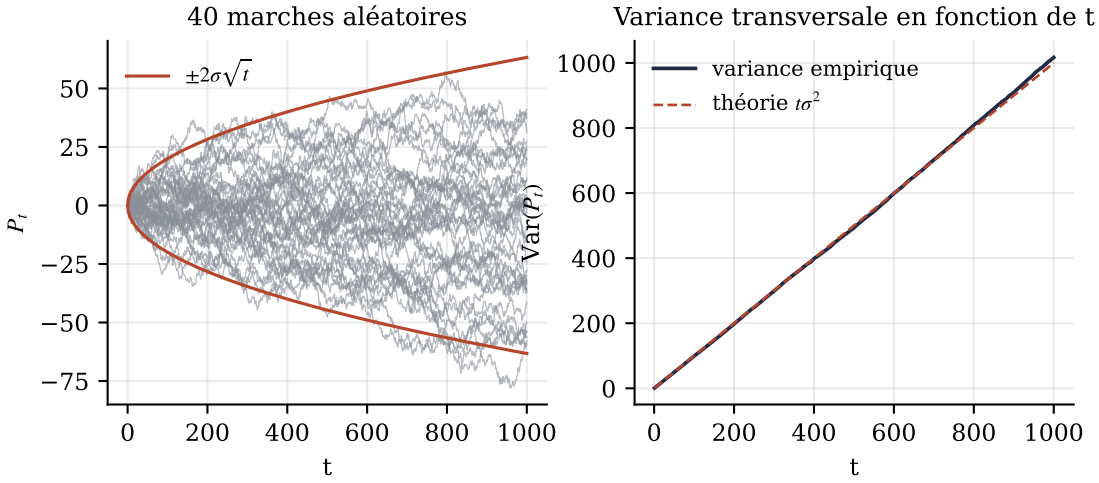


Figure 1.1: À gauche, 40 marches aléatoires et l'enveloppe $\pm 2\sigma\sqrt{t}$. À droite, la variance transversale mesurée sur 20 000 trajectoires suit la droite théorique $t\sigma^2$.

1.5.3 Prix, log-prix et rendements

En pratique on modélise plutôt le *logarithme* du prix comme une marche aléatoire (éventuellement avec une dérive c) : $\log P_t = c + \log P_{t-1} + \varepsilon_t$. Le rendement logarithmique $r_t = \log P_t - \log P_{t-1} = c + \varepsilon_t$ est alors un bruit blanc décalé, donc stationnaire. C'est pourquoi les économètres disent qu'un prix est « intégré d'ordre 1 », noté $I(1)$: il faut le différencier une fois pour obtenir une série stationnaire, notée $I(0)$. Cette notation sera formalisée au chapitre 4.

1.6 Le processus autorégressif d'ordre un, AR(1)

1.6.1 Définition et résolution

Définition 1.7. (X_t) suit un AR(1) si $X_t = c + \varphi X_{t-1} + \varepsilon_t$, avec (ε_t) bruit blanc de variance σ^2 et c, φ deux constantes.

On cherche d'abord le niveau μ autour duquel le processus pourrait se stabiliser. Si la série était constante égale à μ en l'absence de choc, on aurait $\mu = c + \varphi\mu$, donc, pour $\varphi \neq 1$,

$$\mu = \frac{c}{1-\varphi}.$$

En remplaçant $c = \mu(1-\varphi)$ dans la définition, on obtient la forme « centrée », beaucoup plus parlante :

$$X_t - \mu = \varphi\,(X_{t-1} - \mu) + \varepsilon_t. \tag{1.5}$$

Notons $Y_t = X_t - \mu$ l'écart à la moyenne. Alors $Y_t = \varphi Y_{t-1} + \varepsilon_t$, et en remplaçant de proche en proche :

$$\begin{aligned} Y_t &= \varphi Y_{t-1} + \varepsilon_t = \varphi(\varphi Y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \varphi^2 Y_{t-2} + \varphi\varepsilon_{t-1} + \varepsilon_t \\ &= \cdots = \varphi^t Y_0 + \sum_{j=0}^{t-1} \varphi^j\, \varepsilon_{t-j}. \end{aligned} \tag{$*$}$$

La formule $(*)$ dit tout : l'écart d'aujourd'hui est l'écart initial multiplié par φ^t, plus une somme de chocs passés dont l'influence décroît géométriquement avec leur ancienneté (le choc d'il y a j périodes pèse φ^j).

1.6.2 Condition de stationnarité et moments

Proposition 1.4. *Si $|\varphi| < 1$, l'AR(1) admet une solution stationnaire de moyenne $\mu = c/(1-\varphi)$, de variance et d'autocorrélation*

$$\gamma(0) = \frac{\sigma^2}{1-\varphi^2}, \qquad \rho(h) = \varphi^h \quad (h \geq 0).$$

Si $\varphi = 1$, le processus est une marche aléatoire (avec dérive c) et n'est pas stationnaire.

Démonstration. Moyenne. Si X est stationnaire, $\mathbb{E}X_t = \mathbb{E}X_{t-1} = m$. En prenant l'espérance dans la définition : $m = c + \varphi m$, donc $m = c/(1-\varphi) = \mu$.

Variance. Dans (1.5), ε_t est non corrélé avec X_{t-1} (qui ne dépend que des chocs passés). Par la proposition 1.1 appliquée avec une covariance nulle : $\operatorname{Var}(X_t) = \varphi^2 \operatorname{Var}(X_{t-1}) + \sigma^2$. Si la variance est constante, égale à v, alors $v = \varphi^2 v + \sigma^2$, soit $v(1-\varphi^2) = \sigma^2$ et $v = \sigma^2/(1-\varphi^2)$. Cette quantité n'est positive et finie que si $\varphi^2 < 1$, c'est-à-dire $|\varphi| < 1$.

Autocovariance. Avec $Y_t = X_t - \mu$, on itère $(*)$ sur h pas à partir de $t-h$: $Y_t = \varphi^h Y_{t-h} + \sum_{j=0}^{h-1} \varphi^j \varepsilon_{t-j}$. Les chocs $\varepsilon_{t-h+1}, \ldots, \varepsilon_t$ sont non corrélés avec Y_{t-h}, donc

$$\gamma(h) = \operatorname{Cov}(Y_t, Y_{t-h}) = \varphi^h \operatorname{Var}(Y_{t-h}) = \varphi^h \gamma(0), \qquad \rho(h) = \frac{\gamma(h)}{\gamma(0)} = \varphi^h.$$

Cas $\varphi = 1$. La définition devient $X_t = c + X_{t-1} + \varepsilon_t$: c'est une marche aléatoire avec dérive, de variance croissante (proposition 1.3). □

1.6.3 L'écriture « retour à la moyenne »

On soustrait $X_{t-1} - \mu$ des deux côtés de (1.5) :

$$\underbrace{X_t - X_{t-1}}_{\Delta X_t} = -\underbrace{(1-\varphi)}_{\kappa}\,(X_{t-1} - \mu) + \varepsilon_t. \tag{1.6}$$

Avec $0 < \varphi < 1$, le coefficient $\kappa = 1 - \varphi$ est compris entre 0 et 1 : à chaque période, le processus corrige en moyenne la fraction κ de son écart à la moyenne. Si X_{t-1} est au-dessus de μ, la variation attendue est négative ; s'il est en dessous, elle est positive.

Image mentale

Imaginez une balle attachée à un élastique fixé au point μ. À chaque instant, quelqu'un la pousse au hasard (le choc ε_t), mais l'élastique la tire vers μ avec une force proportionnelle à la distance. Plus κ est grand, plus l'élastique est raide. Avec $\varphi = 1$, il n'y a plus d'élastique : on retrouve le promeneur ivre. L'équation (1.6) préfigure le modèle à correction d'erreur du chapitre 4 et le processus d'Ornstein-Uhlenbeck du chapitre 5, qui en est la version en temps continu.

1.6.4 La demi-vie

Proposition 1.5 (Demi-vie)**.** *Pour* $0 < \varphi < 1$*, l'écart* espéré *à la moyenne est divisé par deux en*

$$h_{1/2} = -\frac{\ln 2}{\ln \varphi} \quad \textit{périodes}, \qquad \textit{avec l'approximation} \qquad h_{1/2} \approx \frac{\ln 2}{1-\varphi} \quad \textit{quand } \varphi \textit{ est proche de } 1.$$

Démonstration. D'après $(*)$ appliquée à partir de la date t, $Y_{t+h} = \varphi^h Y_t + \sum_{j=0}^{h-1} \varphi^j \varepsilon_{t+h-j}$. Les chocs futurs ont une espérance nulle, donc $\mathbb{E}[Y_{t+h} \mid Y_t] = \varphi^h Y_t$. On cherche h tel que $\varphi^h = 1/2$. En prenant le logarithme : $h \ln \varphi = \ln(1/2) = -\ln 2$, d'où $h = -\ln 2 / \ln \varphi$ (positif puisque $\ln \varphi < 0$). Pour l'approximation, on pose $\varphi = 1 - \kappa$ avec κ petit ; le développement limité $\ln(1-\kappa) = -\kappa - \kappa^2/2 - \cdots \approx -\kappa$ donne $h \approx \ln 2 / \kappa$. □

Tableau 1.1: Demi-vie en fonction de φ (en nombre de périodes, par exemple en jours sur données quotidiennes).

φ	0,50	0,80	0,90	0,95	0,99
$h_{1/2}$ exacte $= -\ln 2 / \ln \varphi$	1,00	3,11	6,58	13,51	68,97
approximation $\ln 2/(1-\varphi)$	1,39	3,47	6,93	13,86	69,31

Lecture pour le trading. La demi-vie donne l'échelle de temps d'une stratégie. Une demi-vie de 6 jours signifie qu'un écart ouvert met typiquement une à deux semaines à se refermer ; une demi-vie de 70 jours immobilise le capital pendant des mois et multiplie les occasions de rupture. Chan [8] recommande d'utiliser la demi-vie pour régler à la fois la fenêtre de calcul de la moyenne mobile et la durée de détention attendue.

1.6.5 Vérification (H2)

Vérification en Python — script `h2_ar1_half_life.py`

Hypothèses : pour $\varphi = 0{,}95$ et $\sigma = 1$: (a) $\gamma(0) = 1/(1-0{,}95^2) = 10{,}256$; (b) $\rho(h) = 0{,}95^h$; (c) demi-vie 13,51 ; (d) biais de l'estimateur sur échantillon court.
Résultats : (a) variance mesurée sur 200 000 points : 10,355 ; (b) autocorrélation au retard 10 : 0,602 contre 0,599 en théorie ; (c) sur 20 000 trajectoires partant d'un écart de 10, l'écart moyen passe sous 5 après 13,59 périodes ; (d) voir le tableau 1.2.

Tableau 1.2: Estimation de φ et de la demi-vie par moindres carrés sur 2 000 échantillons simulés ($\varphi = 0{,}95$, vraie demi-vie 13,51).

Taille n	$\overline{\hat{\varphi}}$	biais	demi-vie médiane	quantile 5 %	quantile 95 %
250	0,9343	−0,0157	10,82	5,87	21,38
1 000	0,9460	−0,0040	12,65	9,28	17,81
5 000	0,9493	−0,0007	13,39	11,51	15,55

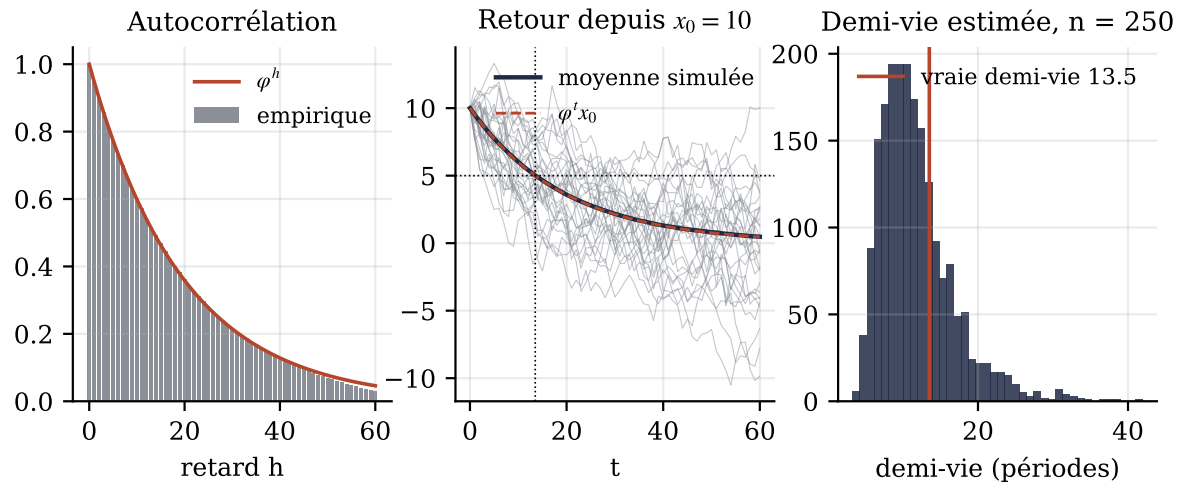


Figure 1.2: À gauche, l'autocorrélation empirique suit φ^h. Au centre, 30 trajectoires partant de $x_0 = 10$ et leur moyenne, qui suit $\varphi^t x_0$ et coupe le niveau 5 à la demi-vie. À droite, la dispersion de la demi-vie estimée sur 250 observations (environ un an de données quotidiennes).

Piège / limite

Avec un an de données quotidiennes ($n = 250$), la demi-vie estimée est en médiane de 10,8 jours au lieu de 13,5, et dans 10 % des cas elle sort de l'intervalle $[5{,}9\,;\,21{,}4]$. L'estimateur de φ est biaisé vers le bas ; l'approximation classique de Kendall [27], $\mathbb{E}[\hat{\varphi}] - \varphi \approx -(1+3\varphi)/n$, prédit $-3{,}85/250 = -0{,}0154$, très proche du biais mesuré ($-0{,}0157$). Conséquence pratique : sur historique court, une paire paraît revenir *plus vite* qu'en réalité, ce qui pousse à trader trop souvent et à sous-estimer la durée de détention. Le chapitre 2 revient sur ce biais et le chapitre 5 sur l'estimation par maximum de vraisemblance.

1.7 De deux prix non stationnaires à un écart stationnaire

1.7.1 L'ivrogne et son chien

Murray [38] propose l'image suivante. Une promeneuse ivre sort du bar et erre au hasard : sa position est une marche aléatoire. Son chien, en laisse, erre lui aussi. Prise isolément, la trajectoire de chacun est imprévisible. Mais la laisse impose que la distance entre les deux reste bornée : quand le chien s'éloigne trop, la promeneuse l'appelle, ou le chien revient de lui-même. La *distance* entre eux est stationnaire, alors que leurs *positions* ne le sont pas.

Définition 1.8 (Cointégration, version intuitive)**.** Deux séries X_t et Y_t non stationnaires de type $I(1)$ sont *cointégrées* s'il existe un nombre β tel que l'écart $S_t = Y_t - \beta X_t$ soit stationnaire. Le vecteur $(1, -\beta)$ est appelé vecteur de cointégration. La définition formelle, les tests et les généralisations à plusieurs actifs sont l'objet du chapitre 4 [15, 26].

Voilà l'idée fondatrice de l'arbitrage statistique par cointégration : on ne sait pas prédire X ni Y, mais si S est stationnaire, on sait que ses écarts à la moyenne sont temporaires, et la section précédente nous dit à quelle vitesse ils se résorbent.

1.7.2 Corrélation n'est pas cointégration

C'est l'erreur la plus fréquente chez les débutants : choisir des paires parce que leurs rendements sont fortement corrélés. La corrélation des rendements mesure si les deux actifs bougent *dans le même sens le même jour*. La cointégration mesure si leurs *niveaux* restent liés *à long terme*. Les deux propriétés sont logiquement indépendantes.

Exemple 1.2 (Deux paires construites pour le montrer)**. Paire A** : X et Y sont deux marches aléatoires dont les chocs quotidiens sont corrélés à 0,9. Elles bougent presque toujours ensemble, mais rien ne ramène l'une vers l'autre : leur écart est lui-même une marche aléatoire.

Paire B : X est une marche aléatoire et $Y_t = X_t + s_t$, où s_t est un AR(1) avec $\varphi = 0{,}5$ et des chocs d'écart-type $\sigma_s = 2$, plus grand que celui des chocs de X (égal à 1). L'écart $Y - X = s$ est stationnaire, mais les rendements de Y sont dominés par le bruit de s.

On peut même calculer la corrélation des rendements de la paire B. Les rendements sont $\Delta X_t = u_t$ et $\Delta Y_t = u_t + \Delta s_t$. Calculons d'abord la variance de $\Delta s_t = s_t - s_{t-1}$ par la proposition 1.1 (avec $\beta = 1$) et la proposition 1.4 :

$$\mathrm{Var}(\Delta s_t) = \gamma(0) + \gamma(0) - 2\gamma(1) = 2\gamma(0)(1-\varphi), \qquad \gamma(0) = \frac{\sigma_s^2}{1-\varphi^2} = \frac{4}{0{,}75} = 5{,}33,$$

donc $\mathrm{Var}(\Delta s_t) = 2 \times 5{,}33 \times 0{,}5 = 5{,}33$. Comme u_t est indépendant de s, $\mathrm{Cov}(\Delta X_t, \Delta Y_t) = \mathrm{Var}(u_t) = 1$ et $\mathrm{Var}(\Delta Y_t) = 1 + 5{,}33 = 6{,}33$. D'où

$$\mathrm{Corr}(\Delta X_t, \Delta Y_t) = \frac{1}{\sqrt{1}\sqrt{6{,}33}} \approx 0{,}397.$$

Vérification en Python — script `h3_correlation_vs_cointegration.py`

Hypothèse : forte corrélation des rendements sans cointégration (A) et faible corrélation avec cointégration (B) sont possibles. **Protocole :** 1 000 jours par paire ; test ADF sur l'écart $Y - X$ (utilisé ici comme boîte noire, il sera étudié au chapitre 3) ; 500 répétitions. **Résultats :** paire A : corrélation moyenne des rendements 0,90, le test conclut à la stationnarité de l'écart dans seulement 5,8 % des cas, ce qui correspond au taux de fausses alertes attendu d'un test à 5 %. Paire B : corrélation moyenne 0,395 (le calcul théorique donnait 0,397), et le test conclut à la stationnarité dans 100 % des cas.

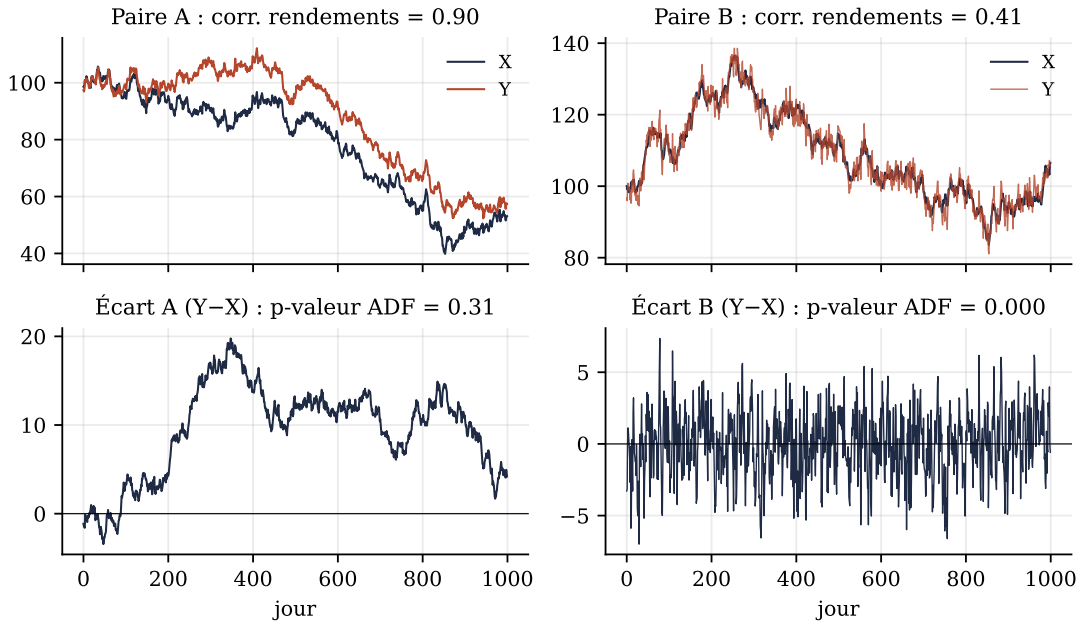


Figure 1.3: En haut, les prix des deux paires ; en bas, leurs écarts. La paire A, très corrélée, dérive sans retour ; la paire B, peu corrélée, a un écart qui oscille autour de zéro.

1.7.3 Le piège de la régression fallacieuse

Si l'on régresse un prix sur un autre pour trouver β, on risque de « découvrir » une relation qui n'existe pas. Granger and Newbold [17] ont montré que la régression d'une marche aléatoire sur une autre, *indépendante*, produit très souvent une pente « significative » au sens du test de Student usuel et un R^2 élevé. La raison : les deux séries ont des tendances aléatoires qui, sur un échantillon fini, semblent aller dans le même sens ou en sens opposé, et les hypothèses du test de Student (résidus non corrélés et stationnaires) sont violées.

Vérification en Python — script `h4_spurious_regression.py`

Hypothèse : régresser deux marches aléatoires indépendantes rejette « pente nulle » bien plus souvent que 5 %. **Protocole :** 2 000 répétitions, $n = 500$. **Résultats :** régression en niveaux : la pente est déclarée significative à 5 % dans 89 % des cas, le R^2 médian vaut 0,17 et dépasse 0,3 dans 35 % des cas. Régression des rendements : 4,3 % de rejets, conforme aux 5 % attendus, et R^2 médian de 0,0009.

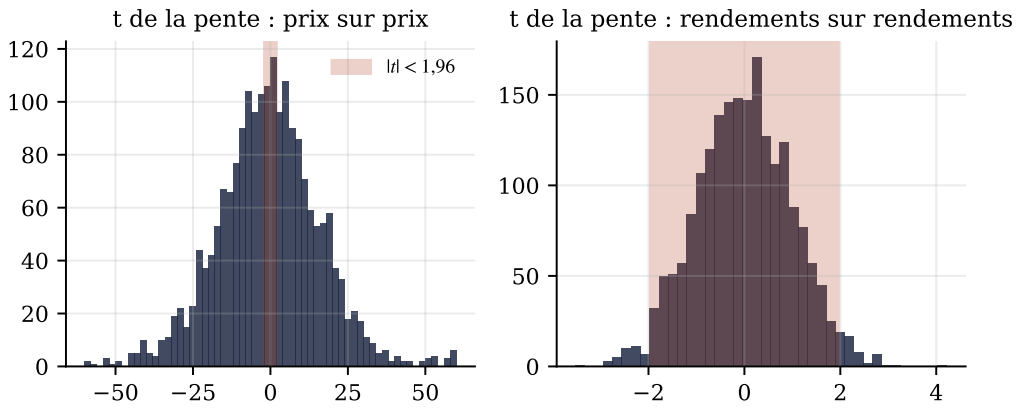


Figure 1.4: Distribution de la statistique t de la pente. En niveaux (gauche), elle est très dispersée et sort presque toujours de la zone $|t| < 1{,}96$; en rendements (droite), elle suit à peu près une loi normale centrée réduite.

Piège / limite

Une régression de prix sur prix ne prouve rien par elle-même. Elle n'a de sens que si l'on vérifie ensuite que les *résidus* sont stationnaires : c'est exactement la méthode d'Engle et Granger, qui utilise des valeurs critiques spécifiques justement parce que les tests usuels sont faussés dans ce contexte (chapitre 4).

1.8 Du spread au signal : une première règle de trading

1.8.1 Construction sans information future

On dispose de deux séries de prix X_t et Y_t. On coupe l'historique en deux : une *période de formation* (les n_f premières dates) et une *période de trading* (les suivantes). Tout ce qui est estimé l'est *uniquement* sur la formation.

1. Sur la formation, on estime $Y_t = \alpha + \beta X_t + e_t$ par moindres carrés (proposition 1.2), d'où $\hat{\alpha}$, $\hat{\beta}$, puis la moyenne m et l'écart-type d des résidus.
2. Sur la période de trading, on calcule l'écart $S_t = Y_t - \hat{\beta} X_t - \hat{\alpha}$ et le *z-score* $z_t = (S_t - m)/d$.
3. Règle : si l'on n'a pas de position et $z_t > 2$, on *vend* l'écart (on vend une unité de Y et on achète $\hat{\beta}$ unités de X) ; si $z_t < -2$, on *achète* l'écart ; on sort quand z_t repasse par 0.

1.8.2 Comptabilité du gain et des coûts

Notons $q_t \in \{-1, 0, +1\}$ la position en écart décidée à la clôture de la date t. Le gain de la date t à la date $t+1$ est

$$\mathrm{G}_{t+1} = q_t \, (S_{t+1} - S_t).$$

Le décalage d'indice est essentiel : la position décidée avec l'information de la date t s'applique à la variation *suivante*. Écrire $q_{t+1}(S_{t+1} - S_t)$ reviendrait à utiliser le prix de demain pour décider aujourd'hui, l'erreur d'anticipation (*look-ahead bias*) la plus fréquente dans les *backtests* amateurs. À chaque changement de position, on paie un coût proportionnel au notionnel échangé sur les deux jambes :

$$\text{coût}_t = c \, |q_t - q_{t-1}| \, \left(Y_t + |\hat{\beta}| X_t\right),$$

où c est exprimé en fraction (5 pb $= 0{,}0005$).

1.8.3 Test dans un monde simulé (H5)

Pour isoler l'effet de chaque ingrédient, on teste la règle dans un monde où la vérité est connue : X est une marche aléatoire autour de 100, $Y_t = 1{,}5 X_t + s_t$ et s_t est un AR(1) avec $\varphi = 0{,}9$ (demi-vie de 6,6 jours) et des chocs d'écart-type 1. La formation dure 500 jours, le trading 1 000 jours, et l'on répète l'expérience 400 fois.

Vérification en Python — script `h5_zscore_toy_strategy.py`

Estimation : $\hat{\beta}$ vaut en moyenne 1,4999 (écart-type 0,058) : la régression retrouve bien le vrai ratio *quand la paire est réellement cointégrée*. **Gain et coûts :** voir le tableau 1.3. **Rupture :** dans une seconde série de mondes, l'écart devient une marche aléatoire ($\varphi = 1$) au 200e jour de trading ; on compare les résultats réalisés *après* ce jour (tableau 1.4).

Tableau 1.3: Règle $|z| > 2$, sortie à $z = 0$, relation stable. Moyennes sur 400 mondes simulés ; gain exprimé en dollars pour une unité d'écart.

Coût par jambe	Gain moyen	Part des mondes gagnants	Sharpe annualisé médian	Allers-retours
0 pb	70,25	100 %	2,02	13,3
5 pb	66,21	100 %	1,91	13,3
10 pb	62,17	100 %	1,80	13,3
25 pb	50,06	100 %	1,45	13,3
50 pb	29,88	98,8 %	0,84	13,3

Tableau 1.4: Après le 200e jour de trading, coût de 5 pb par jambe : relation stable contre relation rompue.

	Relation stable	Relation rompue
Gain moyen par monde	53,41	−2,09 (erreur-type 1,27)
Quantile 5 % du gain	27,64	−46,66
Part des trades gagnants	99,1 %	78,0 %
Gain moyen d'un trade gagnant	5,01	5,17
Perte moyenne d'un trade perdant	−1,73	−20,40
Pire trade	−5,57	−83,76

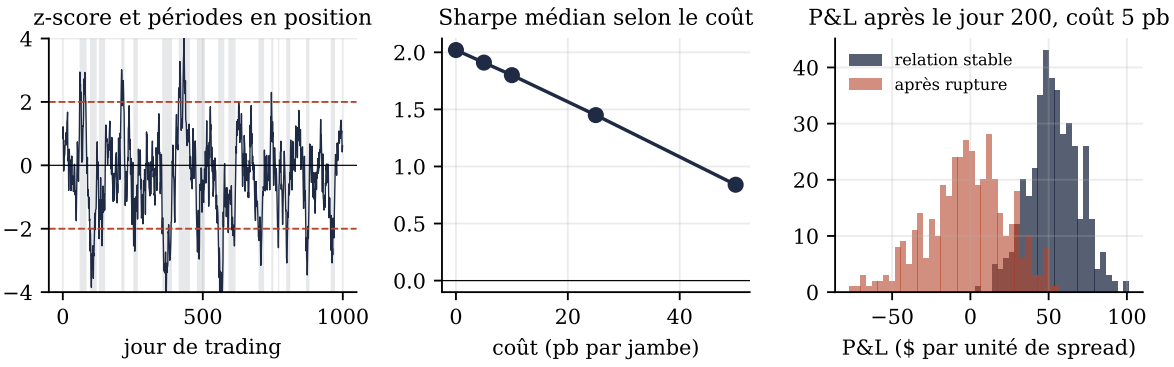


Figure 1.5: À gauche, le *z-score* d'un monde simulé, les seuils ±2 et les périodes en position (grisées). Au centre, le Sharpe médian baisse avec le coût. À droite, distribution du gain réalisé après le 200e jour, avec et sans rupture.

Ce que montrent les chiffres.

1. *Quand l'écart est réellement stationnaire, la règle gagne.* Chaque aller-retour capture environ deux écarts-types de l'écart ($2 \times \sqrt{1/(1-0{,}81)} \approx 4{,}6$), ce qui correspond au gain moyen par trade d'environ 5.
2. *Les coûts mordent vite.* Un aller-retour échange quatre fois un notionnel d'environ 150 (deux jambes, entrée et sortie), soit environ 600 ; à 5 pb, cela coûte 0,30 par aller-retour, ce qui explique la baisse de 70,25 à 66,21 sur 13,3 allers-retours. À 50 pb, le Sharpe est divisé par plus de deux.
3. *Un fort taux de réussite ne prouve rien.* Après la rupture, 78 % des trades restent gagnants, mais la perte moyenne d'un trade perdant (−20,4) est quatre fois le gain moyen d'un trade gagnant, et le gain total moyen devient statistiquement indiscernable de zéro (moins les coûts). C'est le profil « ramasser des pièces devant un rouleau compresseur » : une règle de retour à la moyenne sans contrôle de rupture continue d'accumuler une position perdante en attendant un retour qui ne vient plus.

Piège / limite

Ces résultats proviennent d'un monde simulé *construit pour que la stratégie fonctionne* : écart parfaitement stationnaire, paramètres constants, chocs gaussiens, exécution au prix de clôture, pas de coût d'emprunt des titres vendus à découvert. Sur données réelles, chacun de ces points dégrade la performance. Le monde simulé sert à mesurer l'effet d'un ingrédient à la fois ; il ne prédit pas la rentabilité d'une paire réelle.

1.9 Ce que la théorie apporte, et ses limites

Ce qu'elle apporte. Un langage précis : on ne dit plus « ces deux actions se ressemblent », mais « l'écart est-il stationnaire, avec quelle demi-vie et quelle variance ? ». Des ordres de grandeur avant tout *backtest* : la variance minimale d'un écart ($\sigma_Y^2(1-\rho^2)$), le gain par aller-retour ($\approx$ deux écarts-types de l'écart) et le coût par aller-retour se calculent à la main et disent tout de suite si une idée a une chance de survivre aux frais. Des tests pour éviter les illusions statistiques les plus courantes (régression fallacieuse, corrélation confondue avec cointégration).

Ses limites.

- **La stationnarité ne se démontre jamais sur données.** Un test peut seulement dire que les données sont compatibles avec elle, et sur des échantillons courts la puissance des tests est faible (chapitre 3).
- **Les paramètres changent.** β, φ et σ dérivent avec les régimes de marché ; une relation solide pendant cinq ans peut se rompre en une semaine (fusion, changement de modèle économique, choc réglementaire). Les chapitres 8 (Kalman) et 17 (détection de rupture) y répondent en partie.
- **Les chocs ne sont pas gaussiens.** Les rendements financiers ont des queues épaisses : un écart à 4σ est beaucoup plus fréquent que 0,006 % du temps. Les seuils fondés sur la loi normale sous-estiment le risque extrême.
- **Les frictions ne sont pas modélisées.** Fourchette achat-vente, impact, coût d'emprunt des titres, financement des positions, latence et exécution partielle sont traités dans la partie III.
- **La recherche de paires crée des faux positifs.** Tester 1 000 paires au seuil de 5 % produit en moyenne 50 « paires cointégrées » par pur hasard (chapitre 16).

1.10 Fiche à recopier au tableau blanc

Au tableau blanc

- **Arbitrage pur :** coût ≤ 0, perte impossible, gain possible. **Statistique :** $v(0)=0$, $\mathbb{E}[v(t)] \to > 0$, $\mathbb{P}(v(t)<0)\to 0$, $\mathrm{Var}(v(t))/t \to 0$.
- **Variance d'un écart :** $\mathrm{Var}(Y-\beta X) = \sigma_Y^2 + \beta^2\sigma_X^2 - 2\beta\,\mathrm{Cov}(X,Y)$.
- **Couverture optimale :** $\beta^\star = \mathrm{Cov}(X,Y)/\sigma_X^2 = \rho\,\sigma_Y/\sigma_X$; variance restante $\sigma_Y^2(1-\rho^2)$.
- **Stationnarité faible :** $\mathbb{E}X_t=\mu$, $\mathrm{Var}\,X_t=\gamma(0)$, $\mathrm{Cov}(X_t,X_{t-h})=\gamma(h)$, indépendants de t.
- **Marche aléatoire :** $P_t = P_0 + \sum \varepsilon_i$; $\mathbb{E}P_t = P_0$; $\mathrm{Var}\,P_t = t\sigma^2$; non stationnaire ; $I(1)$.
- **AR(1) :** $X_t - \mu = \varphi(X_{t-1}-\mu)+\varepsilon_t$; stationnaire si $|\varphi|<1$; $\mu = c/(1-\varphi)$; $\gamma(0)=\sigma^2/(1-\varphi^2)$; $\rho(h)=\varphi^h$.
- **Retour à la moyenne :** $\Delta X_t = -(1-\varphi)(X_{t-1}-\mu)+\varepsilon_t$.
- **Demi-vie :** $h_{1/2} = -\ln 2/\ln\varphi \approx \ln 2/(1-\varphi)$.
- **Cointégration (intuition) :** $X, Y \sim I(1)$ et $Y-\beta X \sim I(0)$.
- **Z-score :** $z_t = (S_t - m)/d$, avec m, d estimés *sur la formation seulement*.
- **Gain sans anticipation :** $G_{t+1} = q_t(S_{t+1}-S_t)$.

1.11 Exercices

Exercice 1.1. Montrez que $\mathrm{Var}(aX+bY) = a^2\sigma_X^2 + b^2\sigma_Y^2 + 2ab\,\mathrm{Cov}(X,Y)$, puis retrouvez la proposition 1.1 comme cas particulier.

Exercice 1.2. Deux actifs ont des volatilités quotidiennes $\sigma_X = 1{,}2\,\%$ et $\sigma_Y = 1{,}5\,\%$ et une corrélation de 0,85. Calculez $\beta^\star$ et la volatilité quotidienne de l'écart couvert. Quelle corrélation faudrait-il pour que cette volatilité tombe sous 0,3 % ?

Exercice 1.3. Sur données quotidiennes, on estime $\hat{\varphi} = 0{,}98$. Calculez la demi-vie exacte et approchée. Quel φ correspond à une demi-vie de 10 jours ? En utilisant le tableau 1.2, discutez la fiabilité de cette estimation si elle repose sur un an de données.

Exercice 1.4. Montrez que l'AR(1) avec $\varphi = -0{,}5$ est stationnaire. Que vaut son autocorrélation aux retards 1, 2 et 3 ? Décrivez l'allure d'une trajectoire et ce que cela signifierait pour un trader.

Exercice 1.5. Démontrez que, pour une marche aléatoire, $\mathrm{Corr}(P_t, P_{t+h}) = \sqrt{t/(t+h)}$, et calculez cette corrélation pour $t = 250$ et $h = 5$. Pourquoi cette valeur proche de 1 n'indique-t-elle aucune prévisibilité exploitable ?

Exercice 1.6 (à coder)**.** Modifiez `h5_zscore_toy_strategy.py` pour tester des seuils d'entrée de 1 ; 1,5 ; 2 ; 2,5 et 3. Quel seuil donne le meilleur Sharpe à 5 pb ? Pourquoi serait-il dangereux de retenir ce seuil sur données réelles si on l'a choisi sur la même période que celle où on mesure la performance ? (Indice : chapitre 16.)

Exercice 1.7 (à coder)**.** Ajoutez à `h5` un stop-loss : on ferme la position si $|z_t| > 4$. Mesurez son effet dans le monde stable et dans le monde avec rupture. Le stop-loss coûte-t-il quelque chose quand la relation est stable ?

Exercice 1.8 (données réelles)**.** Téléchargez les prix quotidiens de deux ETF adossés à l'or (par exemple via Interactive Brokers). Estimez $\hat{\beta}$, l'écart, sa demi-vie, et appliquez le test ADF. S'agit-il d'arbitrage statistique ou de quasi-arbitrage au sens de la section 1.2 ? Rapprochez votre réponse du moteur `atjte` (chapitre 0, section 0.7.1).

1.12 Pour aller plus loin

Pour aller plus loin — quoi lire

- Hamilton [19], chapitre 3, sections 3.1 (espérance, stationnarité, ergodicité), 3.2 (bruit blanc) et 3.4 (processus autorégressifs) : la référence pour les démonstrations de la section 6.
- Tsay [46], chapitre 2, sections sur la stationnarité, l'autocorrélation, le bruit blanc et les modèles AR simples : même contenu, orienté données financières, avec des exemples.
- Chan [8], chapitre 2 (« The Basics of Mean Reversion ») : stationnarité, demi-vie et cointégration vues par un praticien, avec code.
- Murray [38] : trois pages, l'image de l'ivrogne et du chien ; à lire en entier.
- Hogan et al. [22] : la section qui définit l'arbitrage statistique (définition 1.2 de ce chapitre).
- Granger and Newbold [17] : l'article original sur la régression fallacieuse, court et lisible.
- Chapitre 0, section 0.6 : la revue de littérature, pour situer la suite.

Prochain chapitre. Le chapitre 2 dérive les moindres carrés sous forme matricielle, explique pourquoi régresser Y sur X ne donne pas le même ratio que régresser X sur Y, introduit le maximum de vraisemblance et revient sur le biais de petit échantillon mesuré au tableau 1.2.

1.13 Scripts du chapitre

Élément	Script (`code/ch01/`)
Figure 1.1	`h1_random_walk_variance.py`
Figure 1.2, tableau 1.2	`h2_ar1_half_life.py`
Figure 1.3	`h3_correlation_vs_cointegration.py`
Figure 1.4	`h4_spurious_regression.py`
Figure 1.5, tableaux 1.3 et 1.4	`h5_zscore_toy_strategy.py`

Chaque script écrit ses chiffres dans `code/ch01/results/` sous le même nom avec l'extension `.json`. Pour tout relancer : `cd code/ch01 && for f in h*.py; do python $f; done` (dépendances : `numpy`, `matplotlib`, `statsmodels`).

Estimer une demi-vie en quatre lignes

```
import numpy as np
def half_life(x):
   """Demi-vie (en periodes) estimee par MCO de x_t sur x_{t-1}."""
   b = np.polyfit(x[:-1], x[1:], 1)[0] # pente = phi estime
   return -np.log(2) / np.log(b) if 0 < b < 1 else np.inf
```

CHAPITRE 2

Régression et estimation

2.1 Objectifs et organisation du chapitre

Objectifs. Le chapitre 1 a montré que le ratio de couverture à variance minimale est une pente de régression. Ce chapitre donne les outils pour estimer ces pentes correctement et pour savoir quand faire confiance au résultat. À la fin du chapitre, vous saurez : (1) dériver les moindres carrés ordinaires sous forme scalaire et matricielle ; (2) énoncer les hypothèses qui rendent l'estimateur sans biais et ses erreurs-types valides ; (3) corriger les erreurs-types quand les résidus sont autocorrélés (Newey-West) ; (4) expliquer pourquoi régresser Y sur X ne donne pas le même ratio que régresser X sur Y, et calculer la régression orthogonale ; (5) écrire et maximiser une vraisemblance, en particulier celle de l'AR(1) ; (6) corriger le biais de petit échantillon du coefficient autorégressif.

Code. Toutes les vérifications sont dans `code/ch02/ch02_regression.py` (expériences E1 à E5), résultats dans `code/ch02/results.json`.

2.2 Le modèle linéaire et les moindres carrés

2.2.1 Cas d'une seule variable explicative

On observe n couples (x_i, y_i) et l'on postule $y_i = a + b x_i + e_i$, où e_i est un résidu. Les moindres carrés ordinaires (MCO) choisissent (a, b) qui minimisent la somme des carrés des résidus

$$S(a,b) = \sum_{i=1}^{n} (y_i - a - b x_i)^2.$$

Proposition 2.1. *Le minimum est atteint en* $\hat{b} = \dfrac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}$ *et* $\hat{a} = \bar{y} - \hat{b}\,\bar{x}$.

Démonstration. S est une fonction convexe de (a,b) (somme de carrés de fonctions affines), donc son minimum annule ses deux dérivées partielles.

$$\frac{\partial S}{\partial a} = -2\sum_i (y_i - a - b x_i) = 0 \;\Rightarrow\; \sum_i y_i = n a + b \sum_i x_i \;\Rightarrow\; a = \bar{y} - b\bar{x}.$$

$$\frac{\partial S}{\partial b} = -2\sum_i x_i (y_i - a - b x_i) = 0.$$

On remplace a par $\bar{y} - b\bar{x}$ dans la seconde équation : $\sum_i x_i \big((y_i - \bar{y}) - b(x_i - \bar{x})\big) = 0$. Comme $\sum_i \bar{x}(y_i - \bar{y}) = 0$ et $\sum_i \bar{x}(x_i - \bar{x}) = 0$, on peut remplacer x_i par $x_i - \bar{x}$ devant la parenthèse sans changer la somme : $\sum_i (x_i - \bar{x})(y_i - \bar{y}) = b \sum_i (x_i - \bar{x})^2$, d'où $\hat{b}$. □

En divisant numérateur et dénominateur par $n-1$, on reconnaît $\hat{b} = \widehat{\mathrm{Cov}}(X,Y) / \widehat{\mathrm{Var}}(X)$: c'est la version empirique du ratio de couverture optimal de la proposition 1.2.

2.2.2 Forme matricielle

Avec k variables explicatives (dont la constante), on empile les observations : $y \in \mathbb{R}^n$, $X \in \mathbb{R}^{n \times k}$ (une ligne par date, une colonne par variable, la première colonne remplie de 1), $\beta \in \mathbb{R}^k$. Le modèle s'écrit $y = X\beta + \varepsilon$.

Proposition 2.2 (Équations normales)**.** *Si* $X^\top X$ *est inversible, l'estimateur des MCO est* $\hat{\beta} = (X^\top X)^{-1} X^\top y$*, et les résidus* $e = y - X\hat{\beta}$ *vérifient* $X^\top e = 0$.

Démonstration. La somme des carrés vaut $S(b) = (y - Xb)^\top (y - Xb) = y^\top y - 2 b^\top X^\top y + b^\top X^\top X b$ (on a utilisé $y^\top X b = b^\top X^\top y$, car c'est un nombre, égal à son transposé). Le gradient par rapport à b est $\nabla S = -2X^\top y + 2X^\top X b$ (règles $\nabla_b (b^\top c) = c$ et $\nabla_b (b^\top A b) = 2Ab$ pour A symétrique). L'annuler donne $X^\top X \hat{\beta} = X^\top y$, puis $\hat{\beta} = (X^\top X)^{-1} X^\top y$. Enfin $X^\top e = X^\top y - X^\top X \hat{\beta} = 0$ par les équations normales elles-mêmes. □

Image mentale

$X\hat{\beta}$ est l'ombre de y projetée sur le plan engendré par les colonnes de X, comme l'ombre d'un bâton au soleil de midi sur le sol. Le résidu e est la partie verticale, perpendiculaire au sol : c'est exactement ce que dit $X^\top e = 0$. En *pairs trading*, le résidu de la régression de Y sur X est le *spread* : la partie de Y que X n'explique pas.

Qualité d'ajustement. Le coefficient de détermination $R^2 = 1 - \sum e_i^2 / \sum (y_i - \bar{y})^2$ mesure la part de la variance de y expliquée. Avec une seule variable explicative, $R^2 = \hat{\rho}_{XY}^2$.

Vérification en Python — E1, données réelles KO et PEP

Hypothèse : les formules écrites à la main donnent les mêmes résultats que `statsmodels`. **Protocole :** régression du cours de clôture de Coca-Cola sur celui de PepsiCo, 500 séances (octobre 2024 à octobre 2026). **Résultats :** $\hat{a} = 105{,}23$ (erreur-type 4,68), $\hat{b} = -0{,}2176$ (erreur-type 0,0319), $R^2 = 0{,}0855$, identiques à `statsmodels` à 4×10^{-12} près ; la plus grande composante de $X^\top e$ vaut 10^{-7} (zéro numérique). **Lecture :** sur ces deux années, les cours de KO et PEP ont évolué en sens opposés (KO a monté, PEP a baissé) ; la « paire classique » des manuels n'avait aucune relation positive en niveau. Nous y reviendrons aux chapitres 4 et 7.

2.3 Propriétés statistiques de l'estimateur

2.3.1 Hypothèses et absence de biais

Les propriétés de $\hat{\beta}$ reposent sur des hypothèses sur le terme d'erreur ε :

(H1) *linéarité* : $y = X\beta + \varepsilon$;

(H2) *rang plein* : $X^\top X$ inversible (aucune variable n'est combinaison linéaire des autres) ;

(H3) *exogénéité* : $\mathbb{E}[\varepsilon \mid X] = 0$;

(H4) *homoscédasticité et absence d'autocorrélation* : $\mathbb{E}[\varepsilon\varepsilon^\top \mid X] = \sigma^2 I_n$.

Proposition 2.3. *Sous (H1)–(H3),* $\mathbb{E}[\hat{\beta} \mid X] = \beta$. *Sous (H1)–(H4),* $\mathrm{Var}(\hat{\beta} \mid X) = \sigma^2 (X^\top X)^{-1}$.

Démonstration. On remplace y par $X\beta + \varepsilon$: $\hat{\beta} = (X^\top X)^{-1} X^\top (X\beta + \varepsilon) = \beta + (X^\top X)^{-1} X^\top \varepsilon$. En prenant l'espérance conditionnelle à X et en utilisant (H3) : $\mathbb{E}[\hat{\beta} \mid X] = \beta + (X^\top X)^{-1} X^\top \mathbb{E}[\varepsilon \mid X] = \beta$. Pour la variance, $\hat{\beta} - \beta = A\varepsilon$ avec $A = (X^\top X)^{-1} X^\top$, donc $\mathrm{Var}(\hat{\beta} \mid X) = A\, \mathbb{E}[\varepsilon\varepsilon^\top \mid X] A^\top = \sigma^2 A A^\top = \sigma^2 (X^\top X)^{-1} X^\top X (X^\top X)^{-1} = \sigma^2 (X^\top X)^{-1}$. □

On estime σ^2 par $\hat{\sigma}^2 = e^\top e / (n - k)$; la division par $n - k$ plutôt que n corrige le fait que k paramètres ont été ajustés sur les mêmes données. Le théorème de Gauss-Markov ajoute que, sous (H1)–(H4), $\hat{\beta}$ a la plus petite variance parmi tous les estimateurs linéaires sans biais.

2.3.2 Le test de Student et ses conditions

La statistique $t_j = \hat{\beta}_j / \widehat{\mathrm{se}}(\hat{\beta}_j)$, où $\widehat{\mathrm{se}}$ est la racine du j-ème terme diagonal de $\hat{\sigma}^2 (X^\top X)^{-1}$, suit approximativement une loi normale centrée réduite si $\beta_j = 0$. Ce résultat exige (H4). Or les séries financières violent souvent (H4) : un *spread* qui revient lentement à la moyenne a des résidus fortement autocorrélés. Le chapitre 1 a montré le cas extrême (régression fallacieuse, section 1.7.3) ; même avec des séries stationnaires, l'autocorrélation fausse les erreurs-types.

2.3.3 Erreurs-types robustes : Newey-West

Sans (H4), la variance exacte de $\hat{\beta}$ est

$$\mathrm{Var}(\hat{\beta} \mid X) = (X^\top X)^{-1} \Big(\sum_t \sum_s x_t x_s^\top \, \mathbb{E}[\varepsilon_t \varepsilon_s] \Big) (X^\top X)^{-1},$$

où x_t est la t-ème ligne de X écrite en colonne. La partie centrale, appelée « viande » du « sandwich », contient les covariances croisées des erreurs. Newey and West [39] l'estiment par

$$\hat{\Omega} = \hat{\Gamma}_0 + \sum_{j=1}^{L} \Big(1 - \frac{j}{L+1} \Big) (\hat{\Gamma}_j + \hat{\Gamma}_j^\top), \qquad \hat{\Gamma}_j = \sum_{t=j+1}^{n} e_t e_{t-j} \, x_t x_{t-j}^\top,$$

avec L retards. Les poids $1 - j/(L+1)$ décroissent linéairement et garantissent que la matrice estimée reste positive.

Vérification en Python — E5, erreurs-types naïves contre Newey-West

Hypothèse : quand x et les résidus sont tous deux autocorrélés, le test de Student naïf rejette à tort « pente nulle » beaucoup plus souvent que 5 %, et Newey-West corrige en partie. **Protocole :** 2 000 répétitions ; x et u indépendants, chacun AR(1) avec $\varphi = 0{,}9$; $y = 1 + 0 \cdot x + u$; $n = 250$. **Résultats :** taux de rejet à 5 % : 51,6 % en naïf, 27,1 % avec Newey-West à 4 retards (règle usuelle $L = \lfloor 4(n/100)^{2/9} \rfloor$), 17,9 % avec 20 retards.

Piège / limite

Le test naïf trouve une relation significative une fois sur deux entre deux séries indépendantes. Newey-West améliore nettement les choses mais reste loin des 5 % nominaux quand la persistance est forte et l'échantillon court. Règle pratique : ne jamais sélectionner une paire ou un signal sur la base d'un t de Student calculé sur des séries persistantes ; utiliser les tests dédiés (chapitres 3 et 4), des erreurs-types robustes et, surtout, une validation hors échantillon (chapitre 16).

2.4 Quelle variable expliquer ? L'asymétrie de la régression

2.4.1 Deux régressions, deux ratios

Pour un *pairs trade*, il faut choisir quelle jambe joue le rôle de Y. Ce choix n'est pas neutre.

Proposition 2.4. *Soit $\hat\beta_{Y|X}$ la pente de Y sur X et $\hat\beta_{X|Y}$ celle de X sur Y. Alors $\hat\beta_{Y|X}\,\hat\beta_{X|Y} = \hat\rho^2_{XY}$, donc $1/\hat\beta_{X|Y} = \hat\beta_{Y|X}/\hat\rho^2_{XY}$.*

Démonstration. D'après la proposition 2.1, $\hat\beta_{Y|X} = \hat s_{XY}/\hat s_X^2$ et, par symétrie, $\hat\beta_{X|Y} = \hat s_{XY}/\hat s_Y^2$. Leur produit vaut $\hat s_{XY}^2/(\hat s_X^2 \hat s_Y^2) = \hat\rho^2_{XY}$. □

Si l'on régresse X sur Y puis qu'on inverse la pente pour obtenir un ratio « en unités de X par unité de Y », on obtient un ratio plus grand d'un facteur $1/\hat\rho^2$. Avec $\rho = 0{,}6$, l'écart est de 178 %. Seule une corrélation parfaite rend les deux choix équivalents.

Image mentale

Les MCO ne mesurent les erreurs que dans une direction : verticalement quand on explique Y, horizontalement quand on explique X. Le bruit de la variable placée à droite (la variable explicative) « aplatit » la pente vers zéro. C'est l'effet dit d'*atténuation*.

2.4.2 La régression orthogonale

Pour traiter les deux actifs symétriquement, on minimise la somme des distances *perpendiculaires* à la droite, ce qui revient à minimiser

$$g(b) = \frac{s_{YY} - 2b\,s_{XY} + b^2 s_{XX}}{1 + b^2},$$

où s_{XX}, s_{YY}, s_{XY} sont les variances et la covariance empiriques. En effet, la distance perpendiculaire d'un point à la droite $y = a + bx$ est $|y - a - bx|/\sqrt{1+b^2}$.

Proposition 2.5 (Pente orthogonale)**.** *Si $s_{XY} > 0$, le minimum de g est atteint en*

$$\hat b_\perp = \frac{(s_{YY} - s_{XX}) + \sqrt{(s_{YY} - s_{XX})^2 + 4 s_{XY}^2}}{2\,s_{XY}}.$$

Démonstration. Écrivons $g = N/D$. La dérivée s'annule quand $N'D = ND'$, soit $(-2s_{XY} + 2bs_{XX})(1+b^2) = 2b\,(s_{YY} - 2bs_{XY} + b^2 s_{XX})$. En développant les deux membres, les termes en $b^3 s_{XX}$ s'annulent et il reste $-2s_{XY} + 2s_{XY}b^2 + 2b(s_{XX} - s_{YY}) = 0$, soit l'équation du second degré $s_{XY}b^2 + (s_{XX} - s_{YY})b - s_{XY} = 0$. Son discriminant $(s_{XX} - s_{YY})^2 + 4s_{XY}^2$ est positif ; des deux racines, celle avec le signe $+$ est de même signe que s_{XY} et correspond au minimum (l'autre est le maximum, la direction perpendiculaire). □

La pente orthogonale est la direction du premier vecteur propre de la matrice de covariance de (X, Y) : c'est déjà une analyse en composantes principales, que l'on retrouvera au chapitre 10. Son défaut : elle dépend des unités (doubler le prix de X change le résultat), d'où l'usage fréquent de log-prix ou de prix normalisés.

Vérification en Python — E2, asymétrie et régression orthogonale

Simulation (vrai $\beta = 1{,}5$, X marche aléatoire, écart AR(1) de paramètre 0,9, $n = 500$, 1 000 répétitions) : MCO de Y sur X : moyenne 1,4986 (écart-type 0,059) ; inverse de la pente de X sur Y : 1,5642 (0,074) ; régression orthogonale : 1,5445 (0,067). **Variables stationnaires** ($\sigma_X = \sigma_Y = 1$) : pour $\rho = 0{,}3$; 0,6 ; 0,9 ; 0,99, on obtient $\hat{\beta}_{Y|X} = 0{,}287$; 0,600 ; 0,903 ; 0,989 et $1/\hat{\beta}_{X|Y} = 3{,}49$; 1,70 ; 1,11 ; 1,009, le produit des deux pentes reproduisant ρ^2. **KO et PEP** (prix) : $-0{,}218$ contre $-2{,}54$ selon le sens, $-0{,}41$ en orthogonal ; les trois ratios n'ont même pas d'ordre de grandeur commun.

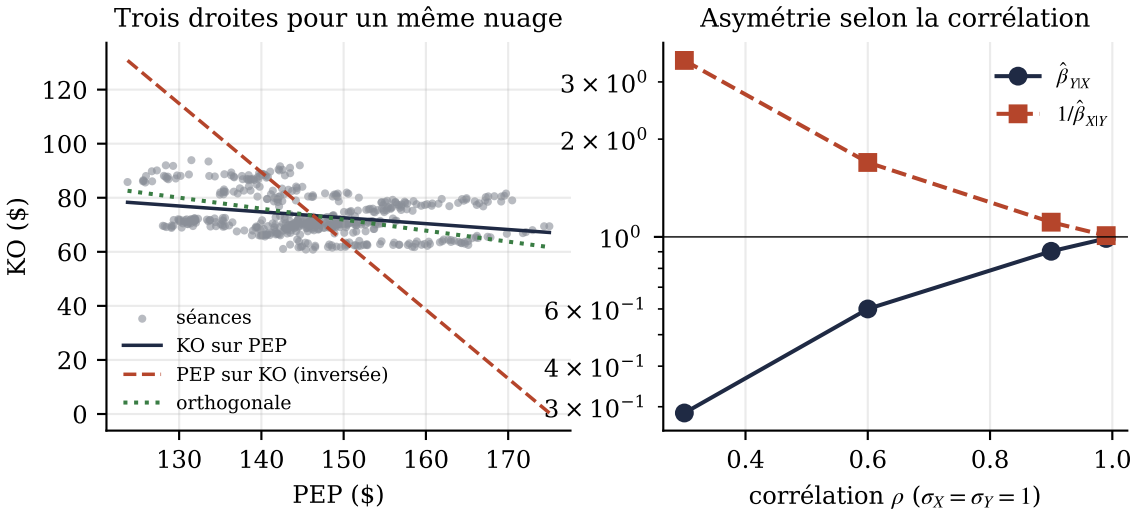


Figure 2.1: À gauche, les cours de KO et PEP (500 séances) et trois droites d'ajustement : selon la méthode, le « ratio de couverture » change du tout au tout, signe d'une relation inexistante. À droite, la pente directe et l'inverse de la pente réciproque ne coïncident que si la corrélation est proche de 1 (échelle logarithmique).

Lecture pour le trading. Quand la paire est réellement cointégrée (simulation), les trois estimateurs sont proches et convergent vers la vraie valeur ; quand elle ne l'est pas (KO/PEP sur cette période), ils divergent. *L'écart entre $\hat{\beta}_{Y|X}$ et $1/\hat{\beta}_{X|Y}$ est donc un premier diagnostic gratuit* : s'il est grand, la relation est fragile. Les praticiens retiennent souvent la jambe la plus liquide comme X, ou testent les deux sens et gardent celui qui produit l'écart le plus stationnaire (chapitre 4).

2.4.3 Prix ou log-prix ? Neutralité en parts ou en dollars

Régresser les prix donne un ratio en *nombre de parts* : $Y - \beta X$ est la valeur d'un portefeuille long une part de Y, court β parts de X. Régresser les log-prix donne un ratio en *élasticité* : $\log Y - \beta \log X$; une position « neutre en dollars » (même montant investi des deux côtés) correspond à $\beta = 1$ en log. Le choix change la position et donc le risque : la version en log-prix est la plus courante en actions (on raisonne en rendements), la version en prix est naturelle pour deux instruments du même sous-jacent (or contre or), comme dans `atjte` où k convertit des unités.

2.5 Le maximum de vraisemblance

2.5.1 Principe

Soit un modèle qui donne la densité des données $f(x_1, \ldots, x_n; \theta)$ en fonction d'un paramètre θ. La *vraisemblance* est cette densité vue comme fonction de θ, à données fixées : $\mathscr{L}(\theta) = f(x_1, \ldots, x_n; \theta)$. L'estimateur du maximum de vraisemblance (MV) est la valeur de θ qui rend les données observées les plus probables. On maximise en pratique la log-vraisemblance $\ell(\theta) = \ln \mathscr{L}(\theta)$, plus simple (les produits deviennent des sommes) et qui a le même maximum car ln est croissante.

Image mentale

Vous trouvez une pièce et la lancez dix fois : huit piles. Quelle probabilité de pile rend ce résultat le plus plausible ? Avec $p = 0{,}5$, huit piles est peu probable ; avec $p = 0{,}8$, c'est le résultat le plus probable. Le maximum de vraisemblance choisit $\hat{p} = 0{,}8$. C'est le même raisonnement, appliqué à un processus entier.

2.5.2 Vraisemblance de l'AR(1)

Pour l'AR(1) gaussien $X_t = c + \varphi X_{t-1} + \varepsilon_t$, $\varepsilon_t \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$, la loi de X_t *sachant* X_{t-1} est $\mathcal{N}(c + \varphi X_{t-1}, \sigma^2)$. Par la formule des probabilités conditionnelles en chaîne, la densité jointe se factorise :

$$f(x_0, \dots, x_n) = f(x_0) \prod_{t=1}^{n} f(x_t \mid x_{t-1}).$$

Proposition 2.6. *En ignorant le terme $f(x_0)$ (vraisemblance « conditionnelle »), l'estimateur MV de (c, φ) est l'estimateur MCO de x_t sur $(1, x_{t-1})$, et $\hat{\sigma}^2_{MV} = \frac{1}{n}\sum_t \hat{e}_t^2$.*

Démonstration. La log-vraisemblance conditionnelle vaut

$$\ell(c, \varphi, \sigma^2) = \sum_{t=1}^{n} \ln\left[\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_t - c - \varphi x_{t-1})^2}{2\sigma^2}}\right] = -\frac{n}{2}\ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{t=1}^{n}(x_t - c - \varphi x_{t-1})^2.$$

Pour tout σ^2 fixé, maximiser en (c, φ) revient à minimiser la somme des carrés : ce sont les MCO. On dérive ensuite par rapport à σ^2 : $-\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum \hat{e}_t^2 = 0$, d'où $\hat{\sigma}^2 = \frac{1}{n}\sum \hat{e}_t^2$. □

La vraisemblance *exacte* ajoute $\ln f(x_0)$, où $X_0 \sim \mathcal{N}\big(c/(1-\varphi), \sigma^2/(1-\varphi^2)\big)$ si le processus est stationnaire (proposition 1.4). Ce terme pèse peu quand n est grand, mais il pénalise les valeurs de φ proches de 1 et améliore légèrement l'estimation sur échantillon court.

Propriétés asymptotiques. Sous des conditions de régularité, l'estimateur MV est convergent et asymptotiquement normal, de variance égale à l'inverse de l'information de Fisher. Pour l'AR(1) stationnaire, cela donne $\mathrm{Var}(\hat{\varphi}) \approx (1 - \varphi^2)/n$ [19, ch. 5 et 8].

Vérification en Python — E3, MCO et maximum de vraisemblance

Protocole : un AR(1) avec $c = 0{,}2$, $\varphi = 0{,}9$, $\sigma = 0{,}5$, $n = 300$; maximisation numérique (Nelder-Mead). **Résultats :** MCO : $\hat{c} = 0{,}1893$, $\hat{\varphi} = 0{,}9039$, $\hat{\sigma} = 0{,}5193$; MV conditionnel : exactement les mêmes valeurs ; MV exact : $\hat{c} = 0{,}1972$, $\hat{\varphi} = 0{,}9019$, $\hat{\sigma} = 0{,}5187$. La figure 2.2 montre la log-vraisemblance profilée en φ.

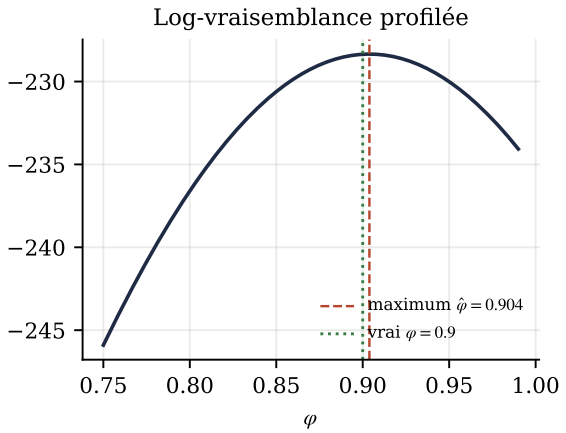


Figure 2.2: Log-vraisemblance profilée de l'AR(1) en fonction de φ (les autres paramètres sont optimisés pour chaque φ). Le maximum est proche, mais pas égal, à la vraie valeur : c'est l'incertitude d'estimation.

2.6 Le biais de petit échantillon et sa correction

Le chapitre 1 (tableau 1.2) a mesuré que $\hat{\varphi}$ est biaisé vers le bas. L'approximation de Kendall [27] donne $\mathbb{E}[\hat{\varphi}] - \varphi \approx -(1+3\varphi)/n$ quand la moyenne est estimée. On peut donc corriger :

$$\hat{\varphi}_c = \hat{\varphi} + \frac{1+3\hat{\varphi}}{n}.$$

La correction utilise $\hat{\varphi}$ au lieu de φ (inconnu), ce qui laisse un petit biais résiduel.

Vérification en Python — E4, correction de Kendall

Protocole : $\varphi = 0{,}95$ (demi-vie vraie 13,51), 3 000 échantillons par taille. **Résultats** (tableau 2.1) : la correction ramène la moyenne de $\hat{\varphi}$ très près de la vérité et supprime l'essentiel du biais de demi-vie, au prix d'une légère sur-correction de la médiane de la demi-vie quand n est petit.

Tableau 2.1: Estimation brute et corrigée de $\varphi = 0{,}95$ (moyennes et médianes sur 3 000 échantillons).

n	$\overline{\hat{\varphi}}$ brut	$\overline{\hat{\varphi}_c}$ corrigé	demi-vie médiane brute	demi-vie médiane corrigée	écart-type de $\hat{\varphi}$
100	0,9068	0,9430	7,92	14,61	0,0496
250	0,9336	0,9489	10,79	14,41	0,0247
1 000	0,9462	0,9500	12,77	13,80	0,0105

Piège / limite

Corriger le biais ne réduit pas l'incertitude. Avec $n = 250$, l'écart-type de $\hat{\varphi}$ (0,025) reste du même ordre que la distance qui sépare $\varphi = 0{,}95$ de la racine unitaire $\varphi = 1$. Autrement dit, un an de données quotidiennes ne permet pas de distinguer de façon fiable un écart qui revient lentement d'un écart qui ne revient pas du tout. Le chapitre 3 quantifie ce problème de puissance.

2.7 Ce que la théorie apporte, et ses limites

Apports. Les MCO donnent le ratio de couverture à variance minimale et le *spread* comme résidu ; le maximum de vraisemblance fournit un cadre unique pour estimer tous les modèles du cours (AR, Ornstein-Uhlenbeck, Kalman, copules) ; les erreurs-types robustes et la correction de biais rendent les estimations plus honnêtes.

Limites. (1) Le ratio estimé dépend du sens de la régression, des unités et de la fenêtre ; il n'existe pas « le » bon β. (2) Les hypothèses (H3)–(H4) sont presque toujours violées par les séries de prix. (3) Les propriétés asymptotiques du MV supposent que le modèle est juste ; si l'écart n'est pas un AR(1), l'estimateur converge vers le « meilleur AR(1) », pas vers une vérité. (4) Aucun estimateur ne crée de l'information absente des données : la précision est limitée par la longueur de l'échantillon, mesurée en nombre de demi-vies observées plutôt qu'en nombre de points.

2.8 Fiche à recopier au tableau blanc

Au tableau blanc

- **MCO simples :** $\hat{b} = \sum(x-\bar{x})(y-\bar{y})/\sum(x-\bar{x})^2$, $\hat{a} = \bar{y} - \hat{b}\bar{x}$.
- **MCO matriciels :** $\hat{\beta} = (X^\top X)^{-1}X^\top y$; $X^\top e = 0$; $\hat{\sigma}^2 = e^\top e/(n-k)$.
- **Sans biais :** $\hat{\beta} = \beta + (X^\top X)^{-1}X^\top \varepsilon$; $\mathrm{Var}(\hat{\beta}) = \sigma^2(X^\top X)^{-1}$ sous (H4).
- **Sandwich :** $(X^\top X)^{-1}\,\hat{\Omega}\,(X^\top X)^{-1}$; Newey-West : poids $1 - j/(L+1)$.
- **Asymétrie :** $\hat{\beta}_{Y|X}\hat{\beta}_{X|Y} = \hat{\rho}^2$.
- **Orthogonale :** $s_{XY}b^2 + (s_{XX} - s_{YY})b - s_{XY} = 0$, racine de même signe que s_{XY}.
- **Log-vraisemblance AR(1) :** $\ell = -\frac{n}{2}\ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum(x_t - c - \varphi x_{t-1})^2$; MV conditionnel = MCO.
- **Asymptotique :** $\mathrm{Var}(\hat{\varphi}) \approx (1-\varphi^2)/n$.
- **Correction de Kendall :** $\hat{\varphi}_c = \hat{\varphi} + (1+3\hat{\varphi})/n$.

2.9 Exercices

Exercice 2.1. Montrez que, dans la régression simple avec constante, la somme des résidus est nulle et que la droite passe par le point moyen $(\bar{x}, \bar{y})$.

Exercice 2.2. Montrez que $R^2 = \hat{\rho}^2_{XY}$ en régression simple. Déduisez-en la proposition 2.4 par un autre chemin.

Exercice 2.3. Vérifiez la proposition 2.5 dans le cas $s_{XX} = s_{YY}$: que vaut la pente orthogonale ? Interprétez géométriquement.

Exercice 2.4. Avec $\varphi = 0{,}95$ et $n = 250$, calculez l'écart-type asymptotique $\sqrt{(1-\varphi^2)/n}$ et comparez à l'écart-type mesuré dans le tableau 2.1. Pourquoi l'asymptotique sous-estime-t-elle l'incertitude ?

Exercice 2.5 (à coder)**.** Reprenez E2 en régressant logKO sur logPEP sur des fenêtres glissantes de 120 séances. Tracez le ratio dans le temps. Que conclure sur la stabilité de la « couverture » ?

Exercice 2.6 (à coder)**.** Implémentez un *bootstrap* par blocs pour l'erreur-type de $\hat{b}$ dans E5 (tirage de blocs consécutifs de 25 observations) et comparez son taux de rejet à celui de Newey-West.

2.10 Pour aller plus loin

Pour aller plus loin — quoi lire

- Hamilton [19], chapitre 8 (« Linear Regression Models ») pour les MCO et leurs propriétés ; chapitre 5 (« Maximum Likelihood Estimation ») pour la vraisemblance des processus ARMA.
- Newey and West [39] : l'article original, très court, sur l'estimateur de variance robuste.
- Kendall [27] : la note originale sur le biais d'estimation de l'autocorrélation.
- Vidyamurthy [48] : la discussion du choix du ratio de couverture en *pairs trading*, avant les tests de cointégration.

2.11 Scripts du chapitre

`code/ch02/ch02_regression.py` : E1 (MCO à la main contre `statsmodels`), E2 (asymétrie et figure 2.1), E3 (vraisemblance et figure 2.2), E4 (tableau 2.1), E5 (Newey-West). Résultats : `code/ch02/results.json`.

CHAPITRE 3

Tester la stationnarité et le retour à la moyenne

3.1 Objectifs et organisation du chapitre

Objectifs. Les chapitres précédents ont utilisé le test ADF comme une boîte noire. Ce chapitre l'ouvre. À la fin, vous saurez : (1) écrire la régression de Dickey-Fuller et expliquer pourquoi sa statistique ne suit pas une loi de Student ; (2) choisir les termes déterministes (constante, tendance) et le nombre de retards ; (3) évaluer la puissance d'un test et la relier au nombre de demi-vies observées ; (4) utiliser le test KPSS et combiner les deux ; (5) calculer et interpréter le ratio de variance et l'exposant de Hurst ; (6) appliquer ces outils à deux paires réelles et lire correctement des résultats contradictoires.

Code. `code/ch03/ch03_stationarity_tests.py`, expériences E1 à E6.

3.2 Le test de Dickey-Fuller

3.2.1 La régression

On part de l'AR(1) $x_t = c + \varphi x_{t-1} + \varepsilon_t$ et l'on soustrait x_{t-1} des deux côtés :

$$\Delta x_t = c + \gamma x_{t-1} + \varepsilon_t, \qquad \gamma = \varphi - 1.$$

L'hypothèse nulle $H_0 : \gamma = 0$ (soit $\varphi = 1$) est celle d'une *racine unitaire* : le processus est une marche aléatoire, sans retour à la moyenne. L'alternative $H_1 : \gamma < 0$ est celle d'un processus stationnaire. La statistique de test est le rapport $\tau = \hat{\gamma}/\widehat{\mathrm{se}}(\hat{\gamma})$, calculé exactement comme un t de Student.

Image mentale

On demande aux données : « quand x était haut hier, a-t-il eu tendance à baisser aujourd'hui ? ». Si oui ($\hat{\gamma}$ nettement négatif), il y a une force de rappel. La subtilité est de savoir ce que veut dire « nettement » quand, sous l'hypothèse nulle, la série elle-même erre sans borne.

3.2.2 Pourquoi la statistique n'est pas normale

Plaçons-nous sous H_0 dans le cas le plus simple (pas de constante, $x_0 = 0$) : $x_t = x_{t-1} + \varepsilon_t$. L'estimateur est $\hat{\gamma} = \sum x_{t-1}\varepsilon_t / \sum x_{t-1}^2$. Regardons le numérateur. En élevant au carré $x_t = x_{t-1} + \varepsilon_t$:

$$x_t^2 = x_{t-1}^2 + 2x_{t-1}\varepsilon_t + \varepsilon_t^2 \quad \Longrightarrow \quad x_{t-1}\varepsilon_t = \tfrac{1}{2}\left(x_t^2 - x_{t-1}^2 - \varepsilon_t^2\right).$$

En sommant de $t = 1$ à n, la somme des $x_t^2 - x_{t-1}^2$ « télescope » (chaque terme s'annule avec le suivant) et il reste

$$\sum_{t=1}^{n} x_{t-1}\varepsilon_t = \tfrac{1}{2}\left(x_n^2 - \sum_{t=1}^{n}\varepsilon_t^2\right).$$

Divisons par $n\sigma^2$. Par la proposition 1.3, $x_n/(\sigma\sqrt{n})$ suit une loi $\mathcal{N}(0,1)$ (exactement, si les chocs sont gaussiens) ; notons-la W. Par la loi des grands nombres, $\frac{1}{n\sigma^2}\sum \varepsilon_t^2 \to 1$. Donc

$$\frac{1}{n\sigma^2}\sum_{t=1}^{n} x_{t-1}\varepsilon_t \;\longrightarrow\; \tfrac{1}{2}\left(W^2 - 1\right).$$

Or W^2 suit une loi du χ^2 à un degré de liberté, très asymétrique : $\mathbb{P}(W^2 < 1) = \mathbb{P}(|W| < 1) \approx 68\,\%$. Le numérateur de $\hat{\gamma}$ est donc négatif dans environ deux cas sur trois *alors même qu'il n'y a aucun retour à la moyenne*. La statistique τ est décalée vers la gauche par rapport à une loi normale. La théorie complète [11, 19] montre que τ converge vers une fonctionnelle du mouvement brownien, $\frac{1}{2}(W(1)^2 - 1)/\sqrt{\int_0^1 W(r)^2\,\mathrm{d}r}$, dont les quantiles se calculent par simulation.

Vérification en Python — E1, distribution de Dickey-Fuller

Protocole : 20 000 marches aléatoires de 500 points ; statistique τ avec constante. **Résultats :** quantiles à 1 %, 5 % et 10 % : $-3{,}44$; $-2{,}87$; $-2{,}57$, pour des valeurs tabulées de $-3{,}43$; $-2{,}86$; $-2{,}57$. La moyenne de τ vaut $-1{,}54$ au lieu de 0. Si l'on utilisait par erreur le seuil de la loi normale ($-1{,}645$), on conclurait à tort au retour à la moyenne dans 46,4 % des cas.

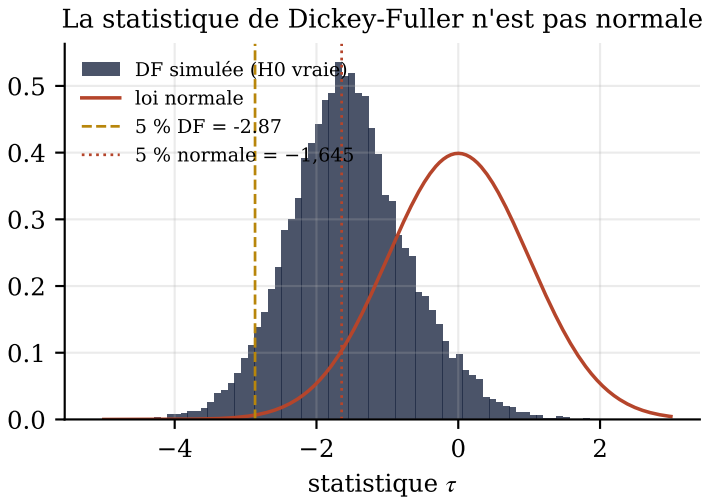


Figure 3.1: Distribution simulée de la statistique de Dickey-Fuller sous l'hypothèse de racine unitaire, comparée à la loi normale.

3.2.3 Termes déterministes et valeurs critiques

Les valeurs critiques dépendent de ce que l'on met dans la régression :

Tableau 3.1: Valeurs critiques asymptotiques du test de Dickey-Fuller (statistique τ).

Régression	1 %	5 %	10 %
Sans constante : $\Delta x_t = \gamma x_{t-1} + \varepsilon_t$	$-2{,}58$	$-1{,}95$	$-1{,}62$
Avec constante : $\Delta x_t = c + \gamma x_{t-1} + \varepsilon_t$	$-3{,}43$	$-2{,}86$	$-2{,}57$
Avec constante et tendance : $\Delta x_t = c + \delta t + \gamma x_{t-1} + \varepsilon_t$	$-3{,}96$	$-3{,}41$	$-3{,}13$

Lequel choisir ? Pour un *spread* de *pairs trading* dont la moyenne n'est pas nulle, on met une constante. On ajoute une tendance seulement si une raison économique la justifie, comme un écart de frais de gestion entre deux ETF (section 3.7) ; ajouter une tendance « au cas où » réduit la puissance.

3.2.4 Le test augmenté (ADF)

Si les chocs du *spread* sont eux-mêmes autocorrélés, ε_t n'est pas un bruit blanc et le test est faussé. Le test de Dickey-Fuller augmenté ajoute des retards de la variation :

$$\Delta x_t = c + \gamma x_{t-1} + \sum_{j=1}^{p} \delta_j \Delta x_{t-j} + \varepsilon_t .$$

Les retards absorbent l'autocorrélation de court terme ; les valeurs critiques asymptotiques restent celles du tableau 3.1. On choisit p par un critère d'information (AIC ou BIC), ce que fait `statsmodels` avec `autolag="AIC"`.

3.3 La puissance : combien de données faut-il ?

La *puissance* d'un test est la probabilité de rejeter H_0 quand elle est fausse. Ici : la probabilité de détecter un retour à la moyenne qui existe vraiment.

Vérification en Python — E2, puissance du test ADF à 5 %

Protocole : AR(1) stationnaires, 200 à 400 répétitions par case. **Résultats :** tableau 3.2 et figure 3.2.

Tableau 3.2: Probabilité que le test ADF (constante, 1 retard) rejette la racine unitaire à 5 %.

	$n = 100$	250	500	1 000	2 500
$\varphi = 0{,}90$ (demi-vie 6,6)	29 %	96 %	100 %	100 %	100 %
$\varphi = 0{,}95$ (demi-vie 13,5)	11 %	44 %	96 %	100 %	100 %
$\varphi = 0{,}98$ (demi-vie 34,3)	9 %	13 %	33 %	85 %	100 %
$\varphi = 0{,}99$ (demi-vie 69,0)	7 %	6 %	10 %	32 %	97 %

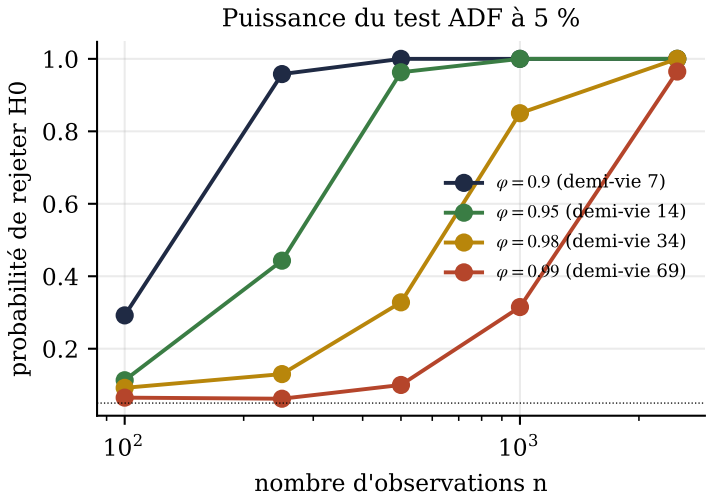


Figure 3.2: Puissance du test ADF en fonction de la taille d'échantillon, pour quatre vitesses de retour.

La règle des demi-vies. Les cases de puissance comparable ont un point commun : la quantité $n(1-\varphi)$. Avec $n(1-\varphi) = 10$ ($\varphi = 0{,}90$, $n = 100$; ou $\varphi = 0{,}99$, $n = 1000$), la puissance est d'environ 30 % ; avec $n(1-\varphi) = 25$ ($\varphi = 0{,}95$, $n = 500$; ou $\varphi = 0{,}99$, $n = 2500$), elle dépasse 95 %. Or, d'après la proposition 1.5, $n(1-\varphi) \approx \ln 2 \times n/h_{1/2}$: ce qui compte n'est pas le nombre de points, mais le *nombre de demi-vies observées*. Règle pratique : il faut observer au moins une trentaine de demi-vies pour détecter un retour à la moyenne de façon fiable.

Piège / limite

Passer de données quotidiennes à des données minute multiplie le nombre de points mais pas le nombre de demi-vies : si l'écart revient en 30 jours, une année de données minute contient toujours une douzaine de demi-vies, et le test reste peu puissant. Augmenter la fréquence n'aide que si la dynamique de retour est elle-même rapide.

3.4 Le test KPSS : inverser l'hypothèse nulle

Le test ADF a pour hypothèse nulle la non-stationnarité ; ne pas la rejeter ne prouve pas qu'elle est vraie (manque de puissance). Kwiatkowski et al. [31] proposent l'inverse : H_0 = stationnarité. Le modèle est $x_t = \xi t + r_t + u_t$, où r_t est une marche aléatoire de variance d'innovation σ_r^2 et u_t est stationnaire ; $H_0 : \sigma_r^2 = 0$.

La statistique repose sur les sommes partielles des résidus e_t de la régression de x_t sur une constante (ou une constante et une tendance) : $S_t = \sum_{i \le t} e_i$, et

$$\eta = \frac{1}{n^2} \frac{\sum_{t=1}^{n} S_t^2}{\hat{\sigma}_{LR}^2},$$

où $\hat{\sigma}_{LR}^2$ est une variance de long terme estimée à la Newey-West (chapitre 2). Valeur critique à 5 % : 0,463 (constante), 0,146 (constante et tendance).

Image mentale

Les écarts d'une série stationnaire s'annulent en moyenne : leur somme cumulée oscille autour de zéro, comme les dépenses et recettes d'un ménage bien géré. Ceux d'une série non stationnaire s'accumulent : la somme cumulée part au loin, comme une dette qui grossit. KPSS mesure la taille de cette somme cumulée.

Vérification en Python — E3, combiner ADF et KPSS

Protocole : 400 séries de 500 points par processus ; tests à 5 %. **Résultats :** marche aléatoire : ADF n'est pas rejeté et KPSS est rejeté dans 89 % des cas (conclusion correcte « non stationnaire »). AR(1) avec $\varphi = 0{,}5$: ADF rejeté, KPSS non rejeté dans 94 % des cas (conclusion correcte « stationnaire »). AR(1) avec $\varphi = 0{,}95$: les deux tests rejettent dans 40 % des cas, signe que la série est stationnaire mais très persistante.

Tableau 3.3: Lecture conjointe des tests ADF et KPSS.

	KPSS non rejeté	KPSS rejeté
ADF rejeté	stationnaire (signal clair)	persistante, à confirmer
ADF non rejeté	données insuffisantes	non stationnaire (signal clair)

3.5 Le ratio de variance

3.5.1 Définition et calcul pour l'AR(1)

Le ratio de variance compare la variance des variations sur q périodes à q fois la variance des variations sur une période :

$$VR(q) = \frac{\mathrm{Var}(x_{t+q} - x_t)}{q\,\mathrm{Var}(x_{t+1} - x_t)}.$$

Pour une marche aléatoire, $\mathrm{Var}(x_{t+q} - x_t) = q\sigma^2$ (proposition 1.3), donc $VR(q) = 1$.

Proposition 3.1. *Pour un AR(1) stationnaire,* $VR(q) = \dfrac{1-\varphi^q}{q(1-\varphi)}$, *qui est strictement inférieur à 1 pour* $0 < \varphi < 1$ *et* $q \ge 2$.

Démonstration. Par la proposition 1.1 avec $\beta = 1$ et la proposition 1.4 : $\mathrm{Var}(x_{t+q} - x_t) = \gamma(0) + \gamma(0) - 2\gamma(q) = 2\gamma(0)(1-\varphi^q)$. De même, $\mathrm{Var}(x_{t+1} - x_t) = 2\gamma(0)(1-\varphi)$. Le rapport donne la formule. Comme $1 - \varphi^q = (1-\varphi)(1 + \varphi + \cdots + \varphi^{q-1})$ et que chaque $\varphi^j < 1$ pour $j \ge 1$, on a $1 - \varphi^q < q(1-\varphi)$. □

Image mentale

Pour une marche aléatoire, les mouvements s'additionnent : dix jours bougent $\sqrt{10}$ fois plus qu'un jour. Pour un processus qui revient à la moyenne, les mouvements se compensent : dix jours bougent moins que ce que l'addition prédirait, $VR < 1$. Pour un processus qui suit une tendance, ils se renforcent : $VR > 1$.

Lo and MacKinlay [35] en déduisent un test : sous l'hypothèse de marche aléatoire à chocs homoscédastiques,

$$z(q) = \frac{VR(q) - 1}{\sqrt{2(2q-1)(q-1)/(3qn)}}$$

suit approximativement une loi $\mathcal{N}(0,1)$.

Vérification en Python — E4, ratio de variance

Protocole : séries de 5 000 points. **Résultats :** pour l'AR(1) avec $\varphi = 0{,}9$, $VR(q)$ simulé vaut 0,954 ; 0,823 ; 0,655 ; 0,417 ; 0,224 ; 0,150 pour $q = 2, 5, 10, 20, 40, 60$, contre 0,950 ; 0,819 ; 0,651 ; 0,439 ; 0,246 ; 0,166 en théorie. Pour une série dont les rendements sont autocorrélés positivement (coefficient 0,3), $VR(10) = 1{,}77$. Statistique $z(10)$: $-1{,}25$ (marche aléatoire, non significatif), $-7{,}21$ (AR), $+16{,}0$ (rendements autocorrélés). Pour la marche aléatoire, $VR(60) = 0{,}73$: l'erreur-type de $VR(60)$ vaut environ 0,125 ici, c'est un écart de deux erreurs-types dû au hasard, rappel que les grands horizons sont mal mesurés.

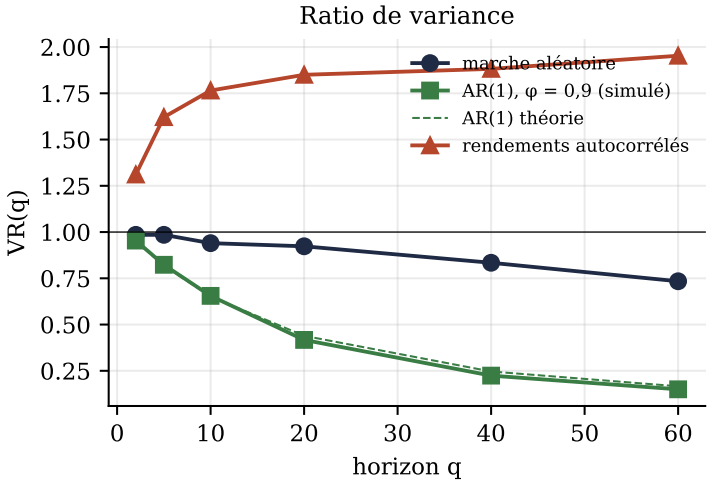


Figure 3.3: Ratio de variance en fonction de l'horizon pour trois dynamiques.

3.6 L'exposant de Hurst

L'exposant de Hurst H résume la façon dont l'amplitude des variations croît avec l'horizon : $\mathrm{sd}(x_{t+\tau} - x_t) \propto \tau^H$. On l'estime par la pente de la régression de $\log \mathrm{sd}(x_{t+\tau} - x_t)$ sur $\log \tau$. Pour une marche aléatoire, $H = 1/2$; $H < 1/2$ indique un retour à la moyenne ; $H > 1/2$ une persistance des tendances [8].

Vérification en Python — E5, exposant de Hurst (retards 2 à 50)

Protocole : 200 séries de 2 000 points. **Résultats** (moyenne, et intervalle 5–95 %) : marche aléatoire 0,494 [0,44 ; 0,55] ; AR(1) $\varphi = 0{,}9$: 0,218 [0,19 ; 0,26] ; AR(1) $\varphi = 0{,}99$: 0,457 [0,40 ; 0,51] ; rendements autocorrélés : 0,525 [0,47 ; 0,58].

Piège / limite

L'exposant de Hurst n'est pas une propriété intrinsèque : il dépend de la plage de retards choisie. Sur les retards 2 à 50, un AR(1) de demi-vie 69 jours ($\varphi = 0{,}99$) a un H indiscernable de celui d'une marche aléatoire : le retour à la moyenne ne se manifeste qu'au-delà de la demi-vie. C'est le même problème de puissance que pour ADF, sous un autre nom. Utilisez Hurst et le ratio de variance comme diagnostics descriptifs, jamais comme tests uniques.

3.7 Études de cas réelles

On applique les outils à deux écarts construits sur 500 séances réelles (octobre 2024 à octobre 2026).

GLD et GLDM : un quasi-arbitrage parfaitement arbitré. Les deux fonds détiennent de l'or physique. Avec une constante seule, ADF ne rejette pas la racine unitaire ($p = 0{,}925$) et KPSS rejette la stationnarité : conclusion naïve, « non stationnaire ». C'est faux. Le log-ratio décroît régulièrement de 0,293 % par an : c'est l'ordre de grandeur de l'écart entre les frais de gestion annuels des deux fonds, prélevés jour après jour sur l'actif du fonds le plus cher. Avec une tendance dans la régression, ADF rejette massivement ($\tau = -22$) et KPSS ne rejette plus. Une fois la tendance retirée, l'écart a un écart-type de 4,5 points de base, son quantile à 99 % vaut 8,3 points de base, et $\hat{\varphi} = 0{,}011$: un écart d'un jour a disparu le lendemain. Les participants

Tableau 3.4: Diagnostics de stationnarité sur données réelles (E6). ADF avec AIC ; KPSS avec retards automatiques ; p-valeurs KPSS bornées entre 0,01 et 0,10 par la table.

Série	ADF p	KPSS p	$\hat{\varphi}$	demi-vie (j)	$VR(10)$	H
log GLD (un prix seul)	0,547	0,01	0,9949	136,6	0,79	0,46
log GLD − log GLDM, constante seule	0,925	0,01	0,9338	10,1	0,10	0,01
idem, tests avec tendance	<0,001	≥0,10	—	—	—	—
idem, tendance retirée	<0,001	≥0,10	0,0111	0,2	0,10	0,01
log KO − log PEP	0,949	0,01	0,9996	1 803	0,96	0,50
log KO − (−0,432) log PEP (MCO)	0,684	0,01	0,9915	81,4	0,82	0,44

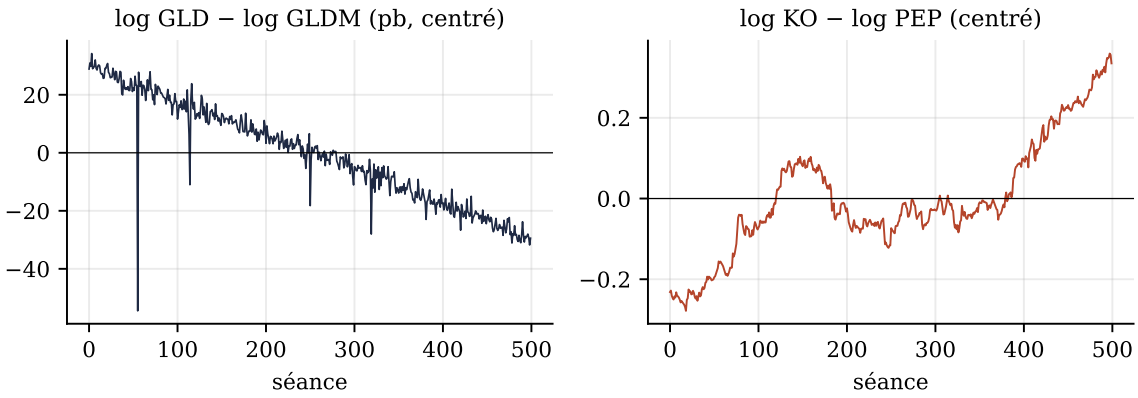


Figure 3.4: À gauche, l'écart logarithmique entre GLD et GLDM en points de base : une pente régulière vers le bas plus un bruit quotidien de quelques points de base. À droite, l'écart logarithmique entre KO et PEP : une dérive sans retour.

autorisés, qui créent et détruisent des parts contre de l'or, maintiennent la relation. **Leçon :** il n'y a rien à gagner à l'échelle quotidienne après coûts ; s'il existe un avantage, il est intrajournalier et réservé à ceux qui exécutent vite et pour presque rien.

KO et PEP : la paire des manuels ne l'était pas. Avec un ratio de 1 ou avec le ratio MCO (négatif, ce qui n'a aucun sens économique pour deux concurrents), l'écart ne montre aucun retour à la moyenne détectable. Le $\hat{\varphi}$ de 0,9915 correspondrait à une demi-vie de 81 jours, soit à peine six demi-vies dans l'échantillon : le tableau 3.2 dit que, même si ce retour existait, on ne pourrait pas le détecter avec deux ans de données. Ajoutons que tester les résidus d'une régression estimée exige d'autres valeurs critiques (chapitre 4) : les p-valeurs de la dernière ligne sont même trop optimistes.

3.8 Tests multiples : un avertissement

Supposons que l'on teste 500 écarts candidats au seuil de 5 %. Même si aucun ne revient à la moyenne, on en déclarera en moyenne 25 « stationnaires ». Les vrais retours à la moyenne, s'il y en a, sont noyés parmi les faux positifs, et ce sont souvent les faux positifs qui ont les meilleures statistiques en échantillon. Le chapitre 7 traite cette question (contrôle du taux de fausses découvertes) et le chapitre 16 en tire les conséquences pour l'évaluation des stratégies.

3.9 Ce que la théorie apporte, et ses limites

Apports. Des valeurs critiques correctes, qui évitent de voir du retour à la moyenne partout ; un lien quantitatif entre durée d'observation et capacité de détection ; des diagnostics complémentaires (KPSS, ratio de variance, Hurst) qui, ensemble, donnent une image plus fiable qu'un test isolé.

Limites. (1) Tous ces tests supposent des paramètres constants sur l'échantillon ; une rupture (changement de moyenne) fait ressembler une série stationnaire à une marche aléatoire. (2) Les tendances déterministes doivent être justifiées économiquement,

sinon on teste ce qu'on veut voir. (3) Un test répond à une question statistique (« y a-t-il une force de rappel ? ») ; la question économique (« cette force est-elle assez rapide et ample pour payer les coûts ? ») demande une analyse séparée, comme le montre l'écart GLD/GLDM, parfaitement stationnaire et pourtant inexploitable.

3.10 Fiche à recopier au tableau blanc

Au tableau blanc

- **DF :** $\Delta x_t = c + \gamma x_{t-1} + \varepsilon_t$, $H_0 : \gamma = 0$ (racine unitaire), $\tau = \hat{\gamma}/\mathrm{se}$.
- **Pourquoi non normale :** $\sum x_{t-1}\varepsilon_t = \frac{1}{2}(x_n^2 - \sum \varepsilon_t^2) \Rightarrow \frac{1}{2}(W^2 - 1)$, négatif 68 % du temps.
- **Seuils 5 % :** $-1{,}95$ (rien), $-2{,}86$ (constante), $-3{,}41$ (tendance).
- **ADF :** ajouter $\sum \delta_j \Delta x_{t-j}$, choisir p par AIC.
- **Puissance :** gouvernée par $n(1-\varphi) \approx 0{,}69\, n/h_{1/2}$; viser ≥ 30 demi-vies.
- **KPSS :** H_0 stationnarité ; $\eta = n^{-2}\sum S_t^2/\hat{\sigma}_{LR}^2$; seuil 0,463.
- **Ratio de variance :** $VR(q) = \mathrm{Var}(x_{t+q} - x_t)/(q\,\mathrm{Var}(\Delta x))$; AR(1) : $(1-\varphi^q)/(q(1-\varphi))$.
- **Hurst :** $\mathrm{sd}(x_{t+\tau} - x_t) \propto \tau^H$; $H < \frac{1}{2}$ retour, $= \frac{1}{2}$ marche, $> \frac{1}{2}$ tendance.

3.11 Exercices

Exercice 3.1. Refaites la démonstration de $\sum x_{t-1}\varepsilon_t = \frac{1}{2}(x_n^2 - x_0^2 - \sum \varepsilon_t^2)$ avec $x_0 \neq 0$. Calculez $\mathbb{P}(W^2 < 1)$ à l'aide de la table de la loi normale.

Exercice 3.2. Un écart a une demi-vie estimée de 20 jours. Combien d'années de données quotidiennes faut-il pour avoir une puissance d'environ 95 % d'après la règle des demi-vies ? Et une demi-vie de 5 jours ?

Exercice 3.3. Calculez la limite de $VR(q)$ quand $q \to \infty$ pour un AR(1) stationnaire. Interprétez.

Exercice 3.4 (à coder)**.** Simulez un AR(1) avec $\varphi = 0{,}8$ dont la moyenne saute de 0 à 5 au milieu de l'échantillon. Appliquez ADF et KPSS. Que concluez-vous à tort ? Comment détecter la rupture (voir chapitre 17) ?

Exercice 3.5 (à coder)**.** Sur l'écart GLD/GLDM sans tendance, calculez l'autocorrélation des variations quotidiennes. Pourquoi est-elle proche de $-0{,}5$ quand l'écart est un bruit blanc ? (Indice : $\mathrm{Var}(\Delta x)$ et $\mathrm{Cov}(\Delta x_t, \Delta x_{t-1})$ pour un bruit blanc.)

3.12 Pour aller plus loin

Pour aller plus loin — quoi lire

- Hamilton [19], chapitre 17 (« Univariate Processes with Unit Roots ») : la théorie asymptotique complète de Dickey-Fuller, avec les tables de valeurs critiques.
- Dickey and Fuller [11] et Kwiatkowski et al. [31] : les articles originaux.
- Lo and MacKinlay [35] : le test du ratio de variance, appliqué aux indices boursiers américains.
- Chan [8], chapitre 2 : ADF, Hurst et ratio de variance appliqués à des paires réelles, avec code.

3.13 Scripts du chapitre

`code/ch03/ch03_stationarity_tests.py` : E1 (figure 3.1), E2 (tableau 3.2, figure 3.2), E3 (tableau 3.3), E4 (figure 3.3), E5 (Hurst), E6 (tableau 3.4, figure 3.4).

CHAPITRE 4

Cointégration

4.1 Objectifs et organisation du chapitre

Objectifs. Le chapitre 1 a donné l'intuition de la cointégration ; ce chapitre en donne la théorie et les outils. À la fin, vous saurez : (1) définir l'ordre d'intégration et la cointégration ; (2) appliquer la méthode d'Engle-Granger avec les bonnes valeurs critiques ; (3) expliquer la superconvergence du ratio de couverture et ses limites ; (4) écrire un modèle à correction d'erreur et en déduire qui « corrige » l'écart et à quelle vitesse ; (5) comprendre la procédure de Johansen pour plusieurs actifs ; (6) reconnaître une cointégration partielle ; (7) appliquer le tout aux paires réelles du cours.

Code. `code/ch04/ch04_cointegration.py`, expériences E1 à E6.

4.2 Ordre d'intégration et définition

Définition 4.1 (Ordre d'intégration)**.** Une série x_t est *intégrée d'ordre d*, notée $x_t \sim I(d)$, s'il faut la différencier d fois pour obtenir une série stationnaire (sans tendance déterministe non modélisée). Une série stationnaire est $I(0)$; une marche aléatoire est $I(1)$, puisque $\Delta x_t = \varepsilon_t$ est $I(0)$.

Définition 4.2 (Cointégration, Engle and Granger [15])**.** Les composantes d'un vecteur $x_t = (x_{1t}, \dots, x_{kt})^\top$, toutes $I(1)$, sont *cointégrées* s'il existe un vecteur non nul $\beta \in \mathbb{R}^k$ tel que $\beta^\top x_t$ soit $I(0)$. Le vecteur β est un *vecteur de cointégration* ; le nombre r de vecteurs linéairement indépendants qui ont cette propriété est le *rang de cointégration*, avec $0 \le r < k$.

Pour deux actifs, r vaut 0 (pas de relation) ou 1 (une relation), et le vecteur est défini à un facteur près ; on le *normalise* en fixant le coefficient d'un actif à 1 : $\beta = (1, -\beta_2)$, d'où l'écart $S_t = x_{1t} - \beta_2 x_{2t}$.

Image mentale

Pensez à k bateaux sur une mer agitée. La marée (une tendance stochastique commune) les soulève tous. S'il y a k bateaux mais seulement $k - r$ marées indépendantes, il existe r combinaisons de leurs hauteurs dans lesquelles les marées s'annulent : ce sont les écarts stationnaires. Deux bateaux sur la même marée : une combinaison. Deux bateaux dans deux ports différents : aucune.

4.3 La méthode d'Engle-Granger

4.3.1 Les deux étapes

1. **Estimer** la relation de long terme par MCO : $x_{1t} = a + b\,x_{2t} + e_t$ (chapitre 2).
2. **Tester** la stationnarité des résidus $\hat{e}_t$ par un test de Dickey-Fuller augmenté (chapitre 3), *avec des valeurs critiques spécifiques*.

4.3.2 Pourquoi des valeurs critiques spécifiques

À la première étape, les MCO choisissent b pour que les résidus soient *les plus petits possible*. Même si x_1 et x_2 ne sont pas cointégrés, ces résidus ont donc l'air « plus stationnaires » qu'une marche aléatoire quelconque : la régression a déjà fait une partie du travail du test. Il faut donc des seuils plus exigeants. Avec deux variables et une constante, les valeurs asymptotiques de Engle and Granger [15], affinées par MacKinnon, sont $-3{,}90$ (1 %), $-3{,}34$ (5 %) et $-3{,}04$ (10 %) ; avec trois variables, $-4{,}29$; $-3{,}74$; $-3{,}45$.

Vérification en Python — E1, valeurs critiques d'Engle-Granger

Protocole : 10 000 paires de marches aléatoires indépendantes de 500 points ; régression puis Dickey-Fuller sur les résidus. **Résultats :** quantiles simulés $-3{,}91$; $-3{,}36$; $-3{,}07$, conformes aux valeurs tabulées. Avec le seuil de Dickey-Fuller ($-2{,}86$), on déclarerait cointégrées 14,9 % des paires indépendantes, trois fois le taux nominal ; avec le seuil d'Engle-Granger, 5,3 %.

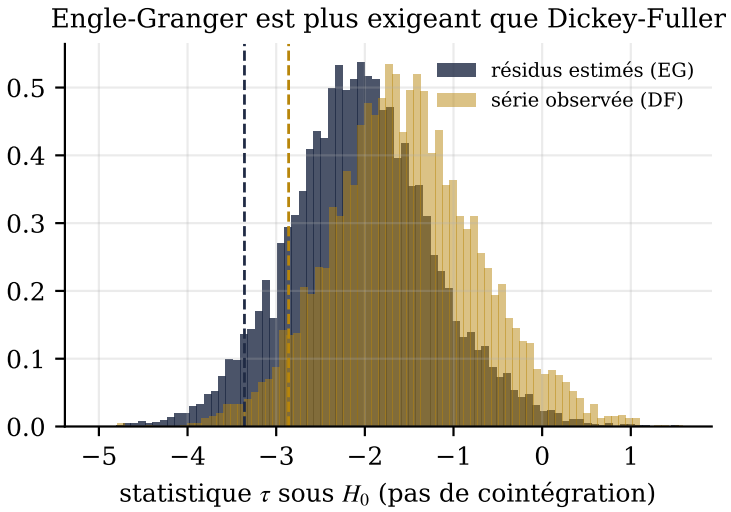


Figure 4.1: Sous l'hypothèse d'absence de cointégration, la statistique calculée sur des résidus estimés (Engle-Granger) est décalée vers la gauche par rapport à celle d'une série observée (Dickey-Fuller).

4.3.3 La superconvergence du ratio

Quand la paire est réellement cointégrée, l'estimateur MCO de b converge vers la vraie valeur à la vitesse $1/n$, et non $1/\sqrt{n}$ comme dans une régression ordinaire : on parle de *superconvergence*. L'intuition : le régresseur x_2 erre de plus en plus loin (sa variance empirique croît comme n), ce qui rend toute erreur sur b de plus en plus coûteuse en somme des carrés.

Vérification en Python — E2, superconvergence

Protocole : vrai $b = 1{,}5$, écart AR(1) avec $\varphi = 0{,}9$, 500 répétitions. **Résultats :** écart-type de $\hat{b}$: 0,111 ($n = 250$), 0,030 ($n = 1\,000$), 0,0081 ($n = 4\,000$) ; il est divisé par environ 4 quand n est multiplié par 4 (vitesse $1/n$). Pour une régression entre variables stationnaires : 0,067 ; 0,030 ; 0,016, divisé par 2 seulement (vitesse $1/\sqrt{n}$).

Piège / limite

La superconvergence est un résultat asymptotique qui suppose que la tendance commune domine le bruit de l'écart. Sur deux ans de données, avec un écart volatil, $\hat{b}$ peut rester loin de la vérité (voir E3 ci-dessous, où $\hat{b} = 0{,}88$ pour une vraie valeur de 1). Elle ne protège en rien contre une relation qui change au cours du temps.

4.4 Le modèle à correction d'erreur

4.4.1 Le théorème de représentation de Granger

Théorème 4.1 (Représentation de Granger, énoncé simplifié)**.** *Deux séries $I(1)$ sont cointégrées, d'écart $S_t = x_{1t} - \beta x_{2t}$, si et seulement si elles admettent une représentation à correction d'erreur*

$$\Delta x_{1t} = \mu_1 + \alpha_1 S_{t-1} + (\text{retards de } \Delta x_1, \Delta x_2) + \varepsilon_{1t},$$
$$\Delta x_{2t} = \mu_2 + \alpha_2 S_{t-1} + (\text{retards de } \Delta x_1, \Delta x_2) + \varepsilon_{2t},$$

avec $(\alpha_1, \alpha_2) \neq (0, 0)$.

Les coefficients α_1, α_2 sont les *vitesses d'ajustement*. Si l'écart est positif (x_1 trop haut par rapport à x_2), il faut que x_1 baisse ($\alpha_1 < 0$) ou que x_2 monte ($\alpha_2 > 0$), ou les deux.

Image mentale

Dans l'image de Murray [38], si la promeneuse appelle son chien et que le chien revient, c'est le chien qui « corrige l'erreur » ; si la promeneuse va chercher son chien, c'est elle ; souvent, les deux font la moitié du chemin. Le modèle à correction d'erreur mesure qui fait quoi.

4.4.2 Vitesse de retour de l'écart

Proposition 4.1. *Sans retards, l'écart suit* $\Delta S_t = (\mu_1 - \beta\mu_2) + (\alpha_1 - \beta\alpha_2) S_{t-1} + (\varepsilon_{1t} - \beta\varepsilon_{2t})$. *C'est un AR(1) de coefficient* $\varphi_S = 1 + \alpha_1 - \beta\alpha_2$.

Démonstration. $\Delta S_t = \Delta x_{1t} - \beta\Delta x_{2t}$; on remplace chaque variation par son équation et on regroupe les termes en S_{t-1}. On reconnaît l'écriture « retour à la moyenne » de l'AR(1), équation (1.6) du chapitre 1, avec $\varphi_S - 1 = \alpha_1 - \beta\alpha_2$. □

Vérification en Python — E3, correction d'erreur

Protocole : système simulé ($n = 2\,000$) avec $\beta = 1$, $\alpha_1 = -0{,}10$, $\alpha_2 = +0{,}05$; donc $\varphi_S = 1 - 0{,}10 - 0{,}05 = 0{,}85$ et une demi-vie de 4,27 jours. **Résultats :** $\hat\beta = 0{,}879$; $\hat\alpha_1 = -0{,}127$ ($t = -13{,}3$) ; $\hat\alpha_2 = 0{,}055$ ($t = 6{,}0$) ; $\hat\varphi_S = 0{,}825$, demi-vie 3,6 jours. Les deux jambes participent à la correction, avec les bons signes. Le biais sur β vient de ce que, dans ce système, la tendance commune est faible par rapport au bruit de l'écart.

Lecture pour le trading. Si seule une jambe corrige ($\alpha_2 \approx 0$), l'autre est le « meneur » : c'est elle qui porte l'information, et c'est sur la jambe suiveuse que le retour se produit. Pour un *pairs trade*, cela influence le choix de la jambe à exécuter en premier et le risque d'exécution (chapitre 15). Dans le cas `atjte`, le CFD sur MT5 sert de prix de référence : on suppose implicitement que c'est le prix sur la plateforme crypto qui s'ajuste.

4.5 Plusieurs actifs : la procédure de Johansen

4.5.1 Le VECM

Avec k actifs, on écrit un modèle vectoriel à correction d'erreur (VECM) :

$$\Delta x_t = \mu + \Pi x_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \Delta x_{t-i} + \varepsilon_t, \qquad \Pi = \alpha\beta^\top,$$

où α et β sont des matrices $k \times r$. Les colonnes de β sont les vecteurs de cointégration, celles de α les vitesses d'ajustement. Le rang de Π est le nombre de relations de cointégration : rang 0, pas de relation (le modèle se réduit à un VAR en différences) ; rang k, toutes les séries sont stationnaires ; entre les deux, r relations.

4.5.2 L'idée de Johansen

Johansen [26] estime le VECM par maximum de vraisemblance. Après avoir retiré l'effet des retards Δx_{t-i} par régression, il calcule les *corrélations canoniques* entre les variations Δx_t et les niveaux x_{t-1} : ce sont les combinaisons des niveaux qui prédisent le mieux les variations. Les carrés de ces corrélations sont des valeurs propres $\hat\lambda_1 \geq \cdots \geq \hat\lambda_k$; un $\hat\lambda_i$ nettement positif signale une combinaison de niveaux qui « rappelle » les prix, donc une relation de cointégration. Deux statistiques testent le rang :

$$\text{trace}(r) = -T \sum_{i=r+1}^{k} \ln(1 - \hat\lambda_i), \qquad \text{valeur propre max}(r) = -T \ln(1 - \hat\lambda_{r+1}),$$

qui testent H_0 : rang $\leq r$. On teste successivement $r = 0, 1, \ldots$ et on s'arrête au premier non-rejet.

Vérification en Python — E4, Johansen sur trois actifs

Protocole : x_1 et x_2 partagent une tendance commune ($x_2 = 0{,}5\times$ tendance + AR(1)), x_3 suit sa propre tendance ; une seule relation, $x_2 - 0{,}5x_1$. **Résultats :** statistique de trace 48,1 ; 6,1 ; 2,1 pour $r = 0, 1, 2$, contre des seuils à 5 % de 29,8 ; 15,5 ; 3,8 : on rejette $r = 0$, pas $r = 1$: rang 1, correct. Vecteur estimé normalisé sur x_2 : $(-0{,}535\,;\,1\,;\,-0{,}042)$, proche de $(-0{,}5\,;\,1\,;\,0)$.

Engle-Granger ou Johansen ? Engle-Granger est simple et transparent mais dépend du choix de la variable normalisée et ne trouve qu'une relation ; Johansen traite les actifs symétriquement et estime le nombre de relations, mais il est sensible à la spécification (retards, termes déterministes) et ses propriétés sur petits échantillons sont moins bonnes. En *pairs trading*, on utilise souvent Engle-Granger pour la sélection et Johansen pour les paniers de trois actifs et plus.

4.6 La cointégration partielle

Les paires réelles ne sont presque jamais parfaitement cointégrées : leur relation dérive lentement (changement de modèle économique, de structure de coûts). Clegg and Krauss [9] modélisent l'écart comme la somme de deux composantes cachées,

$$S_t = M_t + R_t, \qquad M_t = \rho M_{t-1} + \varepsilon_t^M, \quad R_t = R_{t-1} + \varepsilon_t^R,$$

une partie qui revient à la moyenne ($|\rho| < 1$, écart-type d'innovation σ_M) et une partie marche aléatoire (écart-type σ_R). Comme R est une marche aléatoire, S n'est pas stationnaire : un test de cointégration classique conclut à l'absence de relation. Pourtant, une partie des variations de l'écart est prévisible.

Proposition 4.2. *La part de la variance des variations de l'écart due à la composante de retour à la moyenne vaut*

$$R^2_{MR} = \frac{\mathrm{Var}(\Delta M_t)}{\mathrm{Var}(\Delta S_t)} = \frac{2\sigma_M^2}{2\sigma_M^2 + (1+\rho)\sigma_R^2}.$$

Démonstration. D'après la démonstration de la proposition 3.1 avec $q = 1$, $\mathrm{Var}(\Delta M_t) = 2\gamma_M(0)(1-\rho) = 2\frac{\sigma_M^2}{1-\rho^2}(1-\rho) = \frac{2\sigma_M^2}{1+\rho}$. Par ailleurs $\mathrm{Var}(\Delta R_t) = \sigma_R^2$, et les deux composantes sont indépendantes, donc $\mathrm{Var}(\Delta S_t) = \frac{2\sigma_M^2}{1+\rho} + \sigma_R^2$. On fait le rapport et on multiplie numérateur et dénominateur par $1+\rho$. □

Vérification en Python — E5, ADF face à la cointégration partielle

Protocole : $\rho = 0{,}9$, $\sigma_M = 1$, $n = 1\,000$, 300 répétitions. **Résultats :** pour $\sigma_R = 0$; 0,1 ; 0,2 ; 0,4 ; 0,8, on a $R^2_{MR} = 1$; 0,991 ; 0,963 ; 0,868 ; 0,622 et le test ADF conclut à la stationnarité dans 100 ; 98,7 ; 86,7 ; 53,3 ; 17,7 % des cas. Une marche aléatoire qui ne représente que 13 % de la variance des variations suffit à rendre le test aveugle une fois sur deux.

L'estimation de $(\rho, \sigma_M, \sigma_R)$ se fait par filtre de Kalman, puisque M et R sont des états cachés : ce sera l'objet du chapitre 8.

4.7 Études de cas réelles

Tableau 4.1: Tests de cointégration sur les log-prix (E6).

Test	Statistique	p-valeur	Seuil 5 %
Engle-Granger, GLD sur GLDM, constante	−0,53	0,962	−3,35
Engle-Granger, GLD sur GLDM, tendance	−22,17	< 0,001	−3,80
Johansen GLD/GLDM avec tendance, trace $r = 0$	214,4	—	18,4
Engle-Granger, KO sur PEP	−1,18	0,864	−3,35
Engle-Granger, PEP sur KO	−3,17	0,075	−3,35
Johansen KO/PEP, trace $r = 0$	9,99	—	15,49

GLD/GLDM. Les conclusions du chapitre 3 se confirment : cointégration écrasante dès qu'on autorise la tendance due à l'écart de frais, aucune sinon. Johansen, avec un terme déterministe adapté, trouve aussi une relation.

KO/PEP. Selon le sens de la régression, la p-valeur d'Engle-Granger passe de 0,864 à 0,075 : l'asymétrie du chapitre 2 se répercute sur le test. Johansen, symétrique, ne trouve pas de relation. Conclusion honnête : rien sur cette période ne justifie de traiter KO et PEP comme une paire cointégrée ; un trader qui aurait choisi le sens « PEP sur KO » parce qu'il donne la meilleure p-valeur aurait fait, sans le savoir, deux tests et retenu le meilleur.

4.8 Ce que la théorie apporte, et ses limites

Apports. La cointégration donne une justification statistique précise au *pairs trading* : un écart stationnaire entre deux prix non stationnaires. Le modèle à correction d'erreur relie l'écart à la dynamique de chaque jambe et donne sa vitesse de retour ; Johansen étend le cadre aux paniers.

Limites. (1) Les tests héritent du manque de puissance du chapitre 3 : sur deux ans, une relation réelle mais lente passe inaperçue. (2) La cointégration est une propriété « pour toujours » ; les marchés offrent au mieux des relations temporaires, d'où l'intérêt de la cointégration partielle et des modèles à paramètres variables (chapitre 8). (3) Le choix du sens, des termes déterministes et des retards multiplie les tests implicites. (4) Une relation statistique sans raison économique (même secteur, même sous-jacent, contrainte contractuelle) a peu de chances de survivre hors échantillon.

4.9 Fiche à recopier au tableau blanc

Au tableau blanc

- $I(d)$ **:** différencier d fois pour être stationnaire. Prix $\sim I(1)$.
- **Cointégration :** $x \sim I(1)$, $\beta^\top x \sim I(0)$; rang r = nombre de relations indépendantes.
- **Engle-Granger :** MCO en niveaux, puis ADF sur résidus ; seuils 5 % : $-3{,}34$ (2 var.), $-3{,}74$ (3 var.).
- **Superconvergence :** $\hat{b} - b = O(1/n)$ si la paire est cointégrée.
- **Correction d'erreur :** $\Delta x_{1t} = \alpha_1 S_{t-1} + \dots$, $\Delta x_{2t} = \alpha_2 S_{t-1} + \dots$; $\varphi_S = 1 + \alpha_1 - \beta\alpha_2$.
- **VECM :** $\Delta x_t = \Pi x_{t-1} + \sum \Gamma_i \Delta x_{t-i} + \varepsilon_t$, $\Pi = \alpha\beta^\top$, rang r.
- **Johansen :** trace $= -T \sum_{i>r} \ln(1-\hat{\lambda}_i)$; tester $r = 0, 1, \dots$
- **Cointégration partielle :** $S = M + R$; $R^2_{MR} = 2\sigma_M^2/(2\sigma_M^2 + (1+\rho)\sigma_R^2)$.

4.10 Exercices

Exercice 4.1. Montrez que si $x_t \sim I(1)$ et $y_t = 2x_t + u_t$ avec u_t stationnaire, alors $y_t \sim I(1)$ et $(1, -2)$ est un vecteur de cointégration. Le vecteur $(2, -4)$ en est-il un aussi ?

Exercice 4.2. Dans un modèle à correction d'erreur avec $\beta = 1$, $\alpha_1 = -0{,}02$ et $\alpha_2 = 0$, calculez la demi-vie de l'écart. Quelle jambe faut-il surveiller pour anticiper la fermeture de l'écart ?

Exercice 4.3. Que se passe-t-il dans la proposition 4.1 si $\alpha_1 = \beta\alpha_2$? Interprétez.

Exercice 4.4. Avec $\rho = 0{,}8$ et $\sigma_M = 1$, quelle valeur de σ_R donne $R^2_{MR} = 0{,}5$?

Exercice 4.5 (à coder)**.** Écrivez votre propre fonction `engle_granger(y, x)` qui renvoie $\hat{b}$, la statistique ADF des résidus et une décision au seuil $-3{,}34$, et comparez-la à `statsmodels.tsa.stattools.coint` sur E1 et E6.

Exercice 4.6 (à coder)**.** Estimez le VECM complet de GLD/GLDM avec `statsmodels.tsa.vector_ar.vecm.VECM`. Quelle jambe corrige l'écart ? Est-ce cohérent avec la liquidité relative des deux fonds ?

4.11 Pour aller plus loin

Pour aller plus loin — quoi lire

- Engle and Granger [15] : définition, théorème de représentation et méthode en deux étapes.
- Johansen [26] : la procédure du maximum de vraisemblance ; Hamilton [19], chapitres 19 (« Cointegration ») et 20 (« Full-Information Maximum Likelihood Analysis of Cointegrated Systems ») pour une présentation pas à pas.
- Vidyamurthy [48] : la cointégration appliquée au *pairs trading*, avec la notion de tendance commune.
- Clegg and Krauss [9] : la cointégration partielle et son estimation.
- Chan [8], chapitre 2 : Engle-Granger et Johansen sur des paires d'ETF, avec code.

4.12 Scripts du chapitre

`code/ch04/ch04_cointegration.py` : E1 (figure 4.1), E2 (superconvergence), E3 (correction d'erreur), E4 (Johansen), E5 (cointégration partielle), E6 (tableau 4.1).

CHAPITRE 5

Le processus d'Ornstein-Uhlenbeck

5.1 Objectifs et organisation du chapitre

Objectifs. Le processus d'Ornstein-Uhlenbeck (OU) est la version en temps continu de l'AR(1). Il est devenu le modèle standard de l'écart en arbitrage statistique [2, 5, 33], parce qu'il permet de calculer explicitement des durées de détention et des seuils optimaux. À la fin du chapitre, vous saurez : (1) ce qu'est un mouvement brownien et une équation différentielle stochastique ; (2) appliquer le lemme d'Itô pour résoudre l'équation d'OU ; (3) passer exactement de l'OU à l'AR(1) et inversement, et estimer les paramètres ; (4) calculer le temps moyen de retour à la moyenne par l'équation de Kolmogorov ; (5) choisir des seuils d'entrée qui maximisent le gain par unité de temps en présence de coûts.

Code. `code/ch05/ch05_ornstein_uhlenbeck.py`, expériences E1 à E5.

5.2 Mouvement brownien et équations différentielles stochastiques

5.2.1 Le mouvement brownien

Définition 5.1. Un mouvement brownien standard $(W_t)_{t\geq 0}$ est un processus en temps continu tel que $W_0 = 0$, ses trajectoires sont continues, et pour $s < t$ l'accroissement $W_t - W_s$ suit une loi $\mathcal{N}(0, t-s)$, indépendante de tout ce qui s'est passé avant s.

C'est la limite de la marche aléatoire du chapitre 1 quand on fait des pas de plus en plus petits et de plus en plus fréquents. Sur un petit intervalle $\mathrm{d}t$, l'accroissement $\mathrm{d}W_t$ est d'ordre $\sqrt{\mathrm{d}t}$ (son écart-type), et non $\mathrm{d}t$. Conséquence capitale : $(\mathrm{d}W_t)^2$, d'espérance $\mathrm{d}t$ et de variance $2\mathrm{d}t^2$, se comporte comme la quantité déterministe $\mathrm{d}t$; on écrit $(\mathrm{d}W_t)^2 = \mathrm{d}t$.

5.2.2 Équation différentielle stochastique

Une équation différentielle stochastique (EDS) décrit l'évolution infinitésimale d'un processus :

$$\mathrm{d}X_t = b(X_t)\,\mathrm{d}t + s(X_t)\,\mathrm{d}W_t,$$

où b est la *dérive* (la tendance locale) et s la *volatilité*. On la lit comme la limite de $X_{t+\Delta} - X_t \approx b(X_t)\Delta + s(X_t)\sqrt{\Delta}Z$, avec $Z \sim \mathcal{N}(0,1)$.

5.2.3 Le lemme d'Itô

Proposition 5.1 (Lemme d'Itô, forme simple)**.** *Si $\mathrm{d}X_t = b\,\mathrm{d}t + s\,\mathrm{d}W_t$ et si $f(t,x)$ est deux fois dérivable, alors*

$$\mathrm{d}f(t,X_t) = \Big(\partial_t f + b\,\partial_x f + \tfrac{1}{2}s^2\,\partial_{xx} f\Big)\mathrm{d}t + s\,\partial_x f\,\mathrm{d}W_t.$$

Idée de la démonstration. On développe f à l'ordre 2 : $\mathrm{d}f = \partial_t f\,\mathrm{d}t + \partial_x f\,\mathrm{d}X + \frac{1}{2}\partial_{xx} f\,(\mathrm{d}X)^2 + \dots$ Or $(\mathrm{d}X)^2 = b^2\mathrm{d}t^2 + 2bs\,\mathrm{d}t\,\mathrm{d}W + s^2(\mathrm{d}W)^2$; les deux premiers termes sont négligeables (d'ordre $\mathrm{d}t^{3/2}$ ou plus) et le troisième vaut $s^2\mathrm{d}t$. On remplace $\mathrm{d}X$ par $b\,\mathrm{d}t + s\,\mathrm{d}W$ et on regroupe. □

Le terme $\frac{1}{2}s^2\partial_{xx} f$ n'existe pas en calcul ordinaire : il vient de ce que le hasard brownien a une variance d'ordre $\mathrm{d}t$.

5.3 Le processus d'Ornstein-Uhlenbeck

5.3.1 Définition et solution

Définition 5.2 (Uhlenbeck and Ornstein [47])**.** Le processus d'Ornstein-Uhlenbeck est la solution de

$$\mathrm{d}X_t = \theta(\mu - X_t)\,\mathrm{d}t + \sigma\,\mathrm{d}W_t, \qquad \theta > 0,\ \sigma > 0.$$

La dérive $\theta(\mu - X_t)$ tire le processus vers μ avec une force proportionnelle à l'écart : c'est l'élastique du chapitre 1, en temps continu. θ est la *vitesse de retour*, μ le niveau d'équilibre, σ la volatilité instantanée.

Proposition 5.2. *La solution vaut*

$$X_t = \mu + (X_0 - \mu)e^{-\theta t} + \sigma \int_0^t e^{-\theta(t-u)}\, \mathrm{d}W_u,$$

de sorte que, sachant X_0, X_t suit une loi normale de moyenne $\mu + (X_0 - \mu)e^{-\theta t}$ et de variance $\frac{\sigma^2}{2\theta}\big(1 - e^{-2\theta t}\big)$.

Démonstration. On applique le lemme d'Itô à $f(t,x) = e^{\theta t}x$: $\partial_t f = \theta e^{\theta t}x$, $\partial_x f = e^{\theta t}$, $\partial_{xx} f = 0$. Donc

$$\mathrm{d}(e^{\theta t}X_t) = \big(\theta e^{\theta t}X_t + \theta(\mu - X_t)e^{\theta t}\big)\mathrm{d}t + \sigma e^{\theta t}\mathrm{d}W_t = \theta\mu\, e^{\theta t}\mathrm{d}t + \sigma e^{\theta t}\mathrm{d}W_t.$$

Les termes en X_t se sont annulés. On intègre de 0 à t : $e^{\theta t}X_t - X_0 = \mu(e^{\theta t} - 1) + \sigma\int_0^t e^{\theta u}\mathrm{d}W_u$, puis on multiplie par $e^{-\theta t}$. L'intégrale stochastique a une espérance nulle ; sa variance vaut, par la propriété d'isométrie (la variance d'une intégrale brownienne est l'intégrale du carré de l'intégrande), $\sigma^2\int_0^t e^{-2\theta(t-u)}\mathrm{d}u = \frac{\sigma^2}{2\theta}(1 - e^{-2\theta t})$. □

Conséquences. Quand $t \to \infty$, la loi de X_t tend vers la loi stationnaire $\mathcal{N}\big(\mu, \sigma^2/(2\theta)\big)$. L'écart-type stationnaire $\sigma_{eq} = \sigma/\sqrt{2\theta}$ est l'unité naturelle pour placer les seuils de trading. L'écart espéré à la moyenne est divisé par deux en

$$h_{1/2} = \frac{\ln 2}{\theta}.$$

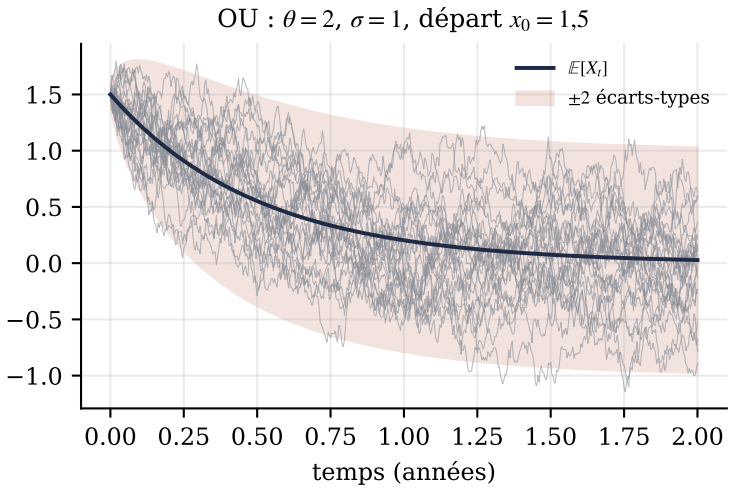


Figure 5.1: Trajectoires d'un OU partant de $x_0 = 1{,}5$: la moyenne décroît exponentiellement vers 0 et la dispersion converge vers $\pm 2\sigma_{eq}$.

5.3.2 De l'OU à l'AR(1), exactement

En observant le processus à intervalles réguliers Δ (un jour, $\Delta = 1/252$ an), la proposition 5.2 appliquée entre t et $t + \Delta$ donne exactement

$$X_{t+\Delta} = \mu + e^{-\theta\Delta}(X_t - \mu) + \eta_t, \qquad \eta_t \sim \mathcal{N}\Big(0,\ \frac{\sigma^2}{2\theta}\big(1 - e^{-2\theta\Delta}\big)\Big),$$

c'est-à-dire un AR(1) avec

$$\varphi = e^{-\theta\Delta}, \qquad \sigma_\eta^2 = \frac{\sigma^2}{2\theta}(1 - \varphi^2).$$

Inversement, une estimation $\hat\varphi$ de l'AR(1) donne $\hat\theta = -\ln\hat\varphi/\Delta$ et $\hat\sigma = \hat\sigma_\eta\sqrt{2\hat\theta/(1-\hat\varphi^2)}$. Le schéma d'Euler, $X_{t+\Delta} = X_t + \theta(\mu - X_t)\Delta + \sigma\sqrt{\Delta}Z$, n'est qu'une approximation : il remplace $e^{-\theta\Delta}$ par $1 - \theta\Delta$.

Vérification en Python — E1, discrétisation exacte contre Euler

Protocole : $\theta = 2$ (demi-vie de 0,35 an), $\sigma = 1$, variance stationnaire théorique 0,25. **Résultats :** pas quotidien ($\Delta = 1/252$) : les deux schémas donnent une autocorrélation de 0,992, identique à la théorie. Pas mensuel : exact 0,846 (théorie 0,847), Euler 0,830 ; variance Euler 0,273. Pas trimestriel : exact 0,610 (théorie 0,607), Euler 0,505 ; variance Euler 0,324, soit 30 % de trop. **Leçon :** simulez toujours avec la discrétisation exacte, qui est aussi simple à coder.

5.3.3 Estimation

Vérification en Python — E2, estimation des paramètres

Protocole : $\theta = 5$ (demi-vie de 35 jours), $\mu = 1$, $\sigma = 0{,}5$; 500 trajectoires quotidiennes par durée. **Résultats** (médiane et intervalle 5–95 % de $\hat{\theta}$) : 1 an : 8,65 [2,8 ; 20,6] ; 4 ans : 5,81 [3,4 ; 9,8] ; 16 ans : 5,22 [4,0 ; 6,8]. $\hat{\sigma}$ est très précis dès un an (médiane 0,504), $\hat{\mu}$ l'est beaucoup moins (écart-type 0,12 sur un an pour un écart-type stationnaire de 0,16).

Piège / limite

Sur un an, la vitesse de retour est surestimée de 70 % en médiane, ce qui divise la demi-vie apparente presque par deux : c'est le biais de Kendall du chapitre 2, traduit en temps continu. La moyenne μ est elle aussi mal connue, alors que tous les seuils de trading sont placés autour d'elle. La volatilité, elle, est bien estimée : c'est le paramètre le plus fiable et le moins important pour la décision.

5.4 Combien de temps pour revenir ? Les temps de premier passage

5.4.1 L'équation de Kolmogorov

Notons $u(x)$ le temps moyen que met le processus, parti de x, pour atteindre un niveau cible. Pendant un court instant $\mathrm{d}t$, il s'écoule $\mathrm{d}t$ et le processus passe de x à $x + \mathrm{d}X$; ensuite, il reste en moyenne $u(x + \mathrm{d}X)$:

$$u(x) = \mathrm{d}t + \mathbb{E}\big[u(x + \mathrm{d}X)\big].$$

On développe u à l'ordre 2 et l'on utilise $\mathbb{E}[\mathrm{d}X] = b(x)\mathrm{d}t$ et $\mathbb{E}[(\mathrm{d}X)^2] = s(x)^2\mathrm{d}t$:

$$u(x) = \mathrm{d}t + u(x) + b(x)u'(x)\mathrm{d}t + \tfrac{1}{2}s(x)^2u''(x)\mathrm{d}t \quad \Longrightarrow \quad \tfrac{1}{2}s(x)^2u''(x) + b(x)u'(x) = -1.$$

C'est l'équation de Kolmogorov rétrograde pour les temps moyens de sortie.

5.4.2 Résolution pour l'OU

Prenons $\mu = 0$ (on mesure l'écart à la moyenne), $b(x) = -\theta x$, $s = \sigma$, et posons $k = \theta/\sigma^2$, $v = u'$. L'équation devient $\frac{\sigma^2}{2}v' - \theta x v = -1$. En multipliant par le facteur intégrant $\frac{2}{\sigma^2}e^{-kx^2}$, le membre de gauche devient une dérivée exacte :

$$\frac{\mathrm{d}}{\mathrm{d}x}\Big(v(x)\,e^{-kx^2}\Big) = -\frac{2}{\sigma^2}e^{-kx^2}.$$

Proposition 5.3 (Temps moyens de passage de l'OU)**.** *Avec $k = \theta/\sigma^2$ et un seuil $a > 0$:*

$$\textit{(retour)} \quad T_{a\to 0} = \frac{2}{\sigma^2}\int_0^a e^{ky^2}\Big(\int_y^{\infty} e^{-kz^2}\mathrm{d}z\Big)\mathrm{d}y,$$

$$\textit{(attente)} \quad T_{0\to\pm a} = \frac{2}{\sigma^2}\int_0^a e^{ky^2}\Big(\int_0^{y} e^{-kz^2}\mathrm{d}z\Big)\mathrm{d}y,$$

où $T_{a\to 0}$ est le temps moyen pour revenir de a à la moyenne, et $T_{0\to\pm a}$ celui pour s'écarter de la moyenne jusqu'à $|x| = a$.

Démonstration. Retour. La cible est 0 et le processus part de $x > 0$; loin vers le haut, la force de rappel est énorme, ce qui impose $v(x)e^{-kx^2} \to 0$ quand $x \to \infty$. On intègre l'équation entre y et $+\infty$: $0 - v(y)e^{-ky^2} = -\frac{2}{\sigma^2}\int_y^{\infty} e^{-kz^2}\mathrm{d}z$, d'où $v(y)$. Comme $u(0) = 0$ (on est déjà arrivé), $u(a) = \int_0^a v(y)\,\mathrm{d}y$.

Attente. Les cibles sont $\pm a$ et le départ est 0 ; par symétrie $u'(0) = 0$. On intègre entre 0 et y : $v(y)e^{-ky^2} = -\frac{2}{\sigma^2}\int_0^y e^{-kz^2}\mathrm{d}z$. Comme $u(a) = 0$, $u(0) = u(a) - \int_0^a v(y)\mathrm{d}y$, ce qui donne la formule. □

Les intégrales intérieures s'écrivent avec la fonction d'erreur ($\int_0^y e^{-kz^2}\mathrm{d}z = \frac{1}{2}\sqrt{\pi/k}\,\mathrm{erf}(\sqrt{k}\,y)$), et l'intégrale extérieure se calcule numériquement.

Vérification en Python — E3, temps de passage : formule contre simulation

Protocole : $\theta = \sigma = 1$, 4 000 trajectoires au pas 10^{-3} par seuil. **Résultats** (seuils en écarts-types stationnaires) :

a/σ_{eq}	$T_{a\to 0}$ formule	simulé	$T_{0\to\pm a}$ formule	simulé
0,5	0,523	0,546	0,130	0,146
1,0	0,902	0,951	0,596	0,637
1,5	1,192	1,233	1,711	1,789
2,0	1,425	1,468	4,502	4,726

Les temps simulés sont 3 à 10 % plus longs : en temps discret, on ne voit le franchissement qu'au pas suivant (biais de surveillance discrète, d'ordre $\sqrt{\Delta}$).

Lecture. Revenir d'un écart de $2\sigma_{eq}$ prend environ $1{,}4/\theta$, soit deux demi-vies ; mais *attendre* un écart de $2\sigma_{eq}$ prend $4{,}5/\theta$, trois fois plus. Les seuils larges font de bons trades, mais rares.

5.5 Seuils de trading optimaux

5.5.1 Le problème

Considérons la stratégie symétrique : on attend que l'écart atteigne $\pm a$, on prend la position opposée, et on la ferme quand l'écart revient à la moyenne. Chaque cycle rapporte a (en unités d'écart) moins un coût c par aller-retour, et dure en moyenne $T_{0\to\pm a} + T_{a\to 0}$. Par la loi des grands nombres, le gain moyen par unité de temps est

$$G(a) = \frac{a - c}{T_{0\to\pm a}(a) + T_{a\to 0}(a)}.$$

Bertram [5] étudie ce critère et sa version ajustée du risque ; Leung and Li [32] traitent le problème comme un double arrêt optimal (quand entrer, puis quand sortir) avec coûts et stop-loss.

Image mentale

Un seuil bas fait beaucoup de petits trades ; un seuil haut fait peu de gros trades. Sans coûts, rien n'empêche de trader de minuscules écarts en continu. Avec des coûts, chaque trade doit d'abord rembourser son ticket d'entrée : le seuil optimal monte avec les coûts.

Vérification en Python — E4, seuil optimal

Résultats ($\theta = \sigma = 1$, seuils et coûts en écarts-types stationnaires) : sans coût, le gain par unité de temps est maximal pour un seuil qui tend vers 0, artefact du temps continu. Avec un coût de 0,1 : seuil optimal 0,69 ; coût 0,25 : 0,97 ; coût 0,5 : 1,26 (figure 5.2). **Vérification en temps quotidien** (demi-vie de 14 jours, 400 ans simulés) : avec un coût de 0,25, gain annuel simulé de 6,5 et 5,0 écarts-types pour $a = 1$ et 1,5, contre 6,3 et 5,4 par la formule. Pour les petits seuils, la simulation gagne nettement plus que la formule (5,9 contre 0 pour $a = c = 0{,}25$) : en temps discret, la clôture dépasse souvent le seuil, ce qui « offre » un meilleur prix d'entrée et de sortie.

Piège / limite

Le gain « offert » par le dépassement en temps discret est une illusion de *backtest* si, dans la réalité, on exécute par ordres limites au seuil (on n'obtient jamais mieux que le seuil, et l'on n'est exécuté que quand le prix traverse, souvent au pire moment : chapitre 15) ou si l'on exécute au marché le lendemain (on paie le retour partiel). Un *backtest* de *pairs trading* au prix de clôture surestime systématiquement les stratégies à seuils serrés.

5.5.2 Seuils et incertitude sur les paramètres

Le seuil optimal dépend de θ, μ et σ. Or E2 a montré que θ est surestimé et que μ est mal connu sur un an. Un seuil optimisé sur des paramètres estimés est donc lui-même incertain, et généralement trop serré (car θ surestimé fait croire que les cycles sont plus courts). En pratique : corriger le biais de $\hat{\theta}$, élargir légèrement les seuils et vérifier la robustesse sur une plage de paramètres plutôt qu'en un point.

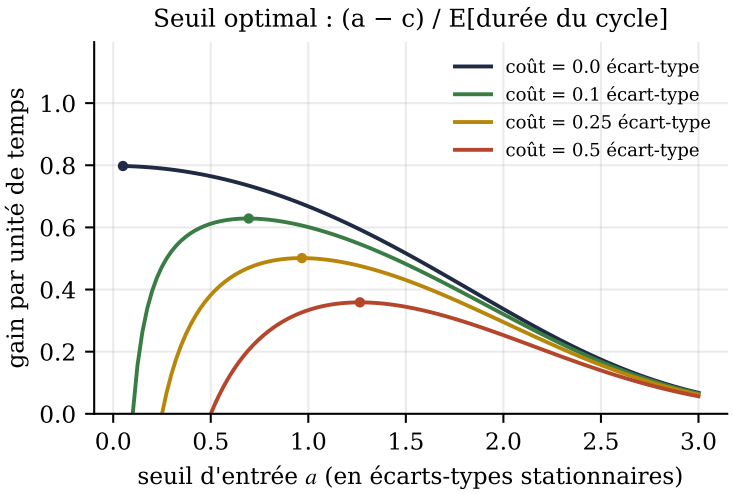


Figure 5.2: Gain par unité de temps en fonction du seuil d'entrée pour quatre niveaux de coût. Le point marque l'optimum.

5.6 Étude de cas : l'écart GLD/GLDM

Sur l'écart GLD/GLDM sans tendance (chapitre 3), $\hat{\varphi} = 0{,}011$ à l'échelle quotidienne : un OU avec $\theta\Delta = -\ln 0{,}011 \approx 4{,}5$, c'est-à-dire une demi-vie d'environ 0,15 jour, soit une heure de bourse. À l'échelle quotidienne, l'écart (écart-type 4,5 pb) est indiscernable d'un bruit blanc. La modélisation OU n'a d'intérêt que si l'on observe le processus à une fréquence comparable à sa demi-vie : pour cet écart, des données intrajournalières seraient indispensables.

5.7 Ce que la théorie apporte, et ses limites

Apports. Un modèle à trois paramètres interprétables (θ, μ, σ), une correspondance exacte avec l'AR(1) à toute fréquence, des formules de durée de détention et un critère explicite pour choisir les seuils en fonction des coûts.

Limites. (1) Les chocs browniens sont gaussiens ; les écarts réels ont des queues épaisses et des sauts (annonces de résultats, dividendes). (2) Les paramètres sont supposés constants. (3) Le critère « gain par unité de temps » ignore le risque : un seuil qui maximise l'espérance peut avoir une variance déplaisante ; il ignore aussi le capital immobilisé et la marge. (4) La surveillance discrète, l'exécution et les coûts réels changent les résultats, surtout pour les seuils serrés.

5.8 Fiche à recopier au tableau blanc

Au tableau blanc

- **Brownien :** $W_t - W_s \sim \mathcal{N}(0, t-s)$, $(\mathrm{d}W)^2 = \mathrm{d}t$.
- **Itô :** $\mathrm{d}f = (\partial_t f + b\,\partial_x f + \frac{1}{2}s^2\partial_{xx} f)\mathrm{d}t + s\,\partial_x f\,\mathrm{d}W$.
- **OU :** $\mathrm{d}X = \theta(\mu - X)\mathrm{d}t + \sigma\mathrm{d}W$; $X_t = \mu + (X_0 - \mu)e^{-\theta t} + \sigma\int_0^t e^{-\theta(t-u)}\mathrm{d}W_u$.
- **Moments :** moyenne $\mu + (X_0 - \mu)e^{-\theta t}$; variance $\frac{\sigma^2}{2\theta}(1 - e^{-2\theta t})$; $\sigma_{eq} = \sigma/\sqrt{2\theta}$; $h_{1/2} = \ln 2/\theta$.
- **OU $\leftrightarrow$ AR(1) :** $\varphi = e^{-\theta\Delta}$, $\sigma_\eta^2 = \frac{\sigma^2}{2\theta}(1 - \varphi^2)$; $\hat{\theta} = -\ln\hat{\varphi}/\Delta$.
- **Kolmogorov :** $\frac{1}{2}s^2 u'' + bu' = -1$.
- **Retour :** $T_{a\to 0} = \frac{2}{\sigma^2}\int_0^a e^{ky^2}\int_y^\infty e^{-kz^2}\mathrm{d}z\,\mathrm{d}y$, $k = \theta/\sigma^2$.
- **Seuil optimal :** maximiser $(a-c)/(T_{0\to\pm a} + T_{a\to 0})$; le seuil monte avec les coûts.

5.9 Exercices

Exercice 5.1. Appliquez le lemme d'Itô à $f(x) = x^2$ pour un mouvement brownien $X = W$. Déduisez-en $\mathbb{E}[W_t^2] = t$.

Exercice 5.2. Un écart quotidien a $\hat{\varphi} = 0{,}96$ et un écart-type des résidus de 0,5 %. Calculez θ (par an), la demi-vie en jours et l'écart-type stationnaire.

Exercice 5.3. Montrez, en dérivant l'intégrale de la proposition 5.3, que pour un petit seuil a, $T_{a\to 0} \approx a\sqrt{\pi/\theta}/\sigma$. Pourquoi ce temps tend-il vers 0 avec a alors que celui d'un mouvement brownien sans dérive serait infini en moyenne ?

Exercice 5.4 (à coder)**.** Ajoutez à E4 un stop-loss : on ferme à perte si l'écart atteint $\pm L$ avec $L > a$. Comment le seuil optimal et le gain changent-ils pour $L = 3\sigma_{eq}$? Comparez à Leung and Li [32].

Exercice 5.5 (à coder)**.** Reprenez E2 avec la correction de Kendall appliquée à $\hat{\varphi}$ avant de calculer $\hat{\theta}$. Quel est le nouveau biais médian sur un an ?

5.10 Pour aller plus loin

Pour aller plus loin — quoi lire

- Uhlenbeck and Ornstein [47] : l'article original, en physique.
- Bertram [5] : expressions analytiques du gain et de la durée des cycles, et seuils optimaux.
- Leung and Li [32] et les premiers chapitres du livre Leung and Li [33] : entrée et sortie optimales avec coûts et stop-loss.
- Avellaneda and Lee [2], l'annexe sur l'estimation des paramètres OU à partir d'une régression AR(1), reprise au chapitre 10.

5.11 Scripts du chapitre

`code/ch05/ch05_ornstein_uhlenbeck.py` : E1 (figure 5.1), E2, E3, E4 (figure 5.2), E5.

PARTIE II

Les méthodes de pairs trading

CHAPITRE 6

La méthode des distances

6.1 Objectifs et organisation du chapitre

Objectifs. La méthode des distances de Gatev et al. [16] est la référence empirique du *pairs trading* : simple, non paramétrique, et testée sur quarante ans de données. À la fin du chapitre, vous saurez : (1) répliquer exactement le protocole de Gatev, Goetzmann et Rouwenhorst (GGR) ; (2) calculer correctement les rendements d'une stratégie de paires (capital engagé, capital employé) ; (3) expliquer pourquoi le critère de sélection par distance est imparfait ; (4) mesurer l'effet des coûts et du nombre de paires ; (5) interpréter les résultats de la littérature qui a suivi.

Code. `code/ch06/ch06_distance_method.py` et l'univers simulé `code/common/universe.py`.

6.2 Le protocole de Gatev, Goetzmann et Rouwenhorst

6.2.1 Formation

Sur une *période de formation* de douze mois, on calcule pour chaque action i un indice de rendement total normalisé à 1 au premier jour, $\tilde{P}_{i,t} = P_{i,t}/P_{i,0}$ (dividendes réinvestis). Pour chaque paire (i, j), on calcule la somme des écarts quadratiques

$$\mathrm{SSD}_{ij} = \sum_{t=1}^{T_f} \left(\tilde{P}_{i,t} - \tilde{P}_{j,t}\right)^2,$$

et l'on retient les 20 paires de plus petite SSD : celles dont les trajectoires normalisées se sont le plus suivies. On note aussi l'écart-type $\hat{\sigma}_{ij}$ de l'écart $\tilde{P}_i - \tilde{P}_j$ sur la formation.

Calcul efficace. Pour N actions il y a $N(N-1)/2$ paires (4 950 pour 100 actions). En notant $\tilde{P}$ la matrice $T_f \times N$, $\mathrm{SSD}_{ij} = \|\tilde{P}_i\|^2 + \|\tilde{P}_j\|^2 - 2\tilde{P}_i^\top \tilde{P}_j$: toutes les distances s'obtiennent par un seul produit matriciel $\tilde{P}^\top \tilde{P}$.

6.2.2 Trading

Pendant les six mois suivants, les prix sont renormalisés à 1 au début de la période. Pour chaque paire retenue :

- on **ouvre** une position quand l'écart normalisé dépasse $2\hat{\sigma}_{ij}$: achat d'un dollar de l'action relativement bon marché, vente à découvert d'un dollar de l'action relativement chère ;
- on **ferme** quand les prix normalisés se recroisent, ou à la fin de la période ;
- la paire peut rouvrir plusieurs fois.

GGR décalent l'exécution d'un jour (signal à la clôture t, exécution à la clôture $t+1$) pour neutraliser l'effet du rebond entre prix acheteur et vendeur, et montrent que ce décalage réduit les profits.

6.2.3 Mesurer le rendement

Une position longue d'un dollar et courte d'un dollar ne coûte rien (en théorie) : le « rendement » d'une paire n'a de sens que rapporté à un capital conventionnel. GGR proposent deux mesures :

- **capital engagé** : somme des gains des 20 paires divisée par 20, que les paires aient tradé ou non. C'est la mesure prudente, celle d'un gestionnaire qui réserve un dollar par paire ;
- **capital employé** : somme des gains divisée par le nombre de paires qui ont effectivement ouvert une position.

Le gain d'une position ouverte en t_0 et fermée en t_1 vaut $\left(P^L_{t_1}/P^L_{t_0} - 1\right) - \left(P^C_{t_1}/P^C_{t_0} - 1\right)$, où L est la jambe longue et C la jambe courte.

Image mentale

La SSD cherche deux voitures qui ont roulé côte à côte pendant un an. Pendant les six mois suivants, si l'une prend de l'avance, on parie qu'elles vont se retrouver. Le pari est bon si elles roulent vraiment ensemble (même route, même destination) ; il est mauvais si elles se sont seulement trouvées côte à côte par hasard.

6.3 Ce que dit la littérature

Sur les actions américaines de 1962 à 2002, GGR obtiennent pour les 20 meilleures paires des rendements excédentaires annualisés pouvant atteindre de l'ordre de 11 % selon la mesure de capital retenue, avec une faible exposition aux facteurs de risque usuels. Do and Faff [12] montrent que ces profits baissent fortement à partir des années 1990, tout en restant positifs dans les périodes de crise (quand la dispersion entre actions augmente). Do and Faff [13] ajoutent des coûts de transaction réalistes (commissions, impact, coût d'emprunt des titres) : la stratégie de base devient à peine rentable, et seule une sélection plus fine (même sous-secteur, nombre de croisements élevé pendant la formation) préserve un profit. Rad et al. [42] confirment, avec un protocole identique pour trois méthodes, une baisse de rentabilité dans la période récente.

6.4 Réplication sur un univers simulé

6.4.1 L'univers

Pour savoir si la méthode trouve les « bonnes » paires, il faut connaître la vérité. L'univers simulé contient 100 actions réparties en 5 secteurs ; chaque log-prix est la somme d'un facteur de marché, d'un facteur sectoriel et d'une composante propre. Dans chaque secteur, deux paires sont *jumelles* : leurs deux actions partagent la même composante propre de long terme et ne diffèrent que par un écart AR(1) stationnaire ($\varphi = 0{,}95$, écart-type stationnaire d'environ 1,3 %). Il y a donc exactement 10 paires cointégrées parmi 4 950. Six univers de 1 764 jours donnent 72 semestres de trading.

Vérification en Python — E1 à E3, protocole GGR simulé

Sélection : en moyenne, 49,9 % des 20 paires retenues sont de vraies paires, soit la quasi-totalité des 10 existantes ; les 10 autres sont des paires d'actions du même secteur qui se sont suivies par hasard. 17,7 paires sur 20 ouvrent au moins une position. **Gain par paire et par semestre :** +2,10 % pour une vraie paire, −1,17 % pour une fausse. **Portefeuille de 20 paires, capital engagé** (annualisé) : 0,93 % sans coût ; 0,35 % à 5 pb par jambe ; −0,22 % à 10 pb ; −1,36 % à 20 pb. **Nombre de paires** (coût de 5 pb) : 5 paires, 4,1 % ; 10 paires, 3,7 % ; 20 paires, 0,35 % ; 50 paires, −1,1 %.

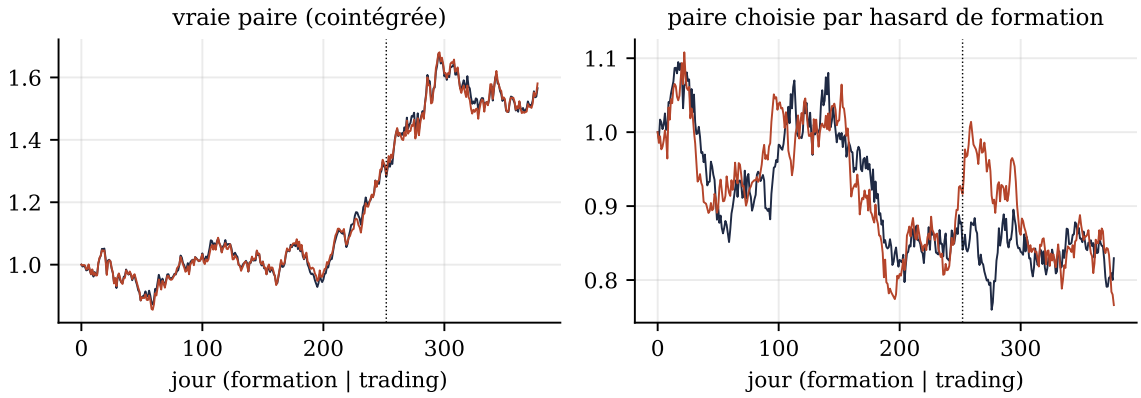


Figure 6.1: Deux paires du top 20 d'une même formation. À gauche, une vraie paire : les trajectoires restent liées après la formation (ligne pointillée). À droite, une paire retenue parce qu'elle s'est suivie par hasard pendant la formation : elle diverge ensuite.

Ce que montrent les chiffres. (1) La SSD classe bien les vraies paires en tête, mais le portefeuille de 20 paires dilue leur profit avec celui de paires fictives qui perdent de l'argent ; c'est pourquoi les 5 ou 10 premières paires font beaucoup mieux que les 20. (2) Les coûts détruisent vite un avantage de quelques dixièmes de pour cent par semestre : à 10 pb par jambe, la stratégie perd de l'argent. (3) Même sans coûts, un tiers des semestres sont perdants.

6.5 Pourquoi la SSD est un critère imparfait

Développons la SSD. En notant $D_t = \tilde{P}_{i,t} - \tilde{P}_{j,t}$ et $\bar{D}$ sa moyenne sur la formation,

$$\frac{1}{T_f}\mathrm{SSD}_{ij} = \frac{1}{T_f}\sum_t D_t^2 = \bar{D}^2 + \widehat{\mathrm{Var}}(D).$$

Minimiser la SSD revient donc à choisir des paires dont l'écart est petit en moyenne *et peu variable*. Or un *pairs trade* gagne à chaque aller-retour environ deux écarts-types de l'écart (chapitre 1) : une paire à l'écart très peu variable gagne très peu par trade et peine à couvrir ses coûts. La paire idéale a au contraire un écart *ample* et qui revient *vite* à la moyenne : la SSD ne mesure ni l'un ni l'autre [29].

Piège / limite

La SSD minimale est atteinte par deux actions identiques, par exemple deux lignes de cotation de la même société, ou deux ETF sur le même indice : l'écart est nul, il n'y a rien à gagner. À l'inverse, deux actions qui oscillent fortement l'une autour de l'autre (très bon candidat) ont une SSD plus élevée et peuvent être écartées. Le critère de sélection et le critère de profit ne sont pas les mêmes.

Améliorations proposées. Restreindre la recherche au même secteur ou sous-secteur [13] ; exiger un nombre minimal de croisements de l'écart pendant la formation (indicateur direct de retour à la moyenne) ; combiner distance et test de cointégration [23, 42] ; normaliser l'écart par sa volatilité, ce qui conduit au *z-score* du chapitre 1.

6.6 Études de cas réelles

On applique la règle GGR à nos deux paires réelles : formation sur les 252 premières séances, trading sur les 248 suivantes.

Vérification en Python — E4, règle GGR sur données réelles

KO/PEP : l'écart normalisé a déjà un écart-type de 9,6 % pendant la formation (les deux titres ont divergé). Une seule position est ouverte pendant la période de trading et ne se referme jamais : perte de 24,1 % avant coûts. **GLD/GLDM :** écart-type de formation de 0,135 % ; une position, gain brut nul (−0,01 %), −0,21 % après coûts de 5 pb par jambe.

Lecture. KO/PEP illustre le risque central de la méthode : une paire qui ne revient pas, gardée jusqu'à la fin de la période faute de stop-loss. GLD/GLDM illustre l'autre extrême : un écart si petit qu'aucun trade ne couvre ses coûts. Ces deux cas sont les deux faces du problème décrit à la section précédente.

6.7 Ce que la théorie apporte, et ses limites

Apports. Un protocole simple et reproductible, une référence pour comparer toutes les autres méthodes, une définition claire du rendement d'une stratégie autofinancée, et la preuve historique qu'un avantage a existé.

Limites. Pas de modèle de l'écart, donc pas de demi-vie ni de seuil optimal ; ratio de couverture implicite de 1 dollar contre 1 dollar, sans justification statistique ; sélection biaisée vers les écarts peu volatils ; profits historiques en déclin et très sensibles aux coûts, au coût d'emprunt et au décalage d'exécution.

6.8 Fiche à recopier au tableau blanc

Au tableau blanc

- **Formation 12 mois :** $\tilde{P}_{i,t} = P_{i,t}/P_{i,0}$, $\mathrm{SSD}_{ij} = \sum_t (\tilde{P}_{i,t} - \tilde{P}_{j,t})^2$, top 20 paires.
- **Calcul matriciel :** $\mathrm{SSD} = \mathrm{diag}(G)\mathbf{1}^\top + \mathbf{1}\mathrm{diag}(G)^\top - 2G$, $G = \tilde{P}^\top \tilde{P}$.
- **Trading 6 mois :** ouvrir à $|D_t| > 2\hat{\sigma}$ (1 \$ long / 1 \$ court), fermer au croisement.
- **Gain d'un trade :** $(P^L_{t_1}/P^L_{t_0} - 1) - (P^C_{t_1}/P^C_{t_0} - 1)$.
- **Capital engagé :** somme des gains / 20 ; **employé :** / nombre de paires ouvertes.
- **Biais de la SSD :** $\mathrm{SSD}/T = \bar{D}^2 + \widehat{\mathrm{Var}}(D)$: favorise les écarts peu volatils.

6.9 Exercices

Exercice 6.1. Démontrez l'identité $\frac{1}{T}\sum_t D_t^2 = \bar{D}^2 + \widehat{\mathrm{Var}}(D)$ (avec la variance empirique divisée par T).

Exercice 6.2. Une paire a un écart de formation d'écart-type 1 %. Les coûts sont de 5 pb par jambe et par transaction. Quel gain minimal (en écarts-types) doit capturer un aller-retour pour être rentable ?

Exercice 6.3 (à coder)**.** Ajoutez à `trade_pair` un décalage d'exécution d'un jour (signal en t, exécution en $t+1$) et un stop-loss à $4\hat{\sigma}$. Mesurez l'effet de chacun sur les vraies et les fausses paires.

Exercice 6.4 (à coder)**.** Remplacez le critère SSD par : SSD minimale *parmi les paires du même secteur ayant au moins 8 croisements pendant la formation*. La part de vraies paires dans le top 20 augmente-t-elle ? Et le rendement ?

6.10 Pour aller plus loin

Pour aller plus loin — quoi lire

- Gatev et al. [16] : la section sur la méthodologie (formation, trading, calcul des rendements) et les tests de robustesse au décalage d'exécution.
- Do and Faff [12, 13] : l'évolution des profits dans le temps et l'effet des coûts.
- Krauss [29], la partie consacrée à l'approche par distance : synthèse des variantes et de leurs critiques.

6.11 Scripts du chapitre

`code/ch06/ch06_distance_method.py` : E1–E3 (protocole GGR simulé, figure 6.1), E4 (données réelles). Univers : `code/common/universe.py`.

CHAPITRE 7

Cointégration appliquée : sélectionner les paires sans se mentir

7.1 Objectifs et organisation du chapitre

Objectifs. Le chapitre 4 a donné les tests de cointégration pour *une* paire. En pratique, on teste des centaines ou des milliers de paires candidates, et c'est là que la plupart des stratégies échouent : on retient surtout des faux positifs. À la fin de ce chapitre, vous saurez : (1) quantifier le nombre de faux positifs d'une recherche de paires ; (2) appliquer les corrections de Bonferroni et de Benjamini-Hochberg ; (3) construire un pipeline de sélection qui combine a priori économique, test statistique et filtres de dynamique [23, 29, 48] ; (4) mesurer la performance hors échantillon des paires retenues ; (5) choisir entre ratio de couverture statique et glissant.

Code. `code/ch07/ch07_cointegration_selection.py`, univers `code/common/universe.py`.

7.2 Le problème des tests multiples

7.2.1 Combien de faux positifs ?

Avec N actions, il y a $m = N(N-1)/2$ paires. Si l'on teste chacune au seuil α et qu'aucune n'est cointégrée, le nombre de rejets suit à peu près une loi binomiale de paramètres (m, α) : on attend $m\alpha$ faux positifs. Pour $N = 100$, $m = 4\,950$ et $\alpha = 5\,\%$, cela fait environ 250 « paires cointégrées » purement fortuites.

Image mentale

Lancez 4 950 pièces de monnaie dix fois chacune : quelques-unes tomberont huit ou neuf fois sur pile. Ce ne sont pas des pièces truquées, ce sont les plus chanceuses. Si vous les « sélectionnez » pour les relancer, elles retomberont à la moyenne. Une paire qui a passé le test par chance se comporte de même hors échantillon.

7.2.2 Deux façons de contrôler l'erreur

Définition 7.1. Parmi m tests, on note V le nombre de faux positifs (hypothèses nulles vraies rejetées) et R le nombre total de rejets.

- Le *taux d'erreur par famille* (FWER) est $\mathbb{P}(V \geq 1)$: la probabilité de commettre au moins une fausse découverte.
- Le *taux de fausses découvertes* (FDR) est $\mathbb{E}[V / \max(R, 1)]$: la proportion attendue de fausses découvertes parmi les découvertes.

Proposition 7.1 (Bonferroni)**.** *Si l'on rejette chaque hypothèse dont la p-valeur est inférieure à α/m, alors* FWER $\leq \alpha$*, quelle que soit la dépendance entre les tests.*

Démonstration. Soit I_0 l'ensemble des hypothèses nulles vraies, de taille $m_0 \leq m$. Sous une hypothèse nulle vraie, $\mathbb{P}(p_i \leq \alpha/m) \leq \alpha/m$ (propriété d'une p-valeur valide). Par l'inégalité de la réunion, $\mathbb{P}(V \geq 1) = \mathbb{P}\big(\bigcup_{i \in I_0} \{p_i \leq \alpha/m\}\big) \leq \sum_{i \in I_0} \alpha/m = m_0 \alpha/m \leq \alpha$. □

Bonferroni est très conservateur : avec 4 950 tests, il exige $p < 10^{-5}$. La procédure de Benjamini-Hochberg contrôle plutôt la proportion de fausses découvertes, ce qui convient mieux à une recherche de paires (on accepte quelques erreurs si la plupart des paires retenues sont bonnes).

Procédure de Benjamini-Hochberg (BH). On ordonne les p-valeurs $p_{(1)} \leq p_{(2)} \leq \cdots \leq p_{(m)}$, on cherche le plus grand k tel que $p_{(k)} \leq kq/m$, et l'on rejette les k hypothèses correspondantes. Sous indépendance des tests (ou une forme de dépendance positive), cette procédure garantit FDR $\leq q$.

Piège / limite

Les tests de cointégration d'un même univers sont fortement dépendants : deux paires qui partagent une action, ou deux actions du même secteur, ont des statistiques corrélées. Les garanties théoriques de BH ne sont alors qu'approximatives. Surtout, *toute* la recherche compte : si vous avez essayé trois fenêtres, deux sens de régression et deux spécifications de tendance, vous avez fait douze fois plus de tests que vous ne le pensez.

7.3 Un pipeline de sélection

La littérature et la pratique convergent vers une sélection en plusieurs filtres, du moins coûteux au plus exigeant :

1. **A priori économique.** Restreindre les candidats aux actifs qui ont une raison de rester liés : même secteur ou sous-secteur, même sous-jacent, relation contractuelle (ETF et panier, deux catégories d'actions d'une même société). Cela réduit m d'un facteur 5 à 50 et élimine les relations purement fortuites.
2. **Test de cointégration** (Engle-Granger dans les deux sens, ou Johansen), avec correction des tests multiples.
3. **Filtres de dynamique.** Demi-vie dans une plage exploitable (assez courte pour trader, assez longue pour couvrir les coûts) ; amplitude de l'écart suffisante par rapport aux coûts (chapitre 5) ; nombre de croisements de la moyenne.
4. **Stabilité.** La relation est-elle détectée sur plusieurs sous-périodes ? Le ratio de couverture est-il stable ?
5. **Contraintes pratiques.** Liquidité des deux jambes, disponibilité et coût de l'emprunt de titres pour la vente à découvert, frais.

7.4 Expérience : 4 950 paires, 10 vraies

On reprend l'univers simulé du chapitre 6 (100 actions, 5 secteurs, 10 paires réellement cointégrées) avec une formation de 500 jours et un trading hors échantillon de 250 jours (règle *z-score* du chapitre 1, entrée à ± 2, sortie à 0, coûts de 5 pb par jambe). On distingue trois sortes de paires : les *vraies* paires ; les paires *partiellement liées*, dont une jambe appartient à une vraie paire (leur écart contient la moitié de l'écart stationnaire de la vraie paire, comme dans la cointégration partielle du chapitre 4) ; les paires *sans lien*, dont l'écart est une martingale. Deux scénarios : vraies paires de demi-vie 4,3 jours ($\varphi = 0{,}85$) ou 13,5 jours ($\varphi = 0{,}95$). Douze univers par scénario.

Tableau 7.1: Paires retenues par univers (moyenne sur 12 univers), selon la règle de sélection.

	Demi-vie 4,3 j		Demi-vie 13,5 j	
Règle	vraies	fausses	vraies	fausses
$p < 5\,\%$ (4 950 tests)	10,0	265,2	8,4	264,3
Bonferroni	9,0	0,0	0,1	0,0
Benjamini-Hochberg, $q = 5\,\%$	10,0	0,9	0,1	0,0
Même secteur (950 tests) + BH	10,0	0,7	0,3	0,1

Vérification en Python — E1 et E2, sélection et performance hors échantillon

Sélection (tableau 7.1) : sans correction, 96 % des paires retenues sont fausses. Avec BH, presque toutes sont vraies *si* le retour à la moyenne est rapide ; si la demi-vie est de 13,5 jours, 500 jours de formation ne suffisent plus à franchir le seuil corrigé et l'on ne retient presque rien. **Rendement hors échantillon par paire** (250 jours, en % du notionnel brut, moyenne des moyennes par univers $\pm$ erreur-type entre univers, scénario 4,3 j) : vraies paires $3{,}71 \pm 0{,}14$; paires partiellement liées $3{,}49 \pm 1{,}93$; paires sans lien $1{,}69 \pm 1{,}61$. Les moyennes par univers des paires sans lien vont de $-4{,}5\,\%$ à $+13{,}1\,\%$, celles des paires partiellement liées de $-7{,}6\,\%$ à $+17{,}2\,\%$, celles des vraies paires de $3{,}0\,\%$ à $4{,}6\,\%$.

Trois leçons.

1. **Les faux positifs ne perdent pas forcément d'argent en moyenne, ils ajoutent du risque.** Une paire sans lien a une espérance de gain nulle (l'écart est une martingale), mais une variance énorme : la moyenne d'un univers à l'autre oscille entre $-4{,}5$ et $+13{,}1\,\%$. Une petite moyenne positive sur un échantillon n'est pas une preuve. Remarquez aussi que l'erreur-type « naïve », qui traite les paires comme indépendantes, vaut $0{,}36\,\%$ alors que l'erreur-type correcte entre univers vaut $1{,}61\,\%$: des paires qui partagent des actions ne sont pas des observations indépendantes.

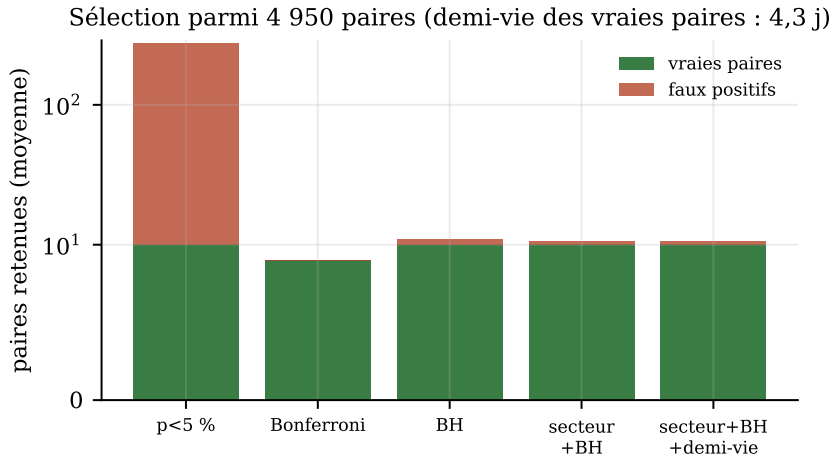


Figure 7.1: Paires retenues par univers selon la règle (échelle logarithmique au-delà de 10). Sans correction, les vraies paires (vert) sont noyées sous les faux positifs (rouge).

2. **Les relations partielles existent et rapportent, mais de façon instable.** Les paires partiellement liées gagnent en moyenne autant que les vraies, avec une dispersion entre univers environ quatorze fois plus grande.
3. **La correction a un prix : la puissance.** Quand la demi-vie est longue, la correction pour tests multiples supprime aussi les vraies paires. Il faut alors plus d'historique, des données plus fréquentes si la dynamique le permet, ou un a priori économique plus serré qui réduit le nombre de tests.

Vérification en Python — E3, persistance des paires retenues

Parmi les 131 paires retenues par BH (scénario 4,3 j, 12 univers), 122 sont de nouveau cointégrées à 5 % sur la fenêtre suivante (décalée de 250 jours), dont 120 vraies. La stabilité dans le temps est un excellent filtre complémentaire : une relation réelle se retrouve d'une fenêtre à l'autre.

7.5 Ratio de couverture : statique ou glissant ?

Une fois la paire retenue, faut-il garder le $\hat{\beta}$ estimé sur la formation ou le réestimer en continu sur une fenêtre glissante ? Une fenêtre glissante s'adapte aux changements, mais chaque réestimation sur peu de données ajoute du bruit, et ce bruit se transforme en P&L parasite : l'écart « bouge » parce que β bouge, pas parce que les prix ont bougé.

Vérification en Python — E4, erreur sur le ratio quand le vrai ratio est constant

Erreur absolue moyenne sur β (vrai $\beta = 1$, 30 vraies paires) : statique sur 500 jours 0,026 ; glissant sur 250 jours 0,033 ; glissant sur 60 jours 0,073.

Quand la relation est stable, la fenêtre glissante courte est presque trois fois moins précise. Elle ne se justifie que si le ratio change réellement ; et dans ce cas, le filtre de Kalman du chapitre 8 fait le même travail de façon optimale, en dosant automatiquement la réactivité.

7.6 Dimensionner les positions

Pour que chaque paire contribue au risque de façon comparable, on dimensionne la position par la volatilité de l'écart plutôt qu'en montant fixe : si l'écart (en log) a un écart-type quotidien σ_S, une position de notionnel K sur la jambe Y a un risque quotidien d'environ $K\sigma_S$. Viser un risque cible R par paire donne $K = R/\sigma_S$. On limite ensuite le notionnel total, l'exposition par secteur et l'exposition au facteur de marché résiduel (si $\hat{\beta}$ diffère des expositions réelles au marché, la paire n'est pas neutre). Le chapitre 17 traite le dimensionnement global.

7.7 Ce que la théorie apporte, et ses limites

Apports. Un cadre pour savoir combien de découvertes sont crédibles, une procédure qui garde la proportion de fausses paires sous contrôle, et un pipeline qui combine information économique et statistique.

Limites. Les corrections supposent que l'on compte honnêtement tous les tests ; la dépendance entre tests affaiblit les garanties ; la puissance chute quand les demi-vies sont longues ; et la cointégration passée ne garantit rien sur l'avenir : il faut surveiller les paires en continu et les retirer quand la relation se dégrade (chapitre 17).

7.8 Fiche à recopier au tableau blanc

Au tableau blanc

- **Faux positifs attendus :** $m\alpha$, avec $m = N(N-1)/2$.
- **FWER** $= \mathbb{P}(V \geq 1)$; **FDR** $= \mathbb{E}[V/\max(R,1)]$.
- **Bonferroni :** rejeter si $p < \alpha/m$; preuve par l'inégalité de la réunion.
- **BH :** plus grand k tel que $p_{(k)} \leq kq/m$; rejeter les k plus petites.
- **Pipeline :** a priori économique $\rightarrow$ test corrigé $\rightarrow$ demi-vie et amplitude $\rightarrow$ stabilité $\rightarrow$ contraintes pratiques.
- **Erreur-type honnête :** regrouper par univers ou période, jamais par paire si les paires partagent des actifs.
- **Taille :** notionnel $K = R/\sigma_S$.

7.9 Exercices

Exercice 7.1. Pour 30 actions d'un même secteur, combien de paires ? Quel seuil de Bonferroni à 5 % ? Combien de faux positifs attendus sans correction ?

Exercice 7.2. Appliquez BH à la main avec $q = 10\,\%$ aux p-valeurs 0,001 ; 0,008 ; 0,039 ; 0,041 ; 0,042 ; 0,06 ; 0,074 ; 0,205 ; 0,212 ; 0,216. Combien de rejets ? Combien avec Bonferroni ?

Exercice 7.3. Pourquoi les paires partiellement liées de l'expérience gagnent-elles de l'argent alors qu'aucune n'est cointégrée ? Reliez votre réponse à la proposition 4.2.

Exercice 7.4 (à coder)**.** Ajoutez au pipeline un filtre « demi-vie entre 2 et 20 jours » et un filtre de stabilité (cointégration sur chacune des deux moitiés de la formation). Mesurez l'effet sur la part de vraies paires dans le scénario de demi-vie 13,5 jours sans correction BH.

Exercice 7.5 (données réelles)**.** Construisez un univers d'une vingtaine d'actions d'un même secteur (téléchargées via Interactive Brokers) et appliquez le pipeline complet. Combien de paires survivent à BH ? Combien sont encore cointégrées six mois plus tard ?

7.10 Pour aller plus loin

Pour aller plus loin — quoi lire

- Vidyamurthy [48] : les chapitres consacrés à la sélection des paires et au test de la tendance commune.
- Huck [23] : une méthode de classement des paires par prévision et surclassement.
- Rad et al. [42] : protocole de comparaison des méthodes sur longue période.
- Harvey et al. [21] : les tests multiples en finance empirique, la référence pour comprendre pourquoi les seuils usuels sont trop faibles.

7.11 Scripts du chapitre

`code/ch07/ch07_cointegration_selection.py` : E1–E2 (tableau 7.1, figure 7.1), E3 (persistance), E4 (ratio statique contre glissant).

CHAPITRE 8

Modèles espace-état et filtre de Kalman

8.1 Objectifs et organisation du chapitre

Objectifs. Les chapitres précédents ont supposé un ratio de couverture constant. Dans la réalité, la relation entre deux actifs dérive. Le filtre de Kalman estime en temps réel des quantités cachées qui évoluent (un ratio de couverture, la composante stationnaire d'un écart) à partir d'observations bruitées. À la fin du chapitre, vous saurez : (1) écrire un modèle espace-état ; (2) dériver les équations du filtre de Kalman à partir du conditionnement gaussien ; (3) l'appliquer à une régression à coefficients variables et à l'estimation de la cointégration partielle ; (4) régler ses paramètres sans tomber dans le piège de la vraisemblance ; (5) en tirer un signal de trading.

Code. `code/ch08/ch08_kalman.py`, expériences E1 à E5.

8.2 Le modèle espace-état

Définition 8.1. Un modèle espace-état linéaire gaussien comprend :

$$\begin{aligned} \text{équation d'état :} \quad & \xi_t = F\,\xi_{t-1} + w_t, & & w_t \sim \mathcal{N}(0, Q), \\ \text{équation d'observation :} \quad & y_t = H_t\,\xi_t + v_t, & & v_t \sim \mathcal{N}(0, R), \end{aligned}$$

où ξ_t est l'état caché (non observé), y_t l'observation, F la matrice de transition, H_t la matrice d'observation (qui peut dépendre du temps), et w_t, v_t des bruits indépendants.

Image mentale

Vous suivez un bateau dans le brouillard. Vous savez à peu près comment il se déplace (équation d'état, avec une part d'imprévu), et de temps en temps un radar vous donne une position imprécise (équation d'observation). Le filtre de Kalman combine ces deux sources pour donner, à chaque instant, la meilleure estimation de la position et son incertitude. Il fait confiance au radar quand la prévision est incertaine, et à la prévision quand le radar est imprécis.

Exemples en arbitrage statistique.

- **Ratio de couverture variable :** $\xi_t = (\alpha_t, \beta_t)^\top$ suit une marche aléatoire ($F = I$), et l'on observe $y_t = \alpha_t + \beta_t x_t + v_t$, donc $H_t = (1, x_t)$.
- **Écart observé avec bruit** [14] : l'état ξ_t est un écart qui revient à la moyenne ($\xi_t = a + b\,\xi_{t-1} + w_t$, $|b| < 1$) et l'on observe $y_t = \xi_t + v_t$, où v_t représente le bruit de microstructure.
- **Cointégration partielle** [9] : $\xi_t = (M_t, R_t)^\top$, $F = \mathrm{diag}(\rho, 1)$, et l'écart observé est $S_t = M_t + R_t$, donc $H = (1, 1)$.

8.3 Les équations du filtre

8.3.1 Un résultat de conditionnement gaussien

Lemme 8.1. *Si (X, Y) est un vecteur gaussien de moyenne (μ_X, μ_Y) et de covariances Σ_{XX}, Σ_{XY}, Σ_{YY}, alors la loi de X sachant $Y = y$ est gaussienne de moyenne $\mu_X + \Sigma_{XY}\Sigma_{YY}^{-1}(y - \mu_Y)$ et de covariance $\Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}$.*

Démonstration. Posons $Z = X - \Sigma_{XY}\Sigma_{YY}^{-1} Y$. Alors $\mathrm{Cov}(Z, Y) = \Sigma_{XY} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YY} = 0$. Pour un vecteur gaussien, covariance nulle signifie indépendance : Z est indépendant de Y. Donc, sachant $Y = y$, $X = Z + \Sigma_{XY}\Sigma_{YY}^{-1} y$ a pour moyenne $\mathbb{E}[Z] + \Sigma_{XY}\Sigma_{YY}^{-1} y = \mu_X + \Sigma_{XY}\Sigma_{YY}^{-1}(y - \mu_Y)$ et pour covariance $\mathrm{Var}(Z) = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}$ (calcul direct avec la proposition 1.1 généralisée aux matrices). □

8.3.2 Prédiction et mise à jour

Supposons connue la loi de l'état sachant les observations jusqu'à $t-1$: $\mathcal{N}(m_{t-1}, P_{t-1})$.

Proposition 8.1 (Filtre de Kalman). ***Prédiction :*** $m_{t|t-1} = F m_{t-1}$, $\quad P_{t|t-1} = F P_{t-1} F^\top + Q$.

Innovation : $e_t = y_t - H_t m_{t|t-1}$, *de variance* $F_t = H_t P_{t|t-1} H_t^\top + R$.

Mise à jour : $K_t = P_{t|t-1} H_t^\top F_t^{-1}$, $\quad m_t = m_{t|t-1} + K_t e_t$, $\quad P_t = P_{t|t-1} - K_t H_t P_{t|t-1}$.

Démonstration. La prédiction découle de l'équation d'état : $\mathbb{E}[F\xi_{t-1} + w_t] = F m_{t-1}$ et $\mathrm{Var}(F\xi_{t-1} + w_t) = F P_{t-1} F^\top + Q$, car w_t est indépendant du passé. Sachant le passé, le couple (ξ_t, y_t) est gaussien, avec $\mathbb{E}[y_t] = H_t m_{t|t-1}$, $\mathrm{Var}(y_t) = H_t P_{t|t-1} H_t^\top + R = F_t$ et $\mathrm{Cov}(\xi_t, y_t) = P_{t|t-1} H_t^\top$. Le lemme 8.1 avec $X = \xi_t$, $Y = y_t$ donne exactement la mise à jour. □

Lecture dans le cas scalaire. Avec un état et une observation de dimension 1 et $H = 1$, le gain vaut $K = P/(P+R)$. Si la prévision est très incertaine ($P \gg R$), $K \approx 1$ et l'on suit l'observation ; si l'observation est très bruitée ($R \gg P$), $K \approx 0$ et l'on garde la prévision. La nouvelle estimation est une moyenne pondérée de la prévision et de l'observation, et sa variance $P(1-K) = PR/(P+R)$ est plus petite que chacune des deux.

8.3.3 Vraisemblance

Les innovations e_t sont indépendantes et de loi $\mathcal{N}(0, F_t)$ sous le modèle. La log-vraisemblance s'écrit donc simplement (décomposition par erreurs de prévision) :

$$\ell = -\frac{1}{2} \sum_t \left(\ln(2\pi F_t) + \frac{e_t^2}{F_t} \right).$$

On estime les paramètres inconnus (Q, R, $\rho \ldots$) en maximisant ℓ, comme au chapitre 2.

8.4 Ratio de couverture variable

8.4.1 Le modèle

On pose $\xi_t = (\alpha_t, \beta_t)^\top$, $F = I$, $Q = \frac{\delta}{1-\delta} I$ et $H_t = (1, x_t)$, suivant la paramétrisation popularisée par Chan [8] : δ règle la vitesse à laquelle les coefficients peuvent changer. Avec $\delta \to 0$, les coefficients sont constants et le filtre converge vers les MCO récursifs ; avec δ grand, ils suivent chaque mouvement.

Vérification en Python — E1 et E2, suivi d'un ratio qui dérive

Protocole : prix simulés, $y_t = 5 + \beta_t x_t + s_t$ avec β_t marche aléatoire (pas d'écart-type 0,003) et s_t AR(1) ($\varphi = 0{,}9$) ; 1 500 jours. **Erreur quadratique moyenne sur β_t** (après 250 jours) : Kalman 0,017 avec $\delta = 10^{-7}$; 0,031 avec 10^{-6} ; 0,061 avec 10^{-5} ; 0,091 avec 10^{-4}. MCO glissants : 0,113 (60 jours), 0,039 (250 jours) ; MCO statique sur la formation : 0,048. **Log-vraisemblance** : maximale pour $\delta = 10^{-5}$ ($-1\,370$), contre $-1\,928$ pour $\delta = 10^{-7}$.

8.4.2 Le piège de la vraisemblance

Le réglage qui maximise la vraisemblance n'est pas celui qui suit le mieux β_t. La raison est importante : dans notre modèle, l'écart s_t est autocorrélé, alors que le filtre suppose un bruit d'observation v_t indépendant. Pour mieux prédire y_t, le filtre a intérêt à faire bouger α_t et β_t pour absorber la partie prévisible de l'écart. Il gagne en vraisemblance… en « mangeant » l'écart que l'on veut justement trader.

Piège / limite

Un filtre de Kalman trop réactif fait disparaître le signal de retour à la moyenne dans l'état. Le critère de réglage doit correspondre à l'usage : pour un ratio de couverture, choisir δ petit (ou estimer δ sur un modèle qui inclut explicitement l'écart comme état AR(1), à la manière d'Elliott et al. [14]) et vérifier hors échantillon le P&L de la stratégie, pas seulement la vraisemblance.

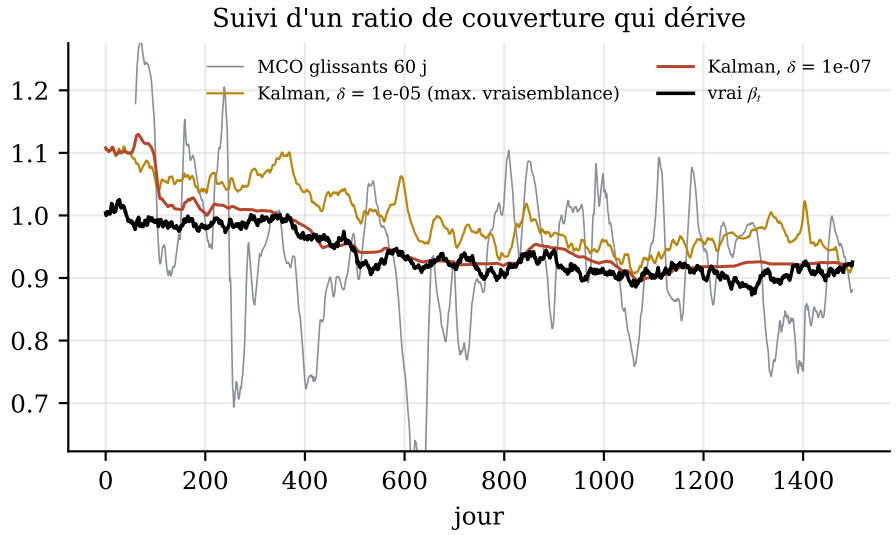


Figure 8.1: Vrai ratio de couverture (noir), estimations par MCO glissants sur 60 jours, et par filtre de Kalman avec deux réglages. Le réglage qui maximise la vraisemblance (or) suit trop nerveusement ; le réglage lent (rouge) suit la vraie dérive.

8.4.3 Un signal de trading

L'innovation e_t est l'écart entre le prix observé de y et sa valeur prédite par la relation estimée : c'est un *spread* à ratio variable, et $\sqrt{F_t}$ son écart-type prédit. Une règle simple : vendre l'écart quand $e_t > \sqrt{F_t}$, l'acheter quand $e_t < -\sqrt{F_t}$, fermer quand e_t change de signe ; le P&L utilise le ratio de la veille, pour ne pas anticiper.

Vérification en Python — E3, Kalman contre ratio statique

Protocole : 100 paires simulées avec β_t qui dérive, formation de 250 jours, trading de 750 jours, coûts de 5 pb par jambe. **Résultats** (rendement annuel sur le notionnel brut) : Kalman ($\delta = 10^{-6}$) 6,5 % en moyenne (écart-type 4,2 %, 99 % de paires gagnantes) ; ratio statique et *z-score* à 2 : 1,7 % (écart-type 2,4 %, 72 % de paires gagnantes).

Quand le ratio dérive réellement, le filtre maintient un écart stationnaire là où le ratio statique laisse l'écart dériver. Quand le ratio est stable (chapitre 7, E4), un filtre lent se comporte comme les MCO et ne coûte presque rien : c'est une assurance peu chère.

8.5 Estimer la cointégration partielle

Avec l'état (M_t, R_t), $F = \mathrm{diag}(\rho, 1)$, $Q = \mathrm{diag}(\sigma_M^2, \sigma_R^2)$, $H = (1,1)$ et un bruit d'observation négligeable, le filtre décompose l'écart observé en une partie qui revient à la moyenne et une partie qui dérive. On estime $(\rho, \sigma_M, \sigma_R)$ par maximum de vraisemblance.

Vérification en Python — E5, cointégration partielle

Protocole : vrais paramètres $\rho = 0{,}8$, $\sigma_M = 1$, $\sigma_R = 0{,}4$ ($R^2_{MR} = 0{,}874$), 25 écarts de 1 000 points. **Résultats** (médianes) : $\hat{\rho} = 0{,}801$, $\hat{\sigma}_M = 1{,}005$, $\hat{\sigma}_R = 0{,}379$, $\hat{R}^2_{MR} = 0{,}880$; intervalle 5–95 % de $\hat{\rho}$: $[0{,}73\,;\,0{,}84]$. Rappel : sur ce type d'écart, le test ADF du chapitre 4 échouait souvent à détecter quoi que ce soit.

En trading, on utilise l'estimation filtrée $\hat{M}_t$ (et non l'écart brut) pour le signal : on parie sur le retour de la composante stationnaire, pas sur celui de la marche aléatoire.

8.6 Études de cas réelles

Vérification en Python — E4, ratio de Kalman sur données réelles (log-prix, $\delta = 10^{-5}$)

KO sur PEP : $\hat{\beta}_t$ passe de 0,76 (après 30 séances) à 0,52 au milieu de l'échantillon et finit à 0,58. **GLD sur GLDM :** $\hat{\beta}_t$ part de 1,20 et converge vers 1,02.

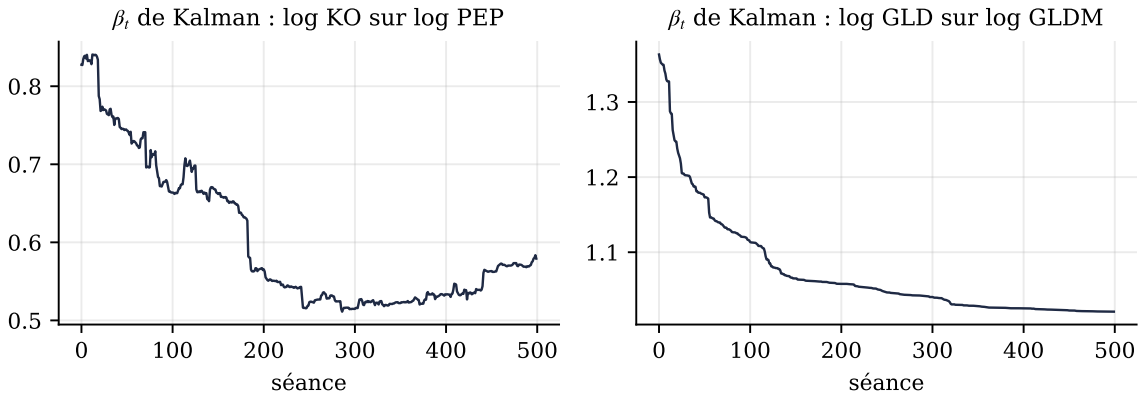


Figure 8.2: Ratio de couverture estimé par filtre de Kalman sur les log-prix réels.

Lecture. Pour GLD/GLDM, le vrai ratio en log vaut 1 ; le départ à 1,20 vient de l'initialisation et d'une difficulté d'identification : quand $\log x_t$ varie peu autour d'un niveau élevé (ici $\log 80 \approx 4{,}4$), l'ordonnée α_t et la pente β_t peuvent se compenser. Pour KO/PEP, le ratio local est positif (les deux titres bougent ensemble au jour le jour) alors que la régression statique sur deux ans donnait un ratio négatif (les niveaux ont divergé) : le filtre mesure une relation de court terme, ce qui ne garantit pas un écart stationnaire.

Piège / limite

Avec des log-prix, centrez la variable explicative (régressez sur $\log x_t - \overline{\log x}$) ou fixez l'ordonnée pour éviter la compensation entre α_t et β_t. Et ne jugez jamais un filtre sur ses premières dizaines d'observations, qui reflètent surtout l'initialisation.

8.7 Ce que la théorie apporte, et ses limites

Apports. Un estimateur récursif, optimal sous hypothèses gaussiennes, qui donne à chaque instant une estimation et son incertitude ; un cadre unique pour les ratios variables, les écarts bruités et la cointégration partielle ; une vraisemblance qui permet d'estimer les paramètres.

Limites. Optimalité seulement si le modèle est juste (linéaire, gaussien, bruits indépendants) ; sensibilité au réglage de Q et R, avec le piège de la vraisemblance quand le modèle est mal spécifié ; initialisation et identification délicates ; un ratio qui s'adapte peut aussi « suivre » une rupture au lieu de la signaler.

8.8 Fiche à recopier au tableau blanc

Au tableau blanc

- **Modèle :** $\xi_t = F\xi_{t-1} + w_t$ (Q) ; $y_t = H_t\xi_t + v_t$ (R).
- **Conditionnement :** $\mathbb{E}[X|y] = \mu_X + \Sigma_{XY}\Sigma_{YY}^{-1}(y-\mu_Y)$; $\mathrm{Var} = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}$.
- **Prédiction :** $m^- = Fm$, $P^- = FPF^\top + Q$.
- **Innovation :** $e = y - Hm^-$, $F_t = HP^-H^\top + R$.
- **Mise à jour :** $K = P^-H^\top F_t^{-1}$, $m = m^- + Ke$, $P = P^- - KHP^-$.
- **Scalaire :** $K = P/(P+R)$.
- **Vraisemblance :** $\ell = -\frac{1}{2}\sum(\ln 2\pi F_t + e_t^2/F_t)$.
- **Ratio variable :** $\xi = (\alpha,\beta)$, $F = I$, $Q = \frac{\delta}{1-\delta}I$, $H_t = (1, x_t)$; signal $e_t/\sqrt{F_t}$.

8.9 Exercices

Exercice 8.1. Dans le cas scalaire avec $F = 1$, $H = 1$, montrez que la variance P_t converge vers une valeur stationnaire P^* solution de $P^* = (P^*+Q)R/(P^*+Q+R)$. Calculez P^* et le gain stationnaire pour $Q = 1$, $R = 4$.

Exercice 8.2. Montrez que si $Q = 0$ et $F = I$, le filtre de Kalman de la régression à coefficients variables donne, à chaque date, l'estimateur MCO calculé sur toutes les observations passées (avec un a priori diffus).

Exercice 8.3. Expliquez pourquoi, dans le modèle d'Elliott et al. [14] où l'écart est un état AR(1) observé avec bruit, la variance du bruit d'observation réduit l'autocorrélation apparente de l'écart observé.

Exercice 8.4 (à coder)**.** Réécrivez E1 avec la variable explicative centrée et comparez les trajectoires de $\hat{\beta}_t$ pour GLD/GLDM. La convergence initiale est-elle plus rapide ?

Exercice 8.5 (à coder)**.** Ajoutez au modèle de ratio variable un troisième état, l'écart AR(1), et estimez δ, φ et la variance de l'écart par maximum de vraisemblance. Le δ estimé est-il proche du réglage qui suit le mieux β_t ?

8.10 Pour aller plus loin

Pour aller plus loin — quoi lire

- Hamilton [19], chapitre 13 (« The Kalman Filter ») : dérivation complète, vraisemblance et lissage.
- Elliott et al. [14] : le modèle d'écart caché et son estimation.
- Chan [8], chapitre 3 : le filtre de Kalman appliqué au ratio de couverture d'une paire d'ETF, avec code.
- Clegg and Krauss [9] : estimation de la cointégration partielle par filtre de Kalman.

8.11 Scripts du chapitre

`code/ch08/ch08_kalman.py` : E1–E2 (figure 8.1), E3, E4 (figure 8.2), E5.

CHAPITRE 9

Copules

9.1 Objectifs et organisation du chapitre

Objectifs. La corrélation résume la dépendance entre deux actifs par un seul nombre, qui ne dit rien des extrêmes : deux actions peuvent être modérément corrélées en temps normal et chuter ensemble lors des krachs. Les copules séparent la loi de chaque actif (sa « marge ») de la structure de dépendance. À la fin du chapitre, vous saurez : (1) énoncer le théorème de Sklar ; (2) mesurer la dépendance par le tau de Kendall et la dépendance de queue ; (3) manipuler les copules gaussienne, de Student et de Clayton ; (4) estimer une copule et choisir entre plusieurs ; (5) construire les signaux de trading proposés par Liew and Wu [34] et Xie et al. [49] et juger honnêtement de leur intérêt.

Code. `code/ch09/ch09_copulas.py`, expériences E1 à E4.

9.2 Définition et théorème de Sklar

9.2.1 Copule

Définition 9.1. Une *copule* bivariée est une fonction de répartition $C : [0,1]^2 \to [0,1]$ d'un couple (U,V) dont les deux marges sont uniformes sur $[0,1]$: $C(u,v) = \mathbb{P}(U \le u, V \le v)$, avec $C(u,1) = u$ et $C(1,v) = v$.

9.2.2 La transformation par la fonction de répartition

Si X a une fonction de répartition continue F_X, alors $U = F_X(X)$ est uniforme sur $[0,1]$. En effet, $\mathbb{P}(U \le u) = \mathbb{P}(F_X(X) \le u) = \mathbb{P}(X \le F_X^{-1}(u)) = F_X(F_X^{-1}(u)) = u$. Cette transformation enlève à X tout ce qui tient à sa loi propre (volatilité, épaisseur des queues) et ne garde que son *rang*.

Théorème 9.1 (Sklar)**.** *Pour tout couple (X,Y) de fonction de répartition jointe H et de marges continues F_X, F_Y, il existe une unique copule C telle que*

$$H(x,y) = C\big(F_X(x), F_Y(y)\big).$$

Réciproquement, toute copule combinée à deux marges quelconques définit une loi jointe valide.

Idée de la démonstration. On pose $U = F_X(X)$ et $V = F_Y(Y)$, uniformes d'après ce qui précède, et C la loi jointe de (U,V). Alors $H(x,y) = \mathbb{P}(X \le x, Y \le y) = \mathbb{P}(U \le F_X(x), V \le F_Y(y)) = C(F_X(x), F_Y(y))$, car F_X et F_Y sont croissantes. □

Image mentale

Une loi jointe, c'est une recette avec deux ingrédients séparables : la « forme » de chaque actif (ses marges) et la « façon dont ils dansent ensemble » (la copule). On peut garder les mêmes danseurs et changer de chorégraphie, ou l'inverse.

9.2.3 Mesures de dépendance

Tau de Kendall. Pour deux observations indépendantes (X_1,Y_1) et (X_2,Y_2) du couple, $\tau = \mathbb{P}\big((X_1 - X_2)(Y_1 - Y_2) > 0\big) - \mathbb{P}\big((X_1 - X_2)(Y_1 - Y_2) < 0\big)$: la probabilité que deux observations soient rangées dans le même ordre sur les deux actifs, moins celle qu'elles soient en ordre inverse. Il ne dépend que de la copule (les rangs ne changent pas si l'on applique une fonction croissante aux marges).

Dépendance de queue. La dépendance de queue inférieure est

$$\lambda_L = \lim_{q \to 0} \mathbb{P}\big(V \le q \mid U \le q\big),$$

la probabilité qu'un actif soit dans ses pires $q\,\%$ sachant que l'autre l'est, quand q devient très petit. On définit de même λ_U pour les hausses extrêmes.

9.2.4 Trois familles

Tableau 9.1: Trois copules usuelles. Φ : fonction de répartition normale ; t_ν : loi de Student à ν degrés de liberté.

Copule	Paramètre et lien avec τ	λ_L	λ_U
Gaussienne	$\rho = \sin(\pi\tau/2)$	0	0
Student (ν)	$\rho = \sin(\pi\tau/2)$	$2t_{\nu+1}\Big(-\sqrt{\frac{(\nu+1)(1-\rho)}{1+\rho}}\Big)$	idem
Clayton	$\theta = 2\tau/(1-\tau)$	$2^{-1/\theta}$	0

La copule de Clayton s'écrit $C(u,v) = (u^{-\theta} + v^{-\theta} - 1)^{-1/\theta}$: elle concentre la dépendance dans les baisses communes. La copule gaussienne n'a aucune dépendance de queue : quels que soient $\rho < 1$, les extrêmes deviennent asymptotiquement indépendants.

Vérification en Python — E1, même τ, extrêmes différents

Protocole : 400 000 tirages de chaque copule avec $\tau = 0{,}5$. **Résultats :** probabilité que les deux actifs soient simultanément dans leur pire 1 % : 0,27 % (gaussienne), 0,45 % (Student, $\nu = 4$), 0,70 % (Clayton), contre 0,01 % sous indépendance. Probabilité conditionnelle $\mathbb{P}(V < 1\,\% \mid U < 1\,\%)$: 0,27 ; 0,45 ; 0,70. Pour les hausses extrêmes, Clayton tombe à 0,03 %. Dépendances de queue théoriques : 0 ; 0,40 ; 0,71.

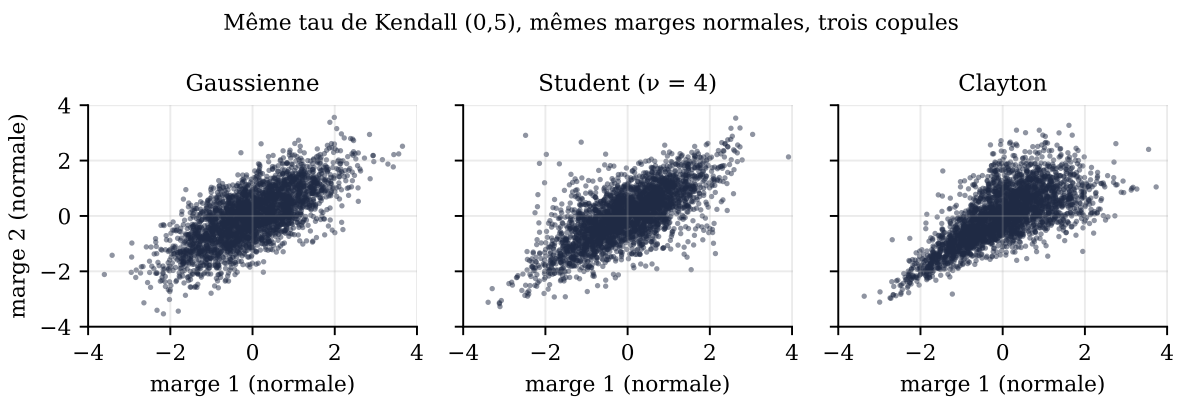


Figure 9.1: Trois copules de même tau de Kendall, représentées avec des marges normales. La Clayton resserre les points dans le coin inférieur gauche (baisses simultanées).

Lecture pour le trading. Une paire couverte avec un ratio estimé en temps normal est exposée à ce qui se passe dans les queues. Si la dépendance de queue est forte, les deux jambes chutent ensemble et la couverture tient ; si elle est faible (une jambe chute seule), l'écart explose. Le choix de la copule est donc d'abord une question de *gestion du risque*.

9.3 Estimation et choix de la copule

Pseudo-observations. On ne connaît pas les marges exactes ; on les remplace par les rangs : $\hat{u}_i = \text{rang}(x_i)/(n+1)$. Diviser par $n+1$ plutôt que n évite les valeurs 0 et 1, où les densités de copule peuvent être infinies.

Paramètre. Le plus simple est d'inverser la relation entre τ et le paramètre (tableau 9.1) ; le plus précis est le maximum de vraisemblance sur la densité de copule $c(u,v) = \partial^2 C/\partial u \partial v$.

Choix. On compare les familles par le critère d'Akaike, AIC $= 2k - 2\ell$, où k est le nombre de paramètres et ℓ la log-vraisemblance maximale ; plus petit est meilleur.

Vérification en Python — E2, estimation et choix par AIC

Protocole : 100 échantillons de 500 observations pour chaque vraie copule ($\tau = 0{,}5$). **Résultats :** la bonne famille est choisie 98 fois sur 100 (gaussienne), 100 fois (Student), 100 fois (Clayton) ; les paramètres estimés par inversion de τ valent en moyenne 0,710 (vrai 0,707), 0,704 et 2,011 (vrai 2).

9.4 Signaux de trading fondés sur les copules

9.4.1 La probabilité conditionnelle

La quantité clé est la *fonction h* : $h(u \mid v) = \mathbb{P}(U \le u \mid V = v) = \partial C(u,v)/\partial v$. Si $h(u_t \mid v_t)$ est proche de 1, l'actif X a fait « trop bien » aujourd'hui compte tenu de ce qu'a fait Y ; proche de 0, trop mal.

Proposition 9.1 (Fonction h gaussienne)**.** *Pour la copule gaussienne de paramètre ρ, $h(u \mid v) = \Phi\Big(\dfrac{\Phi^{-1}(u) - \rho\,\Phi^{-1}(v)}{\sqrt{1-\rho^2}}\Big)$.*

Démonstration. Posons $A = \Phi^{-1}(U)$ et $B = \Phi^{-1}(V)$: le couple (A,B) est gaussien centré réduit de corrélation ρ. D'après le lemme 8.1, sachant $B = b$, A suit $\mathcal{N}(\rho b, 1-\rho^2)$. Donc $\mathbb{P}(U \le u \mid V = v) = \mathbb{P}(A \le \Phi^{-1}(u) \mid B = \Phi^{-1}(v)) = \Phi\big((\Phi^{-1}(u) - \rho\Phi^{-1}(v))/\sqrt{1-\rho^2}\big)$. □

Pour Clayton, en dérivant C par rapport à v : $h(u \mid v) = v^{-\theta-1}(u^{-\theta} + v^{-\theta} - 1)^{-1/\theta-1}$.

9.4.2 Deux règles de la littérature

- Liew and Wu [34] : on calcule chaque jour $h(u_t \mid v_t)$ et $h(v_t \mid u_t)$ sur les rendements ; si la première est inférieure à 0,05 et la seconde supérieure à 0,95, X est jugé sous-évalué par rapport à Y : on achète X et vend Y.
- Xie et al. [49] : on cumule les « indices de mauvaise évaluation » $m_t = h(u_t \mid v_t) - 0{,}5$ dans le temps ; on ouvre quand les indices cumulés des deux actifs dépassent un seuil dans des sens opposés et on ferme quand ils reviennent à zéro.

Vérification en Python — E3, signal de copule cumulé contre *z-score*

Protocole : 60 paires simulées, cointégrées en log-prix (écart AR(1), $\varphi = 0{,}9$), chocs de Student à 3 degrés de liberté ; formation de 500 jours (estimation de la copule sur les rendements : la copule de Student est retenue 60 fois sur 60) ; trading de 500 jours ; coûts de 5 pb par jambe. **Résultats** (gain sur 500 jours, en % du notionnel brut) : *z-score* sur l'écart 9,1 % (écart-type 4,6 %) ; signal de copule cumulé (seuil 0,6) 1,6 % (écart-type 2,3 %).

Pourquoi la copule fait moins bien ici. Une copule estimée sur des rendements quotidiens décrit leur dépendance *instantanée*. Si les rendements sont indépendants d'un jour à l'autre, la copule ne contient aucune information sur l'avenir : un « rendement trop haut » n'est pas suivi d'une correction. Le signal ne gagne que dans la mesure où l'indice cumulé reconstruit l'écart de niveau, ce que le *z-score* fait directement. Rad et al. [42] trouvent de même que la méthode par copules n'est pas plus rentable que les méthodes par distance et cointégration, même si son profil de risque diffère.

Piège / limite

La copule n'est pas une source de rendement en soi. Elle n'apporte un avantage que si la structure de dépendance contient une information de retour à la moyenne que l'écart linéaire ignore. Son usage le plus robuste est ailleurs : modéliser les co-extrêmes pour dimensionner les positions et placer les stop-loss (chapitre 17).

9.5 Étude de cas réelle : KO et PEP

Vérification en Python — E4, copule des rendements quotidiens KO/PEP

Sur 499 rendements quotidiens : $\tau = 0{,}449$. Log-vraisemblances : gaussienne 121,4, Student ($\nu = 4$) 114,5, Clayton 46,5 : l'AIC retient la gaussienne. Jours où les deux titres sont simultanément dans leurs pires 5 % : 5 observés, contre 8,6 attendus avec la copule gaussienne ajustée, 10,8 avec la Student, 16,4 avec la Clayton et 1,2 sous indépendance.

Sur cette période, les deux titres n'ont pas eu plus de baisses communes extrêmes que ne le prévoit une copule gaussienne. Avec seulement cinq événements, l'incertitude est énorme : un seul épisode de stress aurait pu changer la conclusion. Pour estimer des queues, il faut des historiques longs.

9.6 Ce que la théorie apporte, et ses limites

Apports. Séparation propre entre marges et dépendance, mesures de dépendance robustes (rangs), modélisation explicite des co-extrêmes, probabilités conditionnelles interprétables.

Limites. La copule est statique : elle ne modélise pas la dynamique de retour à la moyenne qui fait gagner un *pairs trade*. Les queues sont estimées sur très peu de points. Le choix de la famille est un a priori fort ; les copules à paramètres variables dans le temps sont plus réalistes mais beaucoup plus difficiles à estimer.

9.7 Fiche à recopier au tableau blanc

Au tableau blanc

- **Transformation :** $U = F_X(X) \sim \mathcal{U}[0,1]$.
- **Sklar :** $H(x,y) = C(F_X(x), F_Y(y))$.
- **Kendall :** $\tau = \mathbb{P}(\text{concordance}) - \mathbb{P}(\text{discordance})$; gaussienne/Student : $\rho = \sin(\pi\tau/2)$; Clayton : $\theta = 2\tau/(1-\tau)$.
- **Queue :** $\lambda_L = \lim_{q\to 0} \mathbb{P}(V \le q \mid U \le q)$; Clayton $2^{-1/\theta}$; gaussienne 0.
- **Clayton :** $C = (u^{-\theta} + v^{-\theta} - 1)^{-1/\theta}$.
- **Fonction h :** $h(u|v) = \partial C/\partial v$; gaussienne $\Phi\big((\Phi^{-1}(u) - \rho\Phi^{-1}(v))/\sqrt{1-\rho^2}\big)$.
- **Pseudo-observations :** $\text{rang}/(n+1)$; choix par AIC $= 2k - 2\ell$.

9.8 Exercices

Exercice 9.1. Montrez que la copule d'indépendance est $C(u,v) = uv$ et que son tau de Kendall est nul.

Exercice 9.2. Démontrez la formule $\lambda_L = 2^{-1/\theta}$ pour la copule de Clayton en calculant $C(q,q)/q$ et en faisant tendre q vers 0.

Exercice 9.3. Dérivez la fonction h de la copule de Clayton à partir de $C(u,v)$.

Exercice 9.4 (à coder)**.** Ajoutez la copule de Clayton « tournée » (de survie) $\tilde{C}(u,v) = u + v - 1 + C(1-u, 1-v)$, qui a une dépendance de queue supérieure. Mesurez sur KO/PEP si elle améliore l'AIC.

Exercice 9.5 (à coder)**.** Modifiez E3 pour que les rendements simulés aient une composante prévisible (par exemple une réaction partielle de X aux chocs de Y du jour précédent). La copule estimée sur les couples (r^X_{t+1}, r^Y_t) fait-elle alors mieux que le *z-score* ?

9.9 Pour aller plus loin

Pour aller plus loin — quoi lire

- Liew and Wu [34] : la première application des copules au *pairs trading*, avec la règle des probabilités conditionnelles.
- Xie et al. [49] : l'indice de mauvaise évaluation cumulé.
- Rad et al. [42] : la comparaison de la méthode par copules avec les méthodes par distance et cointégration sur longue période.
- Krauss [29], partie consacrée aux « autres approches » : synthèse des variantes à base de copules.

9.10 Scripts du chapitre

`code/ch09/ch09_copulas.py` : E1 (figure 9.1), E2, E3, E4.

CHAPITRE 10

Arbitrage statistique multi-actifs

10.1 Objectifs et organisation du chapitre

Objectifs. Une paire est un cas particulier : on couvre une action par une autre. Plus généralement, on peut couvrir chaque action par les facteurs communs à tout le marché et trader ce qui reste, son *résidu*. C'est l'approche d'Avellaneda and Lee [2], qui a structuré l'arbitrage statistique institutionnel sur actions. À la fin du chapitre, vous saurez : (1) dériver l'analyse en composantes principales (ACP) et construire des portefeuilles propres ; (2) distinguer les vrais facteurs du bruit d'estimation (borne de Marchenko-Pastur) ; (3) modéliser les résidus par un processus d'Ornstein-Uhlenbeck et calculer le *s-score* ; (4) implémenter et tester la stratégie complète ; (5) situer les approches de portefeuilles de retour à la moyenne parcimonieux.

Code. `code/ch10/ch10_pca_statarb.py`.

10.2 L'analyse en composantes principales

10.2.1 Le problème

Soit C la matrice de corrélation des rendements standardisés de N actions ($N \times N$, symétrique, positive). On cherche la combinaison w (de norme 1) dont la variance $w^\top C w$ est maximale : la direction qui explique le plus de mouvements communs.

Proposition 10.1. *Le maximum de $w^\top C w$ sous la contrainte $w^\top w = 1$ est atteint en $w = v_1$, vecteur propre associé à la plus grande valeur propre λ_1 de C, et vaut λ_1. Les composantes suivantes sont les vecteurs propres suivants, orthogonaux entre eux.*

Démonstration. On introduit un multiplicateur de Lagrange λ et l'on annule le gradient de $w^\top C w - \lambda(w^\top w - 1)$: $2Cw - 2\lambda w = 0$, soit $Cw = \lambda w$. Les candidats sont donc les vecteurs propres de C, et pour un tel vecteur la variance vaut $w^\top C w = \lambda w^\top w = \lambda$. Le maximum est atteint pour la plus grande valeur propre. Pour la deuxième composante, on ajoute la contrainte d'orthogonalité à v_1 et le même raisonnement donne v_2. □

La somme des valeurs propres vaut $\mathrm{tr}(C) = N$; la part de variance expliquée par les k premières composantes est $\sum_{j \le k} \lambda_j / N$. Sur les actions, la première composante est presque toujours le « marché » (tous les poids de même signe), les suivantes opposent des secteurs ou des styles.

Portefeuilles propres. Les vecteurs propres portent sur des rendements standardisés ; pour obtenir un portefeuille investissable, on divise chaque poids par la volatilité de l'action : $Q_{ij} = v_{j,i}/\sigma_i$. Le rendement du facteur j est $F_{jt} = \sum_i Q_{ij} R_{it}$.

10.2.2 Combien de facteurs ? La borne de Marchenko-Pastur

Même si les actions étaient indépendantes, la matrice de corrélation estimée sur T jours aurait des valeurs propres dispersées autour de 1, par pur bruit d'échantillonnage. La théorie des matrices aléatoires montre que, pour des séries indépendantes et $N/T = q$ fixé, les valeurs propres se répartissent entre $(1-\sqrt{q})^2$ et $(1+\sqrt{q})^2$. Une valeur propre au-dessus de $(1+\sqrt{q})^2$ signale un facteur réel ; celles en dessous sont indiscernables du bruit.

Vérification en Python — E1, spectre et borne de Marchenko-Pastur

Protocole : 100 actions simulées avec 3 facteurs, fenêtre de 252 jours ($q = 0{,}40$, borne 2,66). **Résultats :** valeurs propres 29,7 ; 10,4 ; 6,8 ; puis 1,42 ; 1,39… Exactement trois valeurs propres dépassent la borne ; elles expliquent 47 % de la variance.

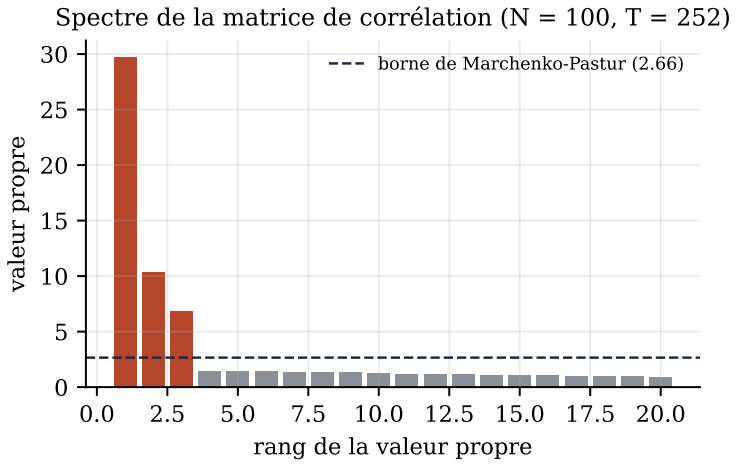


Figure 10.1: Les 20 plus grandes valeurs propres de la matrice de corrélation ; en rouge, celles qui dépassent la borne de Marchenko-Pastur.

10.3 Le modèle d'Avellaneda et Lee

10.3.1 Décomposition des rendements

Chaque action suit

$$\frac{\mathrm{d}P_{it}}{P_{it}} = \alpha_i \,\mathrm{d}t + \sum_{j=1}^{k} \beta_{ij} F_{jt} \,\mathrm{d}t + \mathrm{d}X_{it},$$

où les F_j sont les rendements des facteurs (portefeuilles propres ou ETF sectoriels) et X_{it} est le *résidu cumulé*, supposé suivre un processus d'Ornstein-Uhlenbeck (chapitre 5) : $\mathrm{d}X_{it} = \kappa_i(m_i - X_{it})\mathrm{d}t + \sigma_i \mathrm{d}W_{it}$. Une position longue sur l'action et courte sur β_{ij} unités de chaque facteur n'est exposée qu'à X_{it}.

Image mentale

Chaque action est un passager dans un bus (le marché) qui roule vite et change de direction. Le chauffeur, c'est le facteur ; on ne sait pas où il va. Mais chaque passager se déplace aussi dans l'allée, et il finit toujours par revenir à sa place. On ne parie pas sur la route du bus ; on parie que le passager qui est trop loin de sa place va y retourner.

10.3.2 Estimation, pas à pas

Chaque jour t :

1. **Facteurs :** ACP sur la matrice de corrélation des 252 derniers jours ; on garde k portefeuilles propres.
2. **Régression :** pour chaque action, régression de ses rendements des 60 derniers jours sur ceux des facteurs ; on obtient $\hat{\beta}_{ij}$ et les résidus $\hat{\varepsilon}_{is}$.
3. **Résidu cumulé :** $X_{is} = \sum_{u \le s} \hat{\varepsilon}_{iu}$ sur la fenêtre.
4. **AR(1) :** $X_{i,s+1} = a_i + b_i X_{is} + \zeta_{i,s+1}$; d'où, par la correspondance du chapitre 5, $\kappa_i = -252 \ln b_i$, $m_i = a_i/(1-b_i)$ et $\sigma_{eq,i} = \sqrt{\mathrm{Var}(\zeta_i)/(1-b_i^2)}$.
5. **s-score :** $s_i = (X_{it} - m_i)/\sigma_{eq,i}$: l'écart actuel du résidu à son équilibre, en écarts-types stationnaires.

10.3.3 Règles de trading

Avellaneda et Lee utilisent des seuils asymétriques : ouvrir une position courte si $s_i > 1{,}25$ et longue si $s_i < -1{,}25$; fermer la position courte quand $s_i < 0{,}75$ et la longue quand $s_i > -0{,}5$. Ils ne tradent que les actions dont le retour est assez rapide : $\kappa_i > 252/30$, soit un temps caractéristique $1/\kappa_i$ inférieur à environ 30 jours de bourse, une demi-vie inférieure à une vingtaine de jours. Chaque position est couverte par les facteurs, de sorte que le portefeuille est proche de la neutralité au marché.

Résultats publiés. Selon le résumé de l'article, la version ACP affiche un ratio de Sharpe annuel moyen de 1,44 sur 1997–2007 sur les actions américaines, avec une performance plus forte avant 2003 ; l'ajout d'une information de volume améliore les résultats.

10.4 Expérience

Vérification en Python — E2 et E3, stratégie s-score sur univers simulé

Protocole : 100 actions, 3 facteurs, 1 000 jours de trading. Scénario « signal » : résidus cumulés OU de demi-vie 8 jours (écart-type stationnaire 3 %) plus un bruit quotidien ; scénario « nul » : résidus en bruit blanc de même variance quotidienne. **Résultats** (rendement annuel ; ratio de Sharpe) :

	0 pb	5 pb	10 pb
Signal, $k = 1$ facteur	9,1 % ; 4,1	8,2 % ; 3,7	7,3 % ; 3,3
Signal, $k = 3$ facteurs	10,5 % ; 9,0	9,6 % ; 8,2	8,6 % ; 7,4
Signal, $k = 10$ facteurs	10,1 % ; 8,4	9,0 % ; 7,5	8,0 % ; 6,7
Nul, $k = 3$	−0,1 % ; −0,1	−1,0 % ; −0,8	−1,9 % ; −1,4

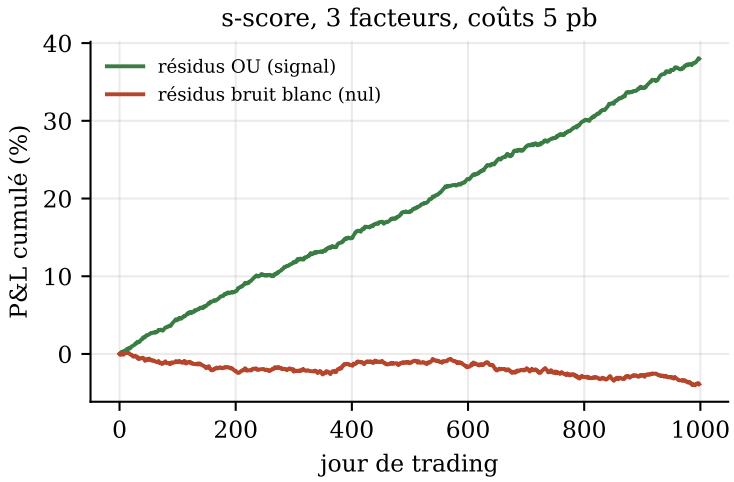


Figure 10.2: P&L cumulé de la stratégie s-score (3 facteurs, 5 pb) quand les résidus reviennent à la moyenne et quand ils ne le font pas.

Lecture. (1) Avec un seul facteur, une partie du risque sectoriel reste dans les résidus : la volatilité double et le Sharpe est divisé par deux. Avec trop de facteurs (10 au lieu de 3), on retire un peu de signal avec le bruit. Le bon nombre est celui que suggère Marchenko-Pastur. (2) Sans retour à la moyenne des résidus, la méthode ne gagne rien et perd ses coûts : elle ne crée pas d'avantage, elle l'exploite. (3) Les Sharpe de 8 du monde simulé sont irréalistes : le modèle y est exactement vrai, les paramètres constants, l'exécution parfaite. La valeur publiée de 1,44, en déclin, donne l'ordre de grandeur réel.

Piège / limite

Cette stratégie fait beaucoup de transactions sur beaucoup de titres : les coûts, l'impact et le coût d'emprunt des titres vendus à découvert y sont déterminants. Elle est aussi typiquement « encombrée »: lors de la crise d'août 2007, de nombreux fonds détenant des portefeuilles semblables ont dû liquider en même temps [28]. Pour un particulier, l'univers doit rester restreint aux titres très liquides et faciles à emprunter.

10.5 Portefeuilles de retour à la moyenne parcimonieux

Plutôt que de couvrir chaque action par des facteurs, on peut chercher directement la combinaison d'actifs la plus prévisible. Box and Tiao [6] posent le problème pour un VAR(1) $x_t = Ax_{t-1} + \varepsilon_t$: la prévisibilité d'un portefeuille w est le rapport entre la

variance de sa partie prévue et sa variance totale, $\lambda(w) = w^\top A\Gamma A^\top w / w^\top \Gamma w$ (avec Γ la covariance de x). Minimiser λ donne le portefeuille qui revient le plus vite à la moyenne ; c'est un problème de valeur propre généralisée, de même nature que la proposition 10.1. d'Aspremont [10] ajoute une contrainte de parcimonie (peu d'actifs non nuls) pour obtenir des portefeuilles tradables à faibles coûts.

10.6 Ce que la théorie apporte, et ses limites

Apports. Une généralisation naturelle du *pairs trading* à tout un univers, une neutralisation explicite des risques communs, un critère objectif du nombre de facteurs, et un signal (le *s-score*) directement issu du modèle OU.

Limites. Facteurs instables d'une fenêtre à l'autre (les vecteurs propres peuvent changer de signe ou d'ordre) ; estimation sur 60 jours très bruitée ; coûts élevés ; profits historiques en déclin ; risque de foule. L'approche demande une infrastructure de données et d'exécution plus lourde que le *pairs trading* simple.

10.7 Fiche à recopier au tableau blanc

Au tableau blanc

- **ACP :** $\max_w w^\top C w$ s.c. $w^\top w = 1 \Rightarrow Cw = \lambda w$; part expliquée $\sum_{j\le k} \lambda_j / N$.
- **Portefeuille propre :** $Q_{ij} = v_{j,i}/\sigma_i$, $F_{jt} = \sum_i Q_{ij} R_{it}$.
- **Marchenko-Pastur :** bruit entre $(1 \pm \sqrt{N/T})^2$.
- **Modèle :** $R_i = \alpha_i + \sum_j \beta_{ij} F_j + \mathrm{d}X_i$, X_i OU.
- **AR(1) sur X :** $\kappa = -252 \ln b$, $m = a/(1-b)$, $\sigma_{eq} = \sqrt{\mathrm{Var}(\zeta)/(1-b^2)}$.
- **s-score :** $s = (X - m)/\sigma_{eq}$; ouvrir à $\pm 1{,}25$, fermer court à $0{,}75$, long à $-0{,}5$; filtre $\kappa > 252/30$.
- **Box-Tiao :** minimiser $w^\top A\Gamma A^\top w / w^\top \Gamma w$.

10.8 Exercices

Exercice 10.1. Montrez que deux vecteurs propres d'une matrice symétrique associés à des valeurs propres distinctes sont orthogonaux. Pourquoi les rendements des portefeuilles propres sont-ils alors non corrélés sur la fenêtre d'estimation ?

Exercice 10.2. Calculez la borne de Marchenko-Pastur pour 500 actions et 252 jours, puis pour 500 actions et 1 000 jours. Commentez.

Exercice 10.3. Avec $b = 0{,}9$ sur données quotidiennes, calculez κ et la demi-vie. Le titre passe-t-il le filtre d'Avellaneda et Lee ?

Exercice 10.4 (à coder)**.** Remplacez les portefeuilles propres par un seul facteur « marché » égal à la moyenne des rendements et comparez avec $k = 1$ en ACP.

Exercice 10.5 (données réelles)**.** Construisez un univers de 30 à 50 ETF ou actions très liquides (via Interactive Brokers) et calculez le spectre de leur matrice de corrélation sur un an. Combien de valeurs propres dépassent la borne ?

10.9 Pour aller plus loin

Pour aller plus loin — quoi lire

- Avellaneda and Lee [2] : la section sur la construction des facteurs (ACP et ETF), celle sur le *s-score* et l'annexe sur l'estimation des paramètres OU.
- Box and Tiao [6] et d'Aspremont [10] : portefeuilles de retour à la moyenne.
- Khandani and Lo [28] : ce qui arrive quand tout le monde trade la même chose.
- Guijarro-Ordonez et al. [18] : la version « apprentissage profond » des signaux sur résidus, reprise au chapitre 11.

10.10 Scripts du chapitre

`code/ch10/ch10_pca_statarb.py` : E1 (figure 10.1), E2–E3 (figure 10.2).

CHAPITRE 11

Apprentissage automatique

11.1 Objectifs et organisation du chapitre

Objectifs. L'apprentissage automatique promet de découvrir des relations non linéaires que les modèles des chapitres précédents ignorent. Il promet aussi, et surtout, de se tromper avec une assurance remarquable. À la fin de ce chapitre, vous saurez : (1) situer les usages de l'apprentissage automatique en arbitrage statistique ; (2) construire variables explicatives et étiquettes sans information future ; (3) reconnaître et éviter la fuite d'information en validation croisée ; (4) comparer honnêtement un modèle complexe à une règle simple ; (5) utiliser la réduction de dimension et le *clustering* pour sélectionner des paires.

Code. `code/ch11/ch11_machine_learning.py` (`scikit-learn`).

11.2 Trois usages

1. **Prévoir les rendements relatifs.** Krauss et al. [30] entraînent chaque jour des réseaux profonds, du *gradient boosting* et des forêts aléatoires à prédire quelles actions du S&P 500 surperformeront la médiane le lendemain, à partir des rendements passés ; ils achètent les mieux classées et vendent les moins bien classées. L'ensemble des modèles produit, selon les auteurs, environ 0,45 % par jour avant coûts sur 1992–2015, avec un net déclin dans la période récente.
2. **Extraire des signaux des résidus.** Guijarro-Ordonez et al. [18] appliquent des réseaux convolutifs et des *transformers* aux trajectoires de résidus (au sens du chapitre 10) pour apprendre directement la règle de trading, et rapportent des ratios de Sharpe hors échantillon élevés.
3. **Sélectionner les paires.** Sarmento and Horta [43] réduisent la dimension des rendements par ACP, regroupent les actions par un algorithme de *clustering* (OPTICS), puis appliquent les tests de cointégration à l'intérieur des groupes.

11.3 Variables, étiquettes et fuite d'information

11.3.1 Variables et étiquettes

Une *variable explicative* (*feature*) f_t doit être calculable avec l'information disponible à la date t : rendements passés, *z-score* de l'écart, volatilité récente, demi-vie estimée. Une *étiquette* (*label*) y_t décrit ce qu'on veut prévoir et regarde par définition vers l'avenir : signe du rendement de l'écart sur les H prochains jours, ou résultat d'un trade (gain, perte, expiration) selon la méthode des trois barrières de López de Prado [36].

11.3.2 Le problème du chevauchement

Si l'étiquette porte sur $H > 1$ jours, les étiquettes de deux dates voisines partagent $H - 1$ jours de rendements futurs : y_t et y_{t+1} sont presque identiques. Une validation croisée classique (*K-fold*) qui mélange les dates place des dates voisines à la fois dans l'apprentissage et dans le test. Le modèle « reconnaît » la période et recopie l'étiquette de la date voisine : il paraît prévoir, alors qu'il se souvient.

Image mentale

C'est comme préparer un examen avec les corrigés de la veille d'une épreuve dont la moitié des questions sont reprises le lendemain. Votre note sera excellente, et ne dira rien de votre capacité à résoudre une question nouvelle.

Le remède : validation séquentielle purgée. On entraîne toujours sur le passé et on teste sur le futur (*walk-forward*) ; on *purge* de l'apprentissage les dates dont les étiquettes chevauchent la période de test, et l'on ajoute un *embargo* de quelques jours après le test [36].

Vérification en Python — E1, fuite d'information

Protocole : 10 marches aléatoires de 3 000 jours (*aucune* prévisibilité) ; six variables passées (rendements sur 1, 5, 10, 20 jours, *z-score* sur 20 jours, volatilité) ; étiquette : signe du rendement sur les 10 jours suivants ; forêt aléatoire de 200 arbres. **Résultats :** précision en validation croisée mélangée à 5 blocs : 58,4 % en moyenne (de 54,7 à 60,7 %) ; en validation séquentielle purgée : 50,7 % (de 46,4 à 55,0 %). La vraie précision possible est 50 %.

Piège / limite

Une précision de 58 % en validation croisée ressemble à une découverte majeure : avec un ratio gain/perte de 1, elle donnerait un ratio de Sharpe considérable. Elle est entièrement due à la fuite d'information. Toute étude d'apprentissage automatique en finance qui ne précise pas comment elle a évité le chevauchement doit être considérée comme fausse jusqu'à preuve du contraire.

11.4 Complexe contre simple

Quand la structure du signal est connue et linéaire (un écart qui revient à la moyenne), un modèle flexible doit au mieux redécouvrir la règle simple, avec plus de variance.

Vérification en Python — E2, forêt aléatoire contre règle *z-score*

Protocole : 10 écarts simulés (AR(1) avec $\varphi = 0{,}95$ plus une petite marche aléatoire), 4 000 jours, apprentissage sur la première moitié, test sur la seconde ; étiquette : signe du rendement du lendemain ; position de la forêt si la probabilité prédite sort de $[0{,}45\,;\,0{,}55]$; règle simple : *z-score* à 20 jours au-delà de ± 1 ; coûts de 1 pb. **Résultats :** taux de réussite 53,3 % (forêt) contre 53,5 % (règle) ; P&L moyen 0,54 contre 0,87 (en unités de l'écart).

La forêt n'apporte rien et perd une partie du signal : elle doit apprendre à partir de bruit ce que la règle encode directement. L'apprentissage automatique n'a d'intérêt que s'il existe une structure que les modèles simples ne capturent pas (interactions entre variables, non-linéarités, informations hétérogènes comme les volumes ou le carnet d'ordres), *et* assez de données pour l'apprendre.

Bonnes pratiques. Comparer systématiquement à une règle simple de référence ; préférer des modèles peu profonds et fortement régularisés ; compter toutes les variantes essayées (chapitre 16) ; mesurer l'importance des variables sur l'échantillon de test ; ré-entraîner à intervalles réguliers en walk-forward, jamais sur l'échantillon complet.

11.5 Sélection de paires par *clustering*

11.5.1 La méthode

Le chapitre 7 a montré que tester toutes les paires coûte cher en faux positifs. L'idée de Sarmento and Horta [43] : réduire d'abord l'univers à des groupes d'actions qui se ressemblent, puis tester seulement à l'intérieur des groupes.

1. On standardise les rendements et l'on fait une ACP : chaque action est représentée par ses coordonnées sur les k premières composantes (ses « expositions » aux facteurs).
2. On regroupe les actions proches dans cet espace avec OPTICS, un algorithme qui détecte des groupes de densité variable et laisse de côté les points isolés.
3. On teste la cointégration (avec correction BH) uniquement pour les paires d'un même groupe.

Vérification en Python — E3, ACP + OPTICS + cointégration

Protocole : univers simulé du chapitre 7 (100 actions, 10 vraies paires de demi-vie 4,3 jours), 500 jours ; 8 composantes ; OPTICS avec `min_samples = 2`. **Résultats** (4 univers) : 27 à 31 groupes ; 57 à 93 paires candidates au lieu de 4 950 ; les 10 vraies paires sont toujours parmi les candidates ; après BH, 10 ou 11 paires retenues dont les 10 vraies.

Le *clustering* divise le nombre de tests par 50 à 80 sans perdre les vraies paires, ce qui rend la correction pour tests multiples beaucoup moins coûteuse en puissance. Dans cette simulation, les deux actions d'une vraie paire ont exactement les mêmes expositions aux facteurs, ce qui les rend faciles à regrouper ; sur données réelles, les groupes sont moins nets et le résultat doit être vérifié.

11.6 Ce que la théorie apporte, et ses limites

Apports. Des modèles capables d'exploiter des structures non linéaires et des données hétérogènes ; des outils de réduction de dimension et de regroupement qui structurent la recherche de paires ; une discipline de validation (purge, embargo, walk-forward) utile à toute stratégie.

Limites. Rapport signal/bruit très faible des rendements financiers ; non-stationnarité (ce qui a été appris peut ne plus valoir) ; risque de surapprentissage démultiplié par le nombre d'hyperparamètres ; résultats publiés obtenus sur des univers très liquides, avec des coûts que le particulier ne peut pas toujours égaler ; opacité qui complique le diagnostic quand la stratégie se dégrade.

11.7 Fiche à recopier au tableau blanc

Au tableau blanc

- **Variable :** calculable en t ; **étiquette :** regarde vers $t+H$.
- **Chevauchement :** étiquettes à horizon H partagent $H-1$ jours $\Rightarrow$ K-fold mélangé fuit.
- **Remède :** walk-forward, purge des dates qui chevauchent le test, embargo.
- **Test de base :** toujours comparer à une règle simple sur le même échantillon de test.
- **Sélection :** ACP (expositions) $\rightarrow$ OPTICS (groupes) $\rightarrow$ cointégration intra-groupe + BH.

11.8 Exercices

Exercice 11.1. Avec une étiquette à horizon $H = 10$ et 2 500 dates, combien de dates faut-il purger autour d'un bloc de test de 250 dates ? Quelle fraction des données d'apprentissage perd-on par bloc ?

Exercice 11.2. Expliquez pourquoi une forêt aléatoire dont les feuilles contiennent une seule observation (`min_samples_leaf = 1`) amplifie la fuite d'information de E1.

Exercice 11.3 (à coder)**.** Refaites E1 avec `min_samples_leaf = 200`. La précision de la validation mélangée baisse-t-elle ? Disparaît-elle ?

Exercice 11.4 (à coder)**.** Dans E2, ajoutez une non-linéarité réelle : le retour à la moyenne n'existe que quand la volatilité récente est basse. La forêt bat-elle alors la règle simple ? Avec combien de données ?

Exercice 11.5 (données réelles)**.** Appliquez la méthode ACP + OPTICS à un univers d'une cinquantaine d'actions de deux ou trois secteurs. Les groupes trouvés correspondent-ils aux secteurs ?

11.9 Pour aller plus loin

Pour aller plus loin — quoi lire

- López de Prado [36], chapitres 3 (étiquetage, méthode des trois barrières), 4 (pondération des échantillons qui se chevauchent) et 7 (validation croisée purgée).
- Krauss et al. [30] : protocole complet de prévision quotidienne sur le S&P 500.
- Guijarro-Ordonez et al. [18] : signaux appris sur les résidus d'arbitrage statistique.
- Sarmento and Horta [43] : la sélection de paires par ACP et OPTICS.

11.10 Scripts du chapitre

`code/ch11/ch11_machine_learning.py` : E1 (fuite d'information), E2 (forêt contre règle), E3 (*clustering*).

PARTIE III

Arbitrage inter-plateformes

CHAPITRE 12

À rédiger

CHAPITRE 13

À rédiger

CHAPITRE 14

À rédiger

CHAPITRE 15

À rédiger

PARTIE IV

Validation, risque et mise en production

CHAPITRE 16

À rédiger

CHAPITRE 17

À rédiger

CHAPITRE 18

À rédiger

CHAPITRE A

Formulaire

Bibliographie

[1] ATJ Traders. atjte: cross-venue arbitrage market-making engines. `https://github.com/atj-khactu/atjte`, licence MIT, 2026.

[2] Marco Avellaneda and Jeong-Hyun Lee. Statistical arbitrage in the US equities market. *Quantitative Finance*, 10(7):761–782, 2010.

[3] David H. Bailey and Marcos López de Prado. The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5):94–107, 2014.

[4] David H. Bailey, Jonathan M. Borwein, Marcos López de Prado, and Qiji Jim Zhu. The probability of backtest overfitting. *Journal of Computational Finance*, 20(4):39–69, 2017.

[5] William K. Bertram. Analytic solutions for optimal statistical arbitrage trading. *Physica A*, 389(11):2234–2243, 2010.

[6] George E. P. Box and George C. Tiao. A canonical analysis of multiple time series. *Biometrika*, 64(2):355–365, 1977.

[7] Eric Budish, Peter Cramton, and John Shim. The high-frequency trading arms race: frequent batch auctions as a market design response. *Quarterly Journal of Economics*, 130(4):1547–1621, 2015.

[8] Ernest P. Chan. *Algorithmic Trading: Winning Strategies and Their Rationale*. Wiley, 2013.

[9] Matthew Clegg and Christopher Krauss. Pairs trading with partial cointegration. *Quantitative Finance*, 18(1):121–138, 2018.

[10] Alexandre d'Aspremont. Identifying small mean-reverting portfolios. *Quantitative Finance*, 11(3):351–364, 2011.

[11] David A. Dickey and Wayne A. Fuller. Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74:427–431, 1979.

[12] Binh Do and Robert Faff. Does simple pairs trading still work? *Financial Analysts Journal*, 66(4):83–95, 2010.

[13] Binh Do and Robert Faff. Are pairs trading profits robust to trading costs? *Journal of Financial Research*, 35(2):261–287, 2012.

[14] Robert J. Elliott, John van der Hoek, and William P. Malcolm. Pairs trading. *Quantitative Finance*, 5(3):271–276, 2005.

[15] Robert F. Engle and Clive W. J. Granger. Co-integration and error correction: representation, estimation, and testing. *Econometrica*, 55(2):251–276, 1987.

[16] Evan Gatev, William N. Goetzmann, and K. Geert Rouwenhorst. Pairs trading: performance of a relative-value arbitrage rule. *Review of Financial Studies*, 19(3):797–827, 2006.

[17] Clive W. J. Granger and Paul Newbold. Spurious regressions in econometrics. *Journal of Econometrics*, 2(2):111–120, 1974.

[18] Jorge Guijarro-Ordonez, Markus Pelger, and Greg Zanotti. Deep learning statistical arbitrage. arXiv:2106.04028, 2021.

[19] James D. Hamilton. *Time Series Analysis*. Princeton University Press, 1994.

[20] Larry Harris. *Trading and Exchanges: Market Microstructure for Practitioners*. Oxford University Press, 2003.

[21] Campbell R. Harvey, Yan Liu, and Heqing Zhu. ... and the cross-section of expected returns. *Review of Financial Studies*, 29 (1):5–68, 2016.

[22] Steve Hogan, Robert Jarrow, Melvyn Teo, and Mitch Warachka. Testing market efficiency using statistical arbitrage with applications to momentum and value strategies. *Journal of Financial Economics*, 73(3):525–565, 2004.

[23] Nicolas Huck. Pairs selection and outranking: an application to the S&P 100 index. *European Journal of Operational Research*, 196(2):819–825, 2009.

[24] Hudson & Thames. Arbitragelab: a collection of algorithms for statistical arbitrage. `https://github.com/hudson-and-thames/arbitragelab`, licence BSD-3, 2024.

[25] John C. Hull. *Options, Futures, and Other Derivatives*. Pearson, 11 edition, 2022.

[26] Søren Johansen. Estimation and hypothesis testing of cointegration vectors in gaussian vector autoregressive models. *Econometrica*, 59(6):1551–1580, 1991.

[27] Maurice G. Kendall. Note on bias in the estimation of autocorrelation. *Biometrika*, 41(3/4):403–404, 1954.

[28] Amir E. Khandani and Andrew W. Lo. What happened to the quants in August 2007? Evidence from factors and transactions data. *Journal of Financial Markets*, 14(1):1–46, 2011.

[29] Christopher Krauss. Statistical arbitrage pairs trading strategies: review and outlook. *Journal of Economic Surveys*, 31(2): 513–545, 2017.

[30] Christopher Krauss, Xuan Anh Do, and Nicolas Huck. Deep neural networks, gradient-boosted trees, random forests: statistical arbitrage on the S&P 500. *European Journal of Operational Research*, 259(2):689–702, 2017.

[31] Denis Kwiatkowski, Peter C. B. Phillips, Peter Schmidt, and Yongcheol Shin. Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, 54:159–178, 1992.

[32] Tim Leung and Xin Li. Optimal mean reversion trading with transaction costs and stop-loss exit. *International Journal of Theoretical and Applied Finance*, 18(3):1550020, 2015.

[33] Tim Leung and Xin Li. *Optimal Mean Reversion Trading: Mathematical Analysis and Practical Applications*. World Scientific, 2016.

[34] Rong Qi Liew and Yuan Wu. Pairs trading: a copula approach. *Journal of Derivatives & Hedge Funds*, 19(1):12–30, 2013.

[35] Andrew W. Lo and A. Craig MacKinlay. Stock market prices do not follow random walks: evidence from a simple specification test. *Review of Financial Studies*, 1(1):41–66, 1988.

[36] Marcos López de Prado. *Advances in Financial Machine Learning*. Wiley, 2018.

[37] Igor Makarov and Antoinette Schoar. Trading and arbitrage in cryptocurrency markets. *Journal of Financial Economics*, 135(2):293–319, 2020.

[38] Michael P. Murray. A drunk and her dog: an illustration of cointegration and error correction. *The American Statistician*, 48 (1):37–39, 1994.

[39] Whitney K. Newey and Kenneth D. West. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3):703–708, 1987.

[40] NexusFi. Prohibited strategies on prop firm funded accounts. `https://nexusfi.com/a/prop-firms/prohibited-strategies-funded-accounts`, consulté le 20 octobre 2026, 2026.

[41] Andrew Pole. *Statistical Arbitrage: Algorithmic Trading Insights and Techniques*. Wiley, 2007.

[42] Hossein Rad, Rand Kwong Yew Low, and Robert Faff. The profitability of pairs trading strategies: distance, cointegration and copula methods. *Quantitative Finance*, 16(10):1541–1558, 2016.

[43] Simão Moraes Sarmento and Nuno Horta. Enhancing a pairs trading strategy with the application of machine learning. *Expert Systems with Applications*, 158:113490, 2020.

[44] Skipper Seabold and Josef Perktold. statsmodels: econometric and statistical modeling with Python. Proceedings of the 9th Python in Science Conference, 2010.

[45] Andrei Shleifer and Robert W. Vishny. The limits of arbitrage. *Journal of Finance*, 52(1):35–55, 1997.

[46] Ruey S. Tsay. *Analysis of Financial Time Series*. Wiley, 3 edition, 2010.

[47] George E. Uhlenbeck and Leonard S. Ornstein. On the theory of the brownian motion. *Physical Review*, 36:823–841, 1930.

[48] Ganapathy Vidyamurthy. *Pairs Trading: Quantitative Methods and Analysis*. Wiley, 2004.

[49] Wenjun Xie, Rong Qi Liew, Yuan Wu, and Xi Zou. Pairs trading with copulas. *Journal of Trading*, 11(3):41–52, 2016.